



การพัฒนาแชทบอทถามตอบด้วยโมเดลภาษาขนาดใหญ่  
กรณีศึกษาของพัฒนานักศึกษามหาวิทยาลัยราชภัฏนครปฐม  
Development of a Chatbot Using a Large Language Model: A  
Case Study of Divitions of Student Development Nakhon  
Pathom Rajabhat University

|             |               |              |           |
|-------------|---------------|--------------|-----------|
| นายพัชรพงศ์ | ธิติวานิชย์   | รหัสประจำตัว | 654230016 |
| นายชาญวิทย์ | เทพเทียน      | รหัสประจำตัว | 654230023 |
| นายลภัส     | โพธิ์ทองคำ    | รหัสประจำตัว | 654230025 |
| นายวัฒนา    | รัตนสุวรรณชัย | รหัสประจำตัว | 654230048 |

โครงการนี้เป็นส่วนหนึ่งของการศึกษารายวิชา 7204903  
โครงการด้านเทคโนโลยีสารสนเทศ 2  
สาขาวิชาเทคโนโลยีสารสนเทศ คณะวิทยาศาสตร์และเทคโนโลยี  
มหาวิทยาลัยราชภัฏนครปฐม  
ภาคเรียนที่ 1 ปีการศึกษา 2569

การพัฒนาแชทบอทถามตอบด้วยโมเดลภาษาขนาดใหญ่  
กรณีศึกษาของพัฒนานักศึกษามหาวิทยาลัยราชภัฏนครปฐม  
Development of a Chatbot Using a Large Language Model: A  
Case Study of Divitions of Student Development Nakhon  
Pathom Rajabhat University

|             |               |              |           |
|-------------|---------------|--------------|-----------|
| นายพัชรพงศ์ | ธิติวานิชย์   | รหัสประจำตัว | 654230016 |
| นายชาญวิษฐ์ | เทพเทียน      | รหัสประจำตัว | 654230023 |
| นายลภัส     | โพธิ์ทองคำ    | รหัสประจำตัว | 654230025 |
| นายวัฒนา    | รัตนสุวรรณชัย | รหัสประจำตัว | 654230048 |

หมู่เรียน 65/41

โครงการนี้เป็นส่วนหนึ่งของการศึกษารายวิชา 7204903  
โครงการด้านเทคโนโลยีสารสนเทศ 2  
สาขาวิชาเทคโนโลยีสารสนเทศ คณะวิทยาศาสตร์และเทคโนโลยี  
มหาวิทยาลัยราชภัฏนครปฐม  
ภาคเรียนที่ 1 ปีการศึกษา 2569

## โครงการด้านเทคโนโลยีสารสนเทศ

เรื่อง

การพัฒนาเซตบอทดถามด้วยโมเดลภาษาขนาดใหญ่  
กรณีศึกษาของพัฒนานักศึกษามหาวิทยาลัยราชภัฏนครปฐม  
ได้รับพิจารณาให้เป็นส่วนหนึ่งของการศึกษาตามหลักสูตร วิทยาศาสตร์บัณฑิต  
สาขาวิชาเทคโนโลยีสารสนเทศ ภาคเรียนที่ 1 ปีการศึกษา 2569

วัน/เดือน/ปี

.....

.....

.....

(นายพัชรพงศ์ ธิติวานิชย์)  
ผู้จัดทำ

(นายชาญวิทย์ เทพเทียน)  
ผู้จัดทำ

.....

.....

(นายลภัส โพธิ์ทองคำ)  
ผู้จัดทำ

(นายวัฒนา รัตนสุวรรณชัย)  
ผู้จัดทำ

.....

(อาจารย์ ดร.ปริพัส ศรีสมบูรณ์)  
กรรมการสอบ

.....

(ผู้ช่วยศาสตราจารย์ พิชยา สุขปลั่ง)  
กรรมการสอบ

.....

.....

(ผู้ช่วยศาสตราจารย์ ดร.สุพิชฌาย์ จันทร์เรือง)  
กรรมการสอบ

(อาจารย์แก้วใจ อภรณ์พิศาล)  
กรรมการสอบ

.....

.....

(ผู้ช่วยศาสตราจารย์ ศุภกฤษ นาคป้อมฉิน)  
ประธานสาขาวิชาเทคโนโลยีสารสนเทศ

(ผู้ช่วยศาสตราจารย์ ศุภกฤษ นาคป้อมฉิน)  
อาจารย์ที่ปรึกษา

|                        |                                                                                                 |
|------------------------|-------------------------------------------------------------------------------------------------|
| ชื่อโครงการ            | การพัฒนาแชทบอทถามตอบด้วยโมเดลภาษาขนาดใหญ่กรณีศึกษาของพัฒนานักศึกษามหาวิทยาลัยราชภัฏนครปฐม       |
| ผู้จัดทำ               | นายพัชรพงศ์ อิตินาวิชย์<br>นายชาญวิทย์ เทพเทียน<br>นายลภัส โพธิ์ทองคำ<br>นายวัฒนา รัตนสุวรรณชัย |
| อาจารย์ที่ปรึกษา       | ผู้ช่วยศาสตราจารย์ ศุภกฤษ นาคป้อมฉิน                                                            |
| ระดับการศึกษา          | วิทยาศาสตร์บัณฑิต                                                                               |
| สาขาวิชา               | เทคโนโลยีสารสนเทศ                                                                               |
| ภาคเรียนที่/ปีการศึกษา | 1/2569                                                                                          |

## บทคัดย่อ

โครงการฉบับนี้มีวัตถุประสงค์เพื่อพัฒนาแชทบอทถามตอบด้วยโมเดลภาษาขนาดใหญ่กรณีศึกษาของพัฒนานักศึกษามหาวิทยาลัยราชภัฏนครปฐมผ่านช่องทาง LINE โดยประยุกต์ใช้โมเดลภาษาขนาดใหญ่ (Large Language Model: LLM) ร่วมกับเทคนิค Retrieval-Augmented Generation (RAG) เพื่อช่วยค้นคืนข้อมูลจากฐานความรู้ก่อนนำไปใช้ในการสร้างคำตอบสำหรับผู้ใช้งาน ระบบได้รับการพัฒนาด้วย n8n โดยใช้ Supabase Vector Database สำหรับจัดเก็บข้อมูลเวกเตอร์ ใช้โมเดล nomic-embed-text สำหรับสร้าง Embedding และใช้ Google Gemini เป็นแบบจำลองภาษาสำหรับสร้างคำตอบ

การทดลองใช้ชุดคำถามจำนวน 100 ข้อ และกำหนดรูปแบบการทดลองจำนวน 8 รูปแบบ โดยปรับค่าพารามิเตอร์ของกระบวนการ RAG ได้แก่ Chunk Size, Chunk Overlap และ Top-k เพื่อศึกษาผลของการตั้งค่าที่แตกต่างกันต่อคุณภาพของคำตอบ จากนั้นประเมินผลระบบด้วยเครื่องมือ RAGAS, DeepEval, TruLens และ LLM-as-a-Judge เพื่อประเมินคุณภาพของการค้นคืนข้อมูลและคำตอบจากหลายมิติ

ผลการทดลองพบว่า Exp 06 ซึ่งกำหนดค่า Chunk Size เท่ากับ 512, Chunk Overlap เท่ากับ 64 และ Top-k เท่ากับ 5 ให้ผลการประเมินโดยรวมดีที่สุดเมื่อเปรียบเทียบกับารทดลองรูปแบบอื่น โดยมีค่า Final Combined เท่ากับ 0.3682 จากการประเมินด้วย RAGAS, DeepEval, TruLens และ LLM-as-a-Judge นอกจากนี้ ผลการวิเคราะห์ความสอดคล้องของเครื่องมือประเมินทั้ง 4 แหล่งพบว่ามีค่าความสอดคล้องกันในระดับสูง โดยมีค่า Cronbach's Alpha เท่ากับ 0.9249

ผลการวิจัยแสดงให้เห็นว่า การกำหนดค่าพารามิเตอร์ของกระบวนการ RAG มีผลต่อคุณภาพของข้อมูลที่ค้นคืนและคำตอบของระบบแชทบอท และการประเมินด้วยเครื่องมือหลายรูปแบบสามารถนำมาใช้เพื่อวิเคราะห์คุณภาพของระบบถาม-ตอบผ่าน LINE ได้

## กิตติกรรมประกาศ

โครงการพัฒนาเว็บพหุภาษาด้วยโมเดลภาษาขนาดใหญ่กรณีศึกษาของพัฒนานักศึกษามหาวิทยาลัยราชภัฏนครปฐมฉบับนี้สำเร็จได้ด้วยความอนุเคราะห์และความช่วยเหลือจากบุคคลหลายฝ่าย ผู้วิจัยขอกราบขอบพระคุณ ผู้ช่วยศาสตราจารย์ ศุภฤกษ์ นาคป้อมฉิน ที่ปรึกษาโครงการ ที่ได้ให้คำแนะนำ ข้อคิดเห็น และแนวทางในการดำเนินงานวิจัย ตลอดจนให้การสนับสนุน และตรวจสอบความถูกต้องของงานวิจัยมาโดยตลอด

ขอขอบพระคุณคณาจารย์สาขาวิชาเทคโนโลยีสารสนเทศทุกท่าน ที่ได้ประสิทธิ์ประสาทวิชาความรู้และประสบการณ์อันเป็นประโยชน์ต่อการศึกษาและการจัดทำโครงการวิจัยฉบับนี้

ขอขอบคุณผู้เขียนหนังสือทุกเล่ม เจ้าของบทความ และเว็บไซต์ที่ใช้ในการศึกษาเพิ่มเติม เพื่อให้โครงการนี้ประสบความสำเร็จ

สุดท้ายนี้ ผู้วิจัยขอขอบพระคุณบิดา มารดา ครอบครัว และเพื่อน ๆ ที่ให้กำลังใจ ความช่วยเหลือ และการสนับสนุนในทุกด้าน จนทำให้การจัดทำโครงการวิจัยฉบับนี้สำเร็จลุล่วงไปด้วยดี

นายพัชรพงศ์    ธิดิวานิชย์  
 นายชาญวิทย์    เทพเทียน  
 นายลภัส         โพธิ์ทองคำ  
 นายวัฒนา    รัตนสุวรรณชัย

## สารบัญ

| เรื่อง                                   | หน้า |
|------------------------------------------|------|
| บทคัดย่อ.....                            | ก    |
| กิตติกรรมประกาศ.....                     | ข    |
| สารบัญ .....                             | ค    |
| สารบัญตาราง.....                         | จ    |
| สารบัญภาพ.....                           | ฉ    |
| บทที่ 1 บทนำ                             |      |
| 1.1 ความเป็นมาและความสำคัญของปัญหา ..... | 1    |
| 1.2 แนวคิดในการแก้ไขปัญหา .....          | 2    |
| 1.3 วัตถุประสงค์ของระบบ .....            | 2    |
| 1.4 ขอบเขตการศึกษา.....                  | 2    |
| 1.5 ระยะเวลาดำเนินงาน .....              | 3    |
| 1.6 ประโยชน์ที่ได้คาดว่าจะได้รับ .....   | 4    |
| บทที่ 2 หลักการและทฤษฎีที่เกี่ยวข้อง     |      |
| 2.1 ระบบงานเดิม.....                     | 5    |
| 2.2 ระบบงานอื่นที่เกี่ยวข้อง .....       | 5    |
| 2.3 องค์ความรู้ที่เกี่ยวข้อง.....        | 9    |
| บทที่ 3 วิธีการดำเนินการ                 |      |
| 3.1 การศึกษาเบื้องต้น .....              | 35   |
| 3.2 การกำหนดความต้องการของระบบ.....      | 35   |
| 3.3 การออกแบบระบบ.....                   | 37   |
| 3.4 การพัฒนาระบบ .....                   | 43   |
| 3.5 การทดสอบระบบ .....                   | 45   |
| 3.6 การประเมินประสิทธิภาพของระบบ.....    | 47   |

## สารบัญ (ต่อ)

|                             |    |
|-----------------------------|----|
| บทที่ 4 ผลการศึกษา          |    |
| 4.1 ผลการศึกษา .....        | 49 |
| 4.2 ผลการทดสอบ.....         | 85 |
| 4.3 สรุปผลการทดสอบ .....    | 92 |
| บทที่ 5 สรุปผลและข้อเสนอแนะ |    |
| 5.1 สรุปผล.....             | 94 |
| 5.2 ปัญหาและข้อจำกัด .....  | 94 |
| 5.3 แนวทางการนำไปใช้.....   | 95 |
| 5.4 ข้อเสนอแนะ .....        | 95 |
| บรรณานุกรม.....             | 96 |

## สารบัญตาราง

| ตารางที่                                                                | หน้า |
|-------------------------------------------------------------------------|------|
| 1.1 ระยะเวลาดำเนินงาน .....                                             | 3    |
| 3.1 พจนานุกรมข้อมูลของตาราง .....                                       | 43   |
| 3.2 พจนานุกรมข้อมูลของฟังก์ชัน .....                                    | 43   |
| 3.3 การกำหนดค่าพารามิเตอร์สำหรับการทดลอง.....                           | 46   |
| 4.1 ผลการวิเคราะห์ความสัมพันธ์และความสอดคล้องของเครื่องมือประเมิน ..... | 91   |
| 4.2 ค่าเฉลี่ยและส่วนเบี่ยงเบนมาตรฐานของผลการประเมิน .....               | 92   |

## สารบัญภาพ

| ภาพที่                                                        | หน้า |
|---------------------------------------------------------------|------|
| 2.1 สัญลักษณ์ของ โอเพนเว็บยูไอ .....                          | 12   |
| 2.2 สัญลักษณ์ของ โอลามมา.....                                 | 13   |
| 2.3 สัญลักษณ์ของ ลามาเวอร์ชันสามจุดสอง.....                   | 14   |
| 2.4 สัญลักษณ์ของ ด็อกเกอร์.....                               | 16   |
| 2.6 สัญลักษณ์ของ เอ็นจีร็อค.....                              | 17   |
| 2.7 สัญลักษณ์ของ ไลน์เดวาล็อบเปอร์.....                       | 19   |
| 2.8 รูปแบบการทำงานของ ไลน์เมสเสจจิงเอพีไอ.....                | 20   |
| 2.9 สัญลักษณ์ของ โพสต์แมน .....                               | 22   |
| 2.10 สัญลักษณ์ของ เอ็นเอทเอ็น .....                           | 24   |
| 2.11 สัญลักษณ์ของ โฮสติงเกอร์.....                            | 25   |
| 3.1 ภาพรวมการทำงานของระบบ .....                               | 38   |
| 3.2 แผนภาพกระแสข้อมูลระดับภาพรวม .....                        | 39   |
| 3.3 แผนภาพกระแสข้อมูลระดับที่ 1 .....                         | 40   |
| 3.4 แผนภาพกระบวนการทำงานและการประเมินประสิทธิภาพของระบบ ..... | 41   |
| 4.1 หน้าล็อกอินเอ็นเอทเอ็น.....                               | 49   |
| 4.2 การสร้างเวิร์กโฟลว์.....                                  | 49   |
| 4.3 การตั้งค่าเว็บฮุก .....                                   | 50   |
| 4.4 หน้าเว็บไลน์เดวาล็อบเปอร์.....                            | 50   |
| 4.5 การสร้างโปรไวเดอร์.....                                   | 51   |
| 4.6 การสร้างชื่อโปรไวเดอร์ .....                              | 51   |
| 4.7 การสร้างเอพีไอ.....                                       | 52   |
| 4.8 เลือกเซิร์ฟเวอร์เอพีไอที่ต้องการ.....                     | 52   |
| 4.9 กรอกข้อมูลเพื่อสร้างบัญชี .....                           | 53   |
| 4.10 เมื่อสมัครเสร็จสิ้นทำการกดภายหลัง.....                   | 53   |

## สารบัญภาพ (ต่อ)

| ภาพที่                                                              | หน้า |
|---------------------------------------------------------------------|------|
| 4.11 หน้าเมนูไลน์เดวาล็อบเปอร์.....                                 | 54   |
| 4.12 หน้าตั้งค่าแมสเชสจิงเอฟไอ.....                                 | 54   |
| 4.13 คัดลอกเว็บฮุกยูอาแอลจากเอ็นเอทเอ็น.....                        | 55   |
| 4.14 เว็บฮุกยูอาแอลจากเอ็นเอทเอ็น.....                              | 55   |
| 4.15 ภาพรวมระบบการสร้างไลน์แชทบอท.....                              | 56   |
| 4.16 หน้าตั้งค่าอีดีทฟิวส์.....                                     | 56   |
| 4.17 หน้าตั้งค่าอีดีทฟิวส์.....                                     | 57   |
| 4.18 หน้าตั้งค่าเอไอเอเจ็น.....                                     | 57   |
| 4.19 พรอมที่ใช้ตั้งค่าเอไอเอเจ็น.....                               | 58   |
| 4.20 พรอมที่ใช้ตั้งค่าเอไอเอเจ็น.....                               | 58   |
| 4.21 กฎพรอมที่ใช้ตั้งค่าเอไอเอเจ็น.....                             | 59   |
| 4.22 หน้าตั้งค่าโค้ดโน้ต.....                                       | 59   |
| 4.23 หน้าตั้งค่าโค้ดโน้ต.....                                       | 60   |
| 4.24 หน้าตั้งค่าเอดีทีทีพีรีพลาเย.....                              | 60   |
| 4.25 หน้าตั้งค่าเอดีทีทีพีรีพลาเย.....                              | 61   |
| 4.26 หน้าตั้งค่าเชื่อมต่อกูเกิลจิมี่ไน.....                         | 62   |
| 4.27 หน้าตั้งค่าเชื่อมต่อกูเกิลจิมี่ไน.....                         | 62   |
| 4.28 หน้าตั้งค่าเชื่อมต่อซูปาเบส.....                               | 63   |
| 4.29 หน้าตั้งค่าซูปาเบส.....                                        | 64   |
| 4.30 หน้าตั้งค่าเชื่อมต่อเอ็มเบสดิงโมเดล.....                       | 64   |
| 4.31 ภาพรวมระบบการสร้างเร็กแชทบอท.....                              | 65   |
| 4.32 หน้าการตั้งค่าเชื่อมต่อกูเกิลไดรฟ์ระบบเร็ก.....                | 66   |
| 4.33 หน้าการตั้งค่าลูปโอเวอร์ไอเทมระบบเร็ก.....                     | 66   |
| 4.34 หน้าการตั้งค่าอีดีทฟิลส์ระบบเร็ก.....                          | 67   |
| 4.35 หน้าการตั้งค่าเชื่อมต่อดาวนโหลดไฟล์จากกูเกิลไดรฟ์ระบบเร็ก..... | 68   |

## สารบัญภาพ (ต่อ)

| ภาพที่                                                                       | หน้า |
|------------------------------------------------------------------------------|------|
| 4.36 หน้าการตั้งค่าสวิตช์ไน้ในระบบเร็ก .....                                 | 68   |
| 4.37 หน้าการตั้งค่าเอ็กซ์แท็กไฟล์สำหรับดึงข้อมูลระบบเร็ก.....                | 69   |
| 4.38 หน้าการตั้งค่าเอ็กซ์แท็กไฟล์สำหรับดึงข้อมูลระบบเร็ก.....                | 70   |
| 4.39 หน้าการตั้งค่าอีดีทไฟวส์ระบบเร็ก.....                                   | 70   |
| 4.40 หน้าการตั้งค่าเอไอเอเงินระบบเร็ก .....                                  | 71   |
| 4.41 หน้าการตั้งค่าพรมเอไอเอเงินระบบเร็ก .....                               | 71   |
| 4.42 หน้าการตั้งค่าเชื่อมต่อโมเดลจีมีไน้ในระบบเร็ก .....                     | 72   |
| 4.43 หน้าการตั้งค่าคีโอเทเมต้าดาต้าในระบบเร็ก.....                           | 72   |
| 4.44 หน้าการตั้งค่าคำสังคีโอเทเมต้าดาต้าในระบบเร็ก.....                      | 73   |
| 4.45 หน้าการตั้งค่าเชื่อมต่อโมเดลกูเกิลจีมีไน้คีโอเทเมต้าดาต้าระบบเร็ก ..... | 73   |
| 4.46 หน้าการตั้งค่าสตรัคเจอร์อาดัฟตพาร์เซอร์ระบบเร็ก .....                   | 74   |
| 4.47 หน้าการตั้งค่าสตรัคเจอร์อาดัฟตพาร์เซอร์ระบบเร็ก .....                   | 74   |
| 4.48 หน้าการตั้งค่าโค้ดไน้ระบบเร็ก .....                                     | 75   |
| 4.49 หน้าการตั้งค่าโค้ดไน้ระบบเร็ก .....                                     | 75   |
| 4.50 หน้าการตั้งค่าสลิปเ้าท์ระบบเร็ก.....                                    | 76   |
| 4.51 หน้าการตั้งค่าสลิปเ้าท์ระบบเร็ก.....                                    | 76   |
| 4.52 หน้าการตั้งค่าเชื่อมต่อโมเดลโอลามาระบบเร็ก .....                        | 77   |
| 4.53 หน้าการตั้งค่ากฎคำสังโมเดลโอลามาระบบเร็ก .....                          | 77   |
| 4.54 หน้าการตั้งค่าซัมมะไรซ์ระบบเร็ก .....                                   | 78   |
| 4.55 หน้าการตั้งค่าเชื่อมต่อซูปาเบสระบบเร็ก .....                            | 79   |
| 4.56 หน้าการตั้งค่าเชื่อมต่อโมเดลโอลามาเอ็มเบสตั้งระบบเร็ก.....              | 79   |
| 4.57 หน้าการตั้งค่าดีฟอลต์ดาต้าโหลดเดอร์ระบบเร็ก .....                       | 80   |
| 4.58 หน้าการตั้งค่าแคแร็คเตอร์เท็กซ์สปลิตเตอร์ระบบเร็ก.....                  | 81   |
| 4.59 หน้าการตั้งค่าการสร้างฐานข้อมูลซูปาเบส.....                             | 81   |
| 4.60 หน้าการตั้งค่าการสร้างฐานข้อมูลซูปาเบส.....                             | 82   |

## สารบัญภาพ (ต่อ)

| ภาพที่                                                       | หน้า |
|--------------------------------------------------------------|------|
| 4.61 หน้าการตั้งค่าการสร้างฐานข้อมูลซูปาเบส.....             | 82   |
| 4.62 หน้าการตั้งค่าการสร้างฐานข้อมูลซูปาเบส.....             | 82   |
| 4.63 หน้าการตั้งค่าเทเบิลอีดิเตอร์ซูปาเบส.....               | 83   |
| 4.64 หน้าการตั้งค่ากฎคำสั่งเทเบิลอีดิเตอร์ซูปาเบส.....       | 83   |
| 4.65 หน้าการตั้งค่าการกำหนดข้อมูลเมตาดาต้าซูปาเบส .....      | 84   |
| 4.66 หน้าการค้นคืนข้อมูลเวกเตอร์ตัวเลขซูปาเบส.....           | 84   |
| 4.67 ผลการเปรียบเทียบคะแนนการประเมินด้วย RAGAS.....          | 86   |
| 4.68 ผลการเปรียบเทียบคะแนนการประเมินด้วย DeepEval.....       | 87   |
| 4.69 ผลการเปรียบเทียบคะแนนการประเมินด้วย TruLens .....       | 88   |
| 4.70 ผลการเปรียบเทียบคะแนนการประเมินด้วย LLM-as-a-Judge..... | 89   |
| 4.71 ผลการเปรียบเทียบคะแนนเฉลี่ยของแต่ละการทดลอง .....       | 90   |

# บทที่ 1

## บทนำ

### 1.1 ความเป็นมาและความสำคัญของปัญหา

การพัฒนาไลน์แชทบอท (Chat Bot) ทำให้เกิดการพัฒนาระบบและปรับปรุงเทคโนโลยีการสร้างแชทบอทที่ตอบสนองด้วยโมเดลภาษาขนาดใหญ่ โดยเฉพาะในด้านการเข้าใจภาษา การประมวลผลคำถาม และการให้คำตอบที่ถูกต้องและมีประสิทธิภาพมากขึ้น โดยใช้ (Chat bot) เป็นตัวสอบถามเรื่องข้อมูล เกี่ยวกับกองพัฒนานักศึกษามหาวิทยาลัยราชภัฏนครปฐม

กองพัฒนานักศึกษามหาวิทยาลัยราชภัฏนครปฐม มีข้อมูลจำนวนมากที่เกี่ยวข้องกับการศึกษา การบริการนักศึกษา กิจกรรมภายในมหาวิทยาลัย รวมถึงประกาศสำคัญต่าง ๆ ที่นักศึกษาจำเป็นต้องรู้และติดตามอย่างใกล้ชิด ข้อมูลเหล่านี้มักจะถูกจัดเก็บในหลายช่องทาง เช่น เว็บไซต์ของมหาวิทยาลัย, โซเชียลมีเดีย และประกาศต่าง ๆ ภายในมหาวิทยาลัย ประกาศหรือข้อมูลที่มีการอัปเดตบ่อยครั้งอาจไม่ได้รับการเผยแพร่หรืออัปเดตทันที ทำให้นักศึกษาอาจไม่ได้รับข้อมูลสำคัญ เช่น ประกาศกิจกรรมอื่นๆ

แชทบอท (Chatbot) คือ โปรแกรมที่ถูกพัฒนาเพื่อสามารถโต้ตอบแทนมนุษย์ได้แชทบอทจะถูกตั้งโปรแกรมหรือเซตระบบขึ้นมาเพื่อจำลองการสนทนาของมนุษย์เป็นในรูปแบบข้อความสามารถโต้ตอบกับคู่สนทนาได้อย่างรวดเร็วแบบ Real-Time ซึ่งแชทบอทเป็นหนึ่งในเทคโนโลยีที่ล้ำหน้าที่สุดที่สามารถเชื่อมต่อการสื่อสารระหว่างคนและอุปกรณ์ต่าง ๆ ในมุมมองของเทคโนโลยีแชทบอททำงานโดยการรับข้อมูลการสื่อสาร จากนั้น ทำการวิเคราะห์หาจุดมุ่งหมายของเนื้อความตามที่มีการคุยข้อมูลลงไปจากนั้น แชทบอทจะทำการส่งข้อความตอบกลับไป

โมเดลภาษาขนาดใหญ่ (LLM) คือ เทคโนโลยีที่ใช้ในการประมวลผลภาษาธรรมชาติ (Natural Language Processing หรือ NLP) โดยฝึกจากข้อมูลจำนวนมาก เพื่อให้สามารถเข้าใจและสร้างข้อความในรูปแบบต่าง ๆ เช่น การตอบคำถาม การเขียนเนื้อหา หรือการแปลภาษา จากจุดเด่นของโมเดลภาษาขนาดใหญ่ โดยเฉพาะในด้านการเข้าใจภาษา การประมวลผลคำถาม และการให้คำตอบที่ถูกต้องและมีประสิทธิภาพมากขึ้น หากนำมาปรับใช้กับแชทบอท ทำให้แชทบอทสามารถสร้างคำตอบที่ถูกต้องแม่นยำได้ดียิ่งขึ้น

ดังนั้นจึงพัฒนาแชทบอท (Chat Bot) โดยใช้โมเดลภาษาขนาดใหญ่ (LLM) เพื่อเพิ่มประสิทธิภาพในการเข้าใจและประมวลผลคำถาม รวมถึงให้คำตอบได้อย่างรวดเร็วแบบ Real-Time สำหรับกองพัฒนานักศึกษา มหาวิทยาลัยราชภัฏนครปฐม ซึ่งมีข้อมูลด้านการศึกษา บริการนักศึกษา กิจกรรม และประกาศต่าง ๆ แชทบอทช่วยให้นักศึกษาสามารถเข้าถึงข้อมูลได้สะดวกและรวดเร็ว ลดความยุ่งยากในการค้นหาข้อมูลจากหลายช่องทางโมเดลภาษาขนาดใหญ่ (LLM) สามารถเข้าใจและสร้างข้อความจากข้อมูลจำนวนมาก เมื่อนำมาใช้ร่วมกับแชทบอทจึงช่วยเพิ่มประสิทธิภาพในการตอบคำถาม และลดปัญหาการเข้าถึงข้อมูลสำคัญของนักศึกษา

## 1.2 แนวคิดในการแก้ไขปัญห

จากปัญหาที่กล่าวมาข้างต้น คณะผู้จัดทำโครงการได้ทำการพัฒนาแชทบอทถามตอบด้วยโมเดลภาษาขนาดใหญ่ ฝึกฝนจากกองพัฒนานักศึกษามหาวิทยาลัยราชภัฏนครปฐม ในการถามตอบอย่างสะดวกรวดเร็วและตอบคำถามอย่างมีประสิทธิภาพ

ในการสร้างระบบคำตอบสำหรับแชทบอท ตามที่ผู้วิจัยได้ทำการสืบค้นในเบื้องต้น สามารถแบ่งได้ทั้งหมด 4 วิธีคือ

- 1.2.1 แบบตามกฎ (Rule-Based Systems)
- 1.2.2 แบบตรวจจับคีย์และคาดเดาเจตนา (Keywords and Intent recognition)
- 1.2.3 แบบโมเดลการประมวลผลภาษาธรรมชาติ (Natural Language Processing)
- 1.2.4 แบบผสม (Hybrid Approaches)

## 1.3 วัตถุประสงค์ของระบบ

1.3.1 เพื่อพัฒนาระบบแชทบอทการสอบถามของกองพัฒนานักศึกษามหาวิทยาลัยราชภัฏนครปฐม

## 1.4 ขอบเขตการศึกษา

การพัฒนาแชทบอทถามตอบด้วยโมเดลภาษาขนาดใหญ่สำหรับกองพัฒนานักศึกษามหาวิทยาลัยราชภัฏนครปฐม แบ่งได้เป็น 4 กลุ่มได้แก่ กยศ. ทุนการศึกษา งานทหาร งานนักศึกษา วิชาทหาร กองพัฒนานักศึกษากรณศึกษามหาวิทยาลัยราชภัฏนครปฐม มีรายละเอียดในการพัฒนาดังนี้

### 1.4.1 ขอบเขตของระบบ

#### 1.4.1.1 นักศึกษา

1) นักศึกษาสามารถใช้แชทบอทเพื่อสอบถามข้อมูลต่าง ๆ เช่น กยศ. ทุนการศึกษา งานทหาร งานนักศึกษาวិชาทหาร ที่เกี่ยวข้องกับกองพัฒนานักศึกษา

#### 1.4.1.2 เจ้าหน้าที่กองพัฒนานักศึกษา

1) เจ้าหน้าที่สามารถใช้ระบบเพื่อจัดการข้อมูล เช่น อัปเดตประกาศ แก้ไขข้อมูลกิจกรรม หรือเพิ่มข้อมูลใหม่ ๆ

### 1.4.2 ฮาร์ดแวร์ที่ใช้ในการพัฒนา

#### 1.4.2.1 เครื่องคอมพิวเตอร์ จำนวน 1 เครื่อง

1. หน่วยประมวลผลกลาง (Processor) : Intel i5 12400f
2. การ์ดจอ (GPU) : NVIDIA Geforec RTX 3060 ti
3. หน่วยความจำ (RAM) : 32 กิกะไบต์

### 1.4.3 ซอฟต์แวร์ที่ใช้ในการพัฒนา

#### 1.4.3.1 ระบบปฏิบัติการ Microsoft Windows 10

1.4.3.2 โอโลมา เป็นแพลตฟอร์มหรือซอฟต์แวร์ที่ออกแบบมาเพื่อช่วยในการพัฒนาหรือจัดการโมเดลปัญญาประดิษฐ์ (AI Models)

1.4.3.3 โอเพนเว็บยูไอ คือ อินเทอร์เฟซผู้ใช้ (User Interface: UI) ที่ถูกออกแบบให้เข้าถึงผ่านเว็บเบราว์เซอร์ ซึ่งสามารถใช้งานได้โดยไม่ต้องติดตั้งซอฟต์แวร์เพิ่มเติมบนเครื่องของผู้ใช้

1.4.3.4 เอ็นเอทเอ็น เครื่องมือการทำงานด้าน Automation ที่สามารถเชื่อมต่อกับแอปพลิเคชันต่าง ๆ ได้ด้วย API โดยที่ไม่ต้องใช้การเขียน Code ด้วยการใช้นวัตกรรมแบบ No code ที่ไม่ต้องเป็นผู้พัฒนาโปรแกรมหรือโปรแกรมเมอร์ ออกแบบและสร้าง Workflow ของงานตัวเองได้

1.4.3.5 ไลน์บอทดีไซน์เนอร์ เป็นเครื่องมือที่ช่วยให้นักพัฒนาหรือผู้ที่สนใจสร้างแชทบอท (Chatbot) สำหรับแพลตฟอร์ม LINE สามารถออกแบบและทดสอบการตอบสนองของบอทได้อย่างง่ายดาย โดยไม่จำเป็นต้องมีความรู้ด้านการเขียนโปรแกรมลึกซึ้งมาก่อน

1.4.3.6 ไลน์เดวล็อปเปอร์ คือ แพลตฟอร์มที่ให้บริการและเครื่องมือสำหรับนักพัฒนา (Developers) เพื่อสร้างและปรับแต่งบริการหรือแอปพลิเคชันที่ทำงานร่วมกับ LINE โดยมุ่งเน้นการพัฒนาแชทบอท (Chatbot), ฟีเจอร์เชิงโต้ตอบ (Interactive Features), และบริการอื่น ๆ ที่ผสานเข้ากับ LINE Platform

1.4.3.7 โฮสติ้งเกอร์ คือ ผู้ให้บริการเว็บโฮสติ้ง (Web Hosting) และจดทะเบียนโดเมน (Domain Registration) ระดับสากล ให้บริการเช่าพื้นที่จัดเก็บข้อมูลเว็บไซต์และระบบออนไลน์ในรูปแบบต่าง ๆ เช่น Shared Hosting, VPS Hosting, Cloud Hosting

## 1.5 ระยะเวลาดำเนินงาน

ระยะเวลาในดำเนินการพัฒนาแชทบอทตามด้วยโมเดลภาษาขนาดใหญ่ กรณีศึกษา กองพัฒนานักศึกษามหาวิทยาลัยราชภัฏนครปฐม แสดงดังตารางที่ 1.1

ตารางที่ 1.1 ระยะเวลาดำเนินงาน

| ขั้นตอนวิธีการดำเนินงาน                     | ระยะเวลาดำเนินการ (สัปดาห์) |   |   |   |   |   |   |   |   |    |    |    |    |    |    |    |
|---------------------------------------------|-----------------------------|---|---|---|---|---|---|---|---|----|----|----|----|----|----|----|
|                                             | 1                           | 2 | 3 | 4 | 5 | 6 | 7 | 8 | 9 | 10 | 11 | 12 | 13 | 14 | 15 | 16 |
| 1.ศึกษาข้อมูลและปัญหา                       | ■                           | ■ |   |   |   |   |   |   |   |    |    |    |    |    |    |    |
| 2.วิเคราะห์ข้อมูล                           |                             | ■ | ■ | ■ | ■ |   |   |   |   |    |    |    |    |    |    |    |
| 3.การตั้งค่าระบบและฝึกโมเดล LLM             |                             |   |   |   | ■ | ■ | ■ | ■ |   |    |    |    |    |    |    |    |
| 4.พัฒนาระบบไลน์แชทบอทและสร้าง API เชื่อมต่อ |                             |   |   |   |   | ■ | ■ | ■ | ■ | ■  | ■  |    |    |    |    |    |
| 5.ตรวจสอบและทดสอบระบบ                       |                             |   |   |   |   |   | ■ | ■ | ■ | ■  | ■  | ■  | ■  | ■  |    |    |
| 6.ประเมินผลและปรับปรุงระบบ                  |                             |   |   |   |   |   |   |   |   |    |    |    | ■  | ■  | ■  | ■  |

## 1.6 ประโยชน์ที่ได้คาดว่าจะได้รับ

- 1.6.1 ได้แชทบอทถามตอบด้วยโมเดลภาษาขนาดใหญ่ อย่างมีประสิทธิภาพ
- 1.6.2 สามารถติดตามข่าวสารของกองพัฒนานักศึกษามหาวิทยาลัยราชภัฏนครปฐมโดยไม่ต้องเข้าเว็บมหาวิทยาลัย
- 1.6.3 ผู้ใช้สามารถอ่านข่าวสารได้อย่างรวดเร็ว

## บทที่ 2

### หลักการและทฤษฎีที่เกี่ยวข้อง

การพัฒนาแชทบอทถามตอบด้วยโมเดลภาษาขนาดใหญ่กรณีศึกษาของพัฒนานักศึกษามหาวิทยาลัยราชภัฏนครปฐม

#### 2.1 ระบบงานเดิม

กองพัฒนานักศึกษามหาวิทยาลัยราชภัฏนครปฐม โดยใช้บุคลากรสำหรับการบริหารจัดการ และเผยแพร่ข้อมูลข่าวสารต่าง ๆ ที่เกี่ยวข้องกับกิจกรรมนักศึกษา และการบริการสนับสนุนนักศึกษา เพื่ออำนวยความสะดวกในการสื่อสารระหว่างกองพัฒนานักศึกษากับนักศึกษา คณะอาจารย์ และบุคลากรภายในมหาวิทยาลัย โดยเผยแพร่ข่าวสารทางเว็บไซต์ของมหาวิทยาลัย หรือ ติดต่อสอบถามที่ตึกกองพัฒนานักศึกษามหาวิทยาลัยราชภัฏนครปฐม

#### 2.2 ระบบงานอื่นที่เกี่ยวข้อง

พรชัย จันทรถาวร (2567) ทำการพัฒนางานวิจัยนี้เป็นการสังเคราะห์จากผลงานวิจัยเมืองแห่งการเรียนรู้ (Learning City: LC) โดยใช้ประโยชน์จาก เทคโนโลยีแบบจำลองภาษาขนาดใหญ่ (Large Language Models: LLM) ร่วมกับการวิเคราะห์ผลลัพธ์จากผู้เชี่ยวชาญ โดยมี วัตถุประสงค์เพื่อสกัดประเด็นสาระสำคัญ และสังเคราะห์รูปแบบกลไกของเมืองแห่งการเรียนรู้ที่เกิดขึ้น พร้อมเสนอแนะ รูปแบบการพัฒนาเมืองแห่งการเรียนรู้ในอนาคต ได้ใช้ข้อมูลจากงานวิจัยที่ได้รับการสนับสนุนจากทุน บพข. ในปีงบประมาณ 2564 - ปีงบประมาณ 2565 ทั้งสิ้น 36 โครงการ หรือ 29 เมือง ใช้เทคนิค Text network analysis และทำประมวลผลจาก LLM เพื่อหาความเชื่อมโยงของปัจจัย โครงสร้างขององค์ประกอบเมืองและกลไกขับเคลื่อนการพัฒนาเชื่อมโยงกับความรู้ งานวิจัยผลการสังเคราะห์ที่ได้พบว่า สามารถจำแนกรูปแบบและกลไกของโครงการ LC ได้จำนวน 6 รูปแบบ ดังนี้คือ 1) เมือง สำหรับการพัฒนาเมือง 2) เมืองเพื่อพัฒนาพื้นที่เรียนรู้และนวัตกรรม 3) เมืองเพื่อสร้างการมีส่วนร่วมพัฒนาเครือข่ายเมือง แห่งการเรียนรู้ 4) เมืองเพื่อพัฒนาบุคลากรด้านนวัตกรรมเมืองแห่งการเรียนรู้ 5) เมืองเพื่อวิจัยและพัฒนา และ 6) เมืองเพื่อ แลกเปลี่ยนแบ่งปันเรียนรู้และความร่วมมือระหว่างเมืองแห่งการเรียนรู้ งานวิจัยได้ชี้ให้เห็นว่า การใช้เครื่องมือแบบจำลอง ภาษาขนาดใหญ่ (Large Language Models: LLM) สามารถอธิบายปรากฏการณ์รูปแบบเมืองแห่งการเรียนรู้จากสถานการณ์ ต่าง ๆ ได้และมีบทสรุปข้อเสนอแนะใหม่ๆ ที่เกิดขึ้นสามารถนำไปสร้างนโยบาย

ภูมิรพี เมเยอร์ (2567) งานวิจัยนี้นำเสนอระบบห้องปฏิบัติการระยะไกล (Telepresence Laboratory) ที่ทำงานผ่าน Web Application โดยผสมผสานการควบคุมการทดลองจากระยะไกลเข้ากับ Large Language Model (LLM) เพื่อเป็นผู้ช่วยอัจฉริยะในการสอบเทียบเทอร์โมคัปเปิล ระบบนี้ช่วยให้นักศึกษาสามารถเข้าถึงการทดลองได้จากทุกที่ ลดภาระของผู้สอนในการให้คำแนะนำและตรวจสอบผลลัพธ์ อีกทั้งยังช่วยลดเวลาในการคำนวณค่าพารามิเตอร์ที่เกี่ยวข้องกับการสอบเทียบผ่าน

การประมวลผลอัตโนมัติของ LLM การประเมินผลพบว่าระบบสามารถเพิ่มประสิทธิภาพในการเรียนรู้ และทำให้ผู้ใช้เข้าใจขั้นตอนการทดลองได้ดีขึ้น อย่างไรก็ตาม ยังมีข้อจำกัดบางประการ เช่น การขาดประสบการณ์สัมผัสจริงจากการใช้งานอุปกรณ์ และความล่าช้าในการตอบสนองของ LLM ซึ่งอาจส่งผลกระทบต่อความแม่นยำของข้อมูลที่ได้รับ สรุปได้ว่าระบบนี้เหมาะสำหรับการเรียนรู้ที่มุ่งเน้นความเข้าใจในเชิงทฤษฎีและกระบวนการทดลอง แต่ยังไม่สามารถทดแทนการฝึกปฏิบัติจริงในการใช้อุปกรณ์ที่ซับซ้อนได้อย่างสมบูรณ์

ชนาธิป ชื่นมนัส (2567) ทำการวิจัยและพัฒนาระบบสนทนาอัตโนมัติในข้อมูลป้องกันประเทศ จักรกลสนทนา (Chatbot) เป็นปัญญาประดิษฐ์ (AI) ประเภทหนึ่งซึ่งอยู่ในสาขาการประมวลผลภาษาธรรมชาติ (NLP) เป็นเทคโนโลยีส่วนการเรียนรู้ของเครื่องที่ช่วยให้คอมพิวเตอร์สามารถตีความ จัดการ และทำความเข้าใจภาษามนุษย์ได้ องค์กรในปัจจุบันมีข้อมูลเสียงและข้อความจำนวนมากจากช่องทางการสื่อสารต่าง ๆ เช่น อีเมล ข้อความ ฟีดข่าวโซเชียลมีเดีย วิดีโอเสียง และอื่น ๆ โดยใช้ซอฟต์แวร์ NLP เพื่อประมวลผลข้อมูลนี้โดยอัตโนมัติ ในปัจจุบันโมเดลภาษาขนาดใหญ่ (Large Language Model: LLM) ซึ่งเป็นเทคโนโลยีที่ถูกฝึกด้วยข้อมูลขนาดใหญ่เพื่อนำไปใช้ในการสร้างข้อความคล้ายกับที่มนุษย์เขียนหรือพูดได้ สามารถสร้างข้อความที่มีความสมเหตุสมผลและเป็นธรรมชาติเหมือนที่มนุษย์สร้าง แต่เนื่องจาก LLM ถูกเทรนมาจากข้อมูลที่มีอยู่จำนวนมากการตอบคำถามที่อยู่บนพื้นฐานข้อมูลเฉพาะเจาะจงและเป็นปัจจุบันอาจไม่ถูกต้องแม่นยำ ซึ่งเรียกว่าเกิดการ “Hallucination” การเกิด Hallucination นี้เป็นความท้าทายสำคัญในการพัฒนาและปรับปรุงโมเดลภาษาขนาดใหญ่ เพราะอาจทำให้ผู้ใช้ได้รับข้อมูลที่ผิดพลาดและเกิดความเข้าใจผิด วัตถุประสงค์ในงานวิจัยนี้เพื่อทดสอบระบบจักรกลสนทนากับข้อมูลบทความในวารสารเทคโนโลยีป้องกันประเทศ ว่าสามารถให้ความรู้และตอบคำถามแก่บุคคลภายนอกเกี่ยวกับข้อมูลของเทคโนโลยีป้องกันประเทศได้แม่นยำเพียงใด โดยใช้เทคโนโลยีการดึงข้อมูลเชิงเพิ่มประสิทธิภาพ (Retrieval-Augmented Generation: RAG) ที่มีอยู่แล้วนำมาประยุกต์ใช้ เพื่อแก้ปัญหา Hallucination ใน LLM ผลการทดลองพบว่า ระบบจักรกลสนทนาที่ใช้เทคโนโลยี RAG มีประสิทธิภาพในการตอบคำถามได้อย่างถูกต้องถึง 93% ซึ่งสามารถตอบคำถามที่มีข้อมูลบทความในวารสารเทคโนโลยีป้องกันประเทศได้ถูกต้องดีมาก

มนต์ทิชา รัตนพันธ์ (2566) ทำการพัฒนา Line Chatbot สำหรับงานบริการด้านงานวิจัย ภารกิจศึกษาสถาบันวิจัยและพัฒนา มหาวิทยาลัยเทคโนโลยีราชมงคลธัญบุรี การวิจัยในครั้งนี้มีวัตถุประสงค์เพื่อพัฒนา Line Chatbot สำหรับงานบริการด้านงานวิจัย และ ประเมินความพึงพอใจของผู้ใช้งานที่มีต่อการนำ Line Chatbot สำหรับงานบริการด้านงานวิจัย ภารกิจศึกษา สถาบันวิจัยและพัฒนา มหาวิทยาลัยเทคโนโลยี ราชมงคลธัญบุรี กลุ่มตัวอย่างที่ใช้ในการวิจัยครั้งนี้คือ บุคลากรสังกัดมหาวิทยาลัยเทคโนโลยีราชมงคลธัญบุรี จำนวน 327 คน ใช้ Google Sheet เป็นเครื่องมือในการสร้างคำถาม คำตอบและใช้ Dialogflow เพื่อ เชื่อมต่อฐานข้อมูลข้อคำถาม คำตอบใน Google Sheet เข้ากับ Chatbot และติดต่อกับผู้ใช้งานผ่านทาง โปรแกรม Line ประเมินความพึงพอใจของผู้ใช้งานที่มี ต่อการนำ Line Chatbot สำหรับงานบริการด้าน งานวิจัยที่พัฒนาขึ้น สถิติที่ใช้ในการวิเคราะห์ข้อมูลคือ ค่าเฉลี่ยและส่วนเบี่ยงเบนมาตรฐาน ผลการวิจัยพบว่า ความพึงพอใจต่อภาพรวมของระบบของผู้ใช้งานที่มีต่อ Line Chatbot อยู่ในระดับมาก โดยมีค่าเฉลี่ยเท่ากับ 3.83 (SD = 0.85)

และเมื่อพิจารณารายข้อ 3 ลำดับ แรก พบว่า ความเหมาะสมในการปฏิสัมพันธ์โต้ตอบ ระหว่างผู้ใช้งาน มีค่าเฉลี่ยเท่ากับ 4.24 (SD = 0.64) รองลงมาคือ ระบบให้ผลลัพธ์ถูกต้องตรงตามความต้องการของผู้ใช้งานมีค่าเฉลี่ยเท่ากับ 4.17 (SD = 0.82) และความสอดคล้องระหว่างคำถาม คำตอบ และ คำแนะนำ มีค่าเฉลี่ยเท่ากับ 4.12 (SD = 0.73) ตามลำดับ แสดงให้เห็นว่า Chatbot ในแอปพลิเคชัน Line ที่พัฒนาขึ้นสามารถตอบข้อคำถามงานบริการ ด้านงานวิจัยและลดระยะเวลารอคอยการตอบคำถาม จากเจ้าหน้าที่ด้านงานวิจัย สถาบันวิจัยและพัฒนา มหาวิทยาลัยเทคโนโลยีราชมงคลธัญบุรี ได้อย่างมีประสิทธิภาพ

อัคริมา สุ่มมาตย์ (2567) สำนักหอสมุด มหาวิทยาลัยขอนแก่น ได้นำระบบถาม-ตอบอัตโนมัติโดยใช้เครื่องมือ Dialogflow มาใช้งานผ่านแอปพลิเคชัน LINE Chatbot โดยระบบ KCU Library Chatbot ได้มีการใช้งานตั้งแต่เดือนพฤศจิกายน 2565 เป็นต้นมา และมีการบันทึกสถิติตั้งแต่วันที่เดือนพฤศจิกายน 2565 ถึงเดือนสิงหาคม 2566 รวมทั้งสิ้น 9 เดือน โดยในช่วงเวลาดังกล่าวมีการโต้ตอบกับผู้ใช้งานรวมทั้งสิ้น 2,485 ครั้ง เฉลี่ย 276 ครั้งต่อเดือน นอกจากนี้ ยังได้ประเมินความพึงพอใจของผู้ใช้งานเพื่อปรับปรุงบริการ LINE Official ให้ตอบโจทย์ผู้ใช้งานได้ดียิ่งขึ้น โดยผลการใช้ KCU Library Chatbot ทดแทนเจ้าหน้าที่ตอบคำถามผ่านช่องทาง LINE Official พบว่าจำนวนเจ้าหน้าที่ตอบคำถามลดลงอย่างเห็นได้ชัด โดยก่อนหน้านี้มีเจ้าหน้าที่ตอบคำถาม 2 คนทำงานวันละ 8 ชั่วโมง แต่ด้วยการนำระบบ KCU Library Chatbot ที่ทำงานอัตโนมัติ 100% มาใช้ ทำให้ใช้เวลาในการตรวจสอบและติดตามข้อมูลเพียง 3 ชั่วโมงต่อเดือนเท่านั้น นอกจากนี้ เมื่อเปรียบเทียบจำนวนคำตอบที่เจ้าหน้าที่ตอบผ่านไลน์กับคำตอบจากแชทบอทในเดือนเดียวกันของ 2 ปีที่แตกต่างกัน (2565 และ 2566) พบว่าแชทบอทให้คำตอบได้มากกว่าเจ้าหน้าที่ตอบถึง 3 เท่า แสดงให้เห็นว่า AI Chatbot สามารถทดแทนเจ้าหน้าที่ตอบได้อย่างมีประสิทธิภาพ โดยช่วยตอบคำถามซ้ำๆ ต่อเนื่อง 24 ชั่วโมง ซึ่งสอดคล้องกับคะแนนความพึงพอใจโดยรวมของผู้ใช้บริการที่มีต่อบริการแชทบอทของห้องสมุด มข. ที่ 89.7%

จตุรงค์ จิตติยพล (2565) การประยุกต์ใช้ระบบปัญญาประดิษฐ์ตอบแชทอัตโนมัติเพื่อช่วยให้นักศึกษาสามารถ ทบทวน หาคำตอบ ที่เกี่ยวกับคำศัพท์ด้านเครือข่ายคอมพิวเตอร์ซึ่งมีจำนวนมาก และเป็นคำศัพท์พื้นฐานที่ จะต้องทำความเข้าใจ เพื่อให้การเรียนรู้สามารถเชื่อมโยงเข้ากับเนื้อหาในการเรียนได้โดยมีวัตถุประสงค์คือ 1) เพื่อพัฒนาแอปพลิเคชัน Chatbot สำหรับการเรียนรู้คำศัพท์เครือข่ายคอมพิวเตอร์ 2) เพื่อประเมิน ประสิทธิภาพของแอปพลิเคชัน Chatbot สำหรับการเรียนรู้คำศัพท์เครือข่ายคอมพิวเตอร์ในการวิจัยครั้งนี้ได้ พัฒนาระบบแชทอัตโนมัติโดยการใช้ Dialogflow และแอปพลิเคชันไลน์ เพื่อใช้เป็นเครื่องมือในการเรียนรู้ อย่างมีประสิทธิภาพ โดยมีการประเมินประสิทธิภาพการใช้งานโดยผู้เชี่ยวชาญ จำนวน 3 คน ผลประเมิน ประสิทธิภาพอยู่ในระดับมากที่สุด (Mean=4.89, SD=0.16) และจากการประเมินประสิทธิภาพจากผู้ใช้งานอยู่ใน ระดับมากที่สุด (Mean=4.93, SD=0.19)

นฤพธิตา สุตสวน (2567) การวิจัยนี้มีวัตถุประสงค์หลักสามประการ ได้แก่ 1) การศึกษาอัลกอริทึมการประมวลผลที่เหมาะสมสำหรับพัฒนาระบบโต้ตอบการสนทนาอัตโนมัติ (Chatbot) 2) การพัฒนาระบบ Chatbot สำหรับให้ข้อมูลข่าวสารของมหาวิทยาลัยที่ถูกต้องและเหมาะสม และ 3) การประเมินความพึงพอใจของผู้ใช้งานที่มีต่อระบบดังกล่าว กลุ่มเป้าหมายของการวิจัยประกอบด้วย

นักศึกษาระดับปริญญาตรีจากคณะวิทยาศาสตร์และเทคโนโลยี มหาวิทยาลัยเซาธ์อีสท์บางกอก จำนวน 30 คน ซึ่งถูกคัดเลือกแบบบังเอิญ และผู้เชี่ยวชาญด้านคอมพิวเตอร์ประยุกต์จำนวน 5 ท่าน ซึ่งถูกคัดเลือกแบบเฉพาะเจาะจง เครื่องมือที่ใช้ในการวิจัยประกอบด้วยแบบสอบถามความต้องการ ข้อมูลข่าวสารมหาวิทยาลัย แบบประเมินความถูกต้องและความเหมาะสมของระบบ Chatbot และแบบสอบถามความพึงพอใจของผู้ใช้งาน ทั้งนี้ ข้อมูลที่ได้ถูกวิเคราะห์โดยใช้สถิติเชิงพรรณนา ได้แก่ ความถี่ ค่าเฉลี่ย และส่วนเบี่ยงเบนมาตรฐาน

สมนา บุชบก ญัฐพร เพ็ชรพงษ์ และ จิรณัฐ สิงโตแก้ว (2567) ทำการพัฒนาแอปพลิเคชัน Chatbot สำหรับงานบริการนักศึกษา ภาควิชา กองพัฒนานักศึกษา มหาวิทยาลัยเทคโนโลยีราชมงคลสุวรรณภูมิมีวัตถุประสงค์นี้ 1) เพื่อพัฒนาแอปพลิเคชัน Chatbot สำหรับงานบริการนักศึกษา ภาควิชา กองพัฒนานักศึกษา มหาวิทยาลัยเทคโนโลยีราชมงคลสุวรรณภูมิ 2) เพื่อหาประสิทธิภาพของแอปพลิเคชัน Chatbot สำหรับงานบริการนักศึกษา ภาควิชา กองพัฒนานักศึกษา มหาวิทยาลัยเทคโนโลยีราชมงคลสุวรรณภูมิ 3) เพื่อศึกษาความพึงพอใจของพนักงานและนักศึกษาที่มีต่อแอปพลิเคชัน Chatbot สำหรับงานบริการนักศึกษา ภาควิชา กองพัฒนานักศึกษา มหาวิทยาลัยเทคโนโลยีราชมงคลสุวรรณภูมิ เครื่องมือที่ใช้ในการวิจัยในครั้งนี้คือแอปพลิเคชัน Chatbot ที่ผ่านการประเมินผลจากผู้เชี่ยวชาญด้านเทคโนโลยีสารสนเทศจำนวน 2 คน แบบประเมินรูปแบบการพัฒนาแอปพลิเคชัน Chatbot และแบบประเมินความพึงพอใจของผู้ใช้งานที่มีต่อแอปพลิเคชัน Chatbot สำหรับงานบริการนักศึกษา ภาควิชา กองพัฒนานักศึกษา มหาวิทยาลัยเทคโนโลยีราชมงคลสุวรรณภูมิสถิติที่ใช้ในการวิเคราะห์ข้อมูลคือ ค่าเฉลี่ยและส่วนเบี่ยงเบนมาตรฐาน ผลการวิจัยพบว่าแอปพลิเคชัน Chatbot สำหรับงานบริการนักศึกษา ภาควิชา กองพัฒนานักศึกษา มหาวิทยาลัยเทคโนโลยีราชมงคลสุวรรณภูมิที่พัฒนาขึ้นอยู่ในเกณฑ์ระดับประสิทธิภาพมากที่สุด โดยมีค่าเฉลี่ยรวมเท่ากับ 4.50 ส่วนเบี่ยงเบนมาตรฐาน 0.20 และความพึงพอใจของผู้ใช้แอปพลิเคชัน Chatbot สำหรับงานบริการนักศึกษา ภาควิชา กองพัฒนานักศึกษา มหาวิทยาลัยเทคโนโลยีราชมงคลสุวรรณภูมิอยู่ในเกณฑ์ระดับมาก ค่าเฉลี่ยเท่ากับ 4.46 ส่วนเบี่ยงเบนมาตรฐานเท่ากับ 0.03 แสดงว่าแอปพลิเคชัน Chatbot ที่พัฒนาขึ้นสามารถลดระยะเวลาการตอบคำถามของเจ้าหน้าที่งานพัฒนานักศึกษาและนักศึกษามหาวิทยาลัยเทคโนโลยีราชมงคลสุวรรณภูมิได้อย่างมีประสิทธิภาพ

Benjamaporn Mekara Wutthichula Khunpatwattana และ Robert P. Batzinger (2566) ได้นำเสนอความก้าวหน้าของเทคโนโลยีและข้อกังวลเกี่ยวกับผลกระทบของมันต่อการศึกษาระดับอุดมศึกษา การเกิดขึ้นพร้อมกันของ Large Language Models (LLMs) และ Generative Pre-Trained Transformer ได้นำไปสู่การพัฒนาแอปพลิเคชันเช่น ChatGPT ซึ่งได้ปฏิวัติการศึกษาระดับอุดมศึกษา โดยให้การเข้าถึงข้อมูลที่ไม่เคยมีมาก่อนและช่วยในการสร้างเอกสารและสรุปข้อมูลได้อย่างรวดเร็ว เนื่องจากผลลัพธ์ที่ได้รับมักจะเขียนในโทนที่ดูเป็นกลางและไม่มีอคติ ผู้ใช้จึงมีแนวโน้มที่จะไว้วางใจคุณภาพของมันและนำเสนอเนื้อหาไปเผยแพร่ตามตัวอักษรแม้ว่าจะมีแนวโน้มที่จะทำให้เกิดการสร้างข้อมูลที่ไม่ถูกต้องหรือข้อเรียกร้องที่ไม่มีหลักฐานสนับสนุน ในขณะเดียวกัน เทคโนโลยีนี้ก็สร้างความกังวลเกี่ยวกับการลอกเลียนแบบและโอกาสที่บุคคลอาจอ้างสิทธิ์เป็นผู้เขียนเนื้อหาที่สร้างโดย LLM เพื่อแก้ไขข้อกังวลดังกล่าว มหาวิทยาลัยต่างๆ ควรร่วมมือกันเพื่อปรับวิธีการประเมินผล

การเรียนรู้ที่ส่งเสริมการใช้ LLM อย่างรับผิดชอบ เพื่อรักษาความซื่อสัตย์ทางวิชาการและส่งเสริมการศึกษาที่ลึกซึ้งมากขึ้น

SCB 10X (2567) ได้ทำการนำเสนอ Typhoon 2 ซึ่งเป็นชุดของโมเดลขนาดใหญ่ทั้งสำหรับข้อความและมัลติมีเดียที่ได้รับการปรับแต่งสำหรับภาษาไทย ชุดโมเดลนี้ประกอบไปด้วยโมเดลสำหรับข้อความ, การมองเห็น, และเสียง Typhoon2-Text พัฒนาต่อยอดจากโมเดลเปิดที่ทันสมัย เช่น Llama 3 และ Qwen2 โดยทำการฝึกฝนต่อเนื่องด้วยข้อมูลทั้งภาษาอังกฤษและภาษาไทย เราใช้เทคนิคการฝึกหลังการเรียนรู้ (post-training) เพื่อเพิ่มประสิทธิภาพของภาษาไทยในขณะที่ยังคงความสามารถเดิมของโมเดลฐานไว้ เราปล่อยโมเดลข้อความในหลายขนาดตั้งแต่ 1 ถึง 70 พันล้านพารามิเตอร์ พร้อมทั้งรุ่นพื้นฐานและรุ่นที่ปรับแต่งการสั่งงาน (instruction-tuned) สำหรับการควบคุมการสร้างข้อความ เราปล่อย Typhoon2-Safety ซึ่งเป็นตัวจำแนกประเภทที่ได้รับการเสริมเพื่อรองรับวัฒนธรรมและภาษาของไทย Typhoon2-Vision ช่วยปรับปรุงความเข้าใจเอกสารภาษาไทยในขณะที่ยังคงความสามารถทั่วไปในการมองเห็น เช่น การอธิบายภาพ Typhoon2-Audio แนะนำสถาปัตยกรรมโมเดลสตรีมเสียงแบบครบวงจรที่สามารถประมวลผลข้อมูลเสียง, การพูด, และข้อความ รวมถึงการสร้างทั้งข้อความและการพูดเป็นผลลัพธ์

## 2.3 องค์ความรู้ที่เกี่ยวข้อง

### 2.3.1 แชทบอท (Chatbot)

Chatbot คือ โปรแกรมที่สามารถตอบกลับคำถามหรือโต้ตอบกับผู้ใช้โดยอัตโนมัติ ผ่านช่องทางแชทของแอปพลิเคชันต่างๆ เช่น Facebook Messenger, LINE, หรือแอปพลิเคชันอื่นๆ ที่รองรับการสนทนาอัตโนมัติ โดย Chatbot ถูกออกแบบมาเพื่อให้สามารถจำลองบทสนทนา กับผู้ใช้ได้ อย่างใกล้เคียงกับการพูดคุยกับมนุษย์จริงๆ ซึ่งมันสามารถทำงานได้ด้วยการใช้เทคโนโลยีที่ช่วยในการทำความเข้าใจและตอบสนองตามคำถามหรือคำสั่งจากผู้ใช้ โดยการใช้โปรแกรมนี้สามารถเพิ่ม ประสิทธิภาพการให้บริการและลดภาระงานของมนุษย์ในการตอบคำถามหรือจัดการกับงานที่ซ้ำซากได้ การทำงานของ Chatbot ขึ้นอยู่กับประเภทของมัน ซึ่งมีหลายประเภท เช่น แชทบอทที่ทำงานตามกฎ (Rule-Based Chatbot), แชทบอทที่ใช้การเรียนรู้ของเครื่อง (Machine Learning-Based Chatbot) และแชทบอทที่ผสมผสานระหว่างทั้งสองประเภท (Hybrid Chatbot) แต่ละประเภทจะมีการใช้งาน และข้อจำกัดที่แตกต่างกัน ซึ่งทำให้ Chatbot สามารถตอบสนองต่อคำถาม ในลักษณะที่หลากหลายได้ แชทบอทที่ทำงานตามกฎ (Rule-Based Chatbot) จะทำงานตามกฎหรือคำสั่งที่ได้ตั้งไว้ล่วงหน้า ซึ่งเหมาะสำหรับการตอบคำถามที่มีโครงสร้างชัดเจนและสามารถคาดการณ์ได้ เช่น คำถามที่พบบ่อยหรือ การทำงานที่ต้องการความแม่นยำสูง ระบบนี้จะทำงานได้ดีในกรณีที่คำถามมีการจัดโครงสร้างไว้อย่าง ชัดเจนแต่ไม่สามารถรับมือกับคำถามที่ไม่อยู่ในกรอบที่กำหนดไว้ หรือคำถามที่ซับซ้อนเกินไป แชทบอทที่ใช้การเรียนรู้ของเครื่อง (Machine Learning-Based Chatbot) เป็นเทคโนโลยีที่ใช้การ เรียนรู้จากข้อมูลจำนวนมากและการประมวลผลภาษาธรรมชาติ (NLP) ซึ่งทำให้แชทบอทประเภทนี้ สามารถตอบสนองต่อคำถามที่ซับซ้อนได้ และสามารถเรียนรู้จากคำถามใหม่ ๆ ที่ไม่เคยมีข้อมูลมาก่อน โดยสามารถปรับตัวเองให้ดียิ่งขึ้นจากข้อมูลใหม่ ๆ ที่ได้รับ การ

ใช้งานในลักษณะนี้เหมาะกับระบบที่ต้องการให้แชทบอทสามารถตอบคำถามที่ไม่แน่นอนหรือไม่เคยเกิดขึ้นมาก่อนได้ แต่มันก็มีข้อจำกัด ตรงที่อาจจะให้คำตอบที่ไม่แม่นยำหากข้อมูลที่ใช้ในการฝึกฝนไม่เพียงพอ แชทบอทที่ผสมผสานระหว่างการทำงานตามกฎและการใช้ AI (Hybrid Chatbot) เป็นการรวมข้อดีของ ทั้งสองประเภทนี้ โดยจะใช้ระบบที่ทำงานตามกฎสำหรับคำถามที่มีรูปแบบชัดเจน เช่น การถามข้อมูลที่มีโครงสร้างตายตัวหรือคำถามที่พบบ่อย และใช้ระบบที่ใช้การเรียนรู้ของเครื่องในกรณีที่คำถามนั้นมีความซับซ้อนหรือไม่เคยเกิดขึ้นมาก่อน การใช้ Hybrid Chatbot สามารถเพิ่มประสิทธิภาพในการตอบคำถามในหลากหลายรูปแบบ ทั้งคำถามที่ต้องการความแม่นยำและคำถามที่มีความยืดหยุ่นในการตอบ นอกจากนี้ Hybrid Chatbot ยังมีการทำงานสำรอง (Fallback Mechanism) ซึ่งช่วยให้ระบบสามารถ หันกลับไปใช้กฎที่ตั้งไว้ล่วงหน้าในกรณีที่ AI ไม่สามารถตอบคำถามได้ การพัฒนาและใช้งาน Chatbot โดยเฉพาะในรูปแบบของ Hybrid Chatbot เป็นวิธีที่ช่วยให้สามารถตอบคำถามหรือแก้ปัญหาของผู้ ใช้ได้อย่างรวดเร็วและมีประสิทธิภาพ ซึ่งการใช้ Hybrid Chatbot ทำให้มีความยืดหยุ่นสูง สามารถตอบ คำถามที่มีรูปแบบแน่นอนได้ พร้อมทั้งปรับตัวในการรับมือกับคำถามใหม่ ๆ หรือสถานการณ์ที่ไม่คาดคิด ได้ ทั้งนี้ทำให้การให้บริการหรือการโต้ตอบกับ ผู้ใช้เป็นไปอย่างรวดเร็วและมีประสิทธิภาพมากขึ้น

### 2.3.2 โมเดลภาษาขนาดใหญ่ (Large Language Models)

Large Language Models (LLM) หรือ โมเดลภาษาขนาดใหญ่ คือโมเดลที่ถูกพัฒนาขึ้นเพื่อ ประมวลผลข้อมูลทางภาษาของมนุษย์และสามารถสร้างข้อมูลใหม่ ๆ ที่คล้ายคลึงกับการสื่อสารของ มนุษย์เอง โมเดลเหล่านี้เป็นพื้นฐานของ Generative AI ซึ่งสามารถสร้างข้อมูลหรือ คำพูดใหม่ๆ ตาม ความเข้าใจที่ได้จากการเรียนรู้จากข้อมูลที่มีอยู่ โดยใช้กระบวนการที่เรียกว่า Deep Learning ซึ่งจำลอง วิธีการเรียนรู้ของสมองมนุษย์ LLM ได้รับการพัฒนาผ่านการเทรนกับข้อมูล จำนวนมหาศาล ซึ่งทำให้มัน สามารถเข้าใจภาษามนุษย์ได้ดี โดยที่ไม่ต้องมีการเรียงข้อมูลหรือ คำสั่งจากมนุษย์มากนัก โมเดลนี้สามารถ "คาดเดา" คำถัดไปหรือสร้างข้อความที่เหมาะสมในบริบท ต่างๆ ซึ่งช่วยให้ LLM สามารถตอบคำถาม แปลภาษา หรือเข้าใจคำศัพท์และบริบทได้เหมือนมนุษย์ จริงๆการทำงานของ LLM อยู่บน พื้นฐานของการเรียนรู้แบบ Deep Learning โดยจะรับข้อมูลจาก ชุดข้อมูลที่ได้รับการเทรนมา และเมื่อ ข้อมูลใหม่เข้ามา โมเดลจะทำการประมวลผลและปรับตัวผ่านการฝึกฝนหรือการ "Fine-tuning" เพื่อ เพิ่มความแม่นยำในการตอบสนองต่อคำถามหรือคำขอจาก ผู้ใช้ LLM มีหลากหลายรูปแบบที่ได้รับความนิยม เช่น ChatGPT, Bard, Gemini ซึ่งได้ถูกนำมาใช้ใน หลากหลายวงการและธุรกิจ เช่น การพัฒนา Chatbot หรือ Customer Service ที่ช่วยให้การโต้ตอบกับลูกค้าเป็นไปอย่างรวดเร็วและมีประสิทธิภาพ ช่วยตอบคำถามเบื้องต้นหรือแก้ปัญหาที่ลูกค้า สามารถทำได้เอง ซึ่งทำให้โมเดลสามารถตอบคำถามหรือให้คำแนะนำตาม คำสั่งที่ได้รับในลักษณะที่เป็นธรรมชาติ โมเดลประเภทนี้สามารถรับคำสั่งจากมนุษย์ เช่น การถาม คำถามหรือการให้คำสั่งในรูปแบบต่างๆ ที่สามารถปรับเปลี่ยนผลลัพธ์ตามบริบทของคำถามหรือ Prompt ที่ใส่เข้าไป สิ่งที่ทำให้ LLM มีความพิเศษและมีประโยชน์คือ ความสามารถในการปรับแต่ง คำตอบตามคำสั่งที่ใส่เข้าไป เช่น หากต้องการคำตอบที่เป็นทางการ, สนุกสนาน, หรือสุภาพ ก็สามารถ กำหนดบริบทเหล่านั้นได้โดยการปรับ Prompt ที่ใส่เข้าไป เพื่อให้โมเดลสามารถตอบกลับมาในรูปแบบ ที่ตรงกับความต้องการของผู้ใช้ โดยรวมแล้ว LLM เป็นเครื่องมือที่มีความสามารถหลากหลายทั้งในด้าน การเข้าใจและการสร้าง

ภาษามนุษย์ ซึ่งได้ช่วยในการพัฒนาแอปพลิเคชันต่าง ๆ เช่น การพัฒนา Chatbot หรือการใช้งานในบริบททางธุรกิจเพื่อเพิ่มประสิทธิภาพในการสื่อสารและการให้บริการ

### 2.3.3 โอเพนเว็บยูไอ (Open WebUI)


Open WebUI เป็นแพลตฟอร์มที่ช่วยให้ผู้ใช้สามารถสื่อสารและจัดการโมเดลปัญญาประดิษฐ์ (Artificial Intelligence: AI) ผ่านเว็บเบราว์เซอร์ โดยไม่ต้องใช้คำสั่งเซลล์หรือ API ที่ซับซ้อน รองรับการ ทำงานร่วมกับโมเดล AI หลากหลายประเภท เช่น ChatGPT, LLaMA, Stable Diffusion และ Whisper โดยเฉพาะในด้านการประมวลผลภาษาธรรมชาติ (Natural Language Processing: NLP), การสร้าง ภาพจากข้อความ (Text-to-Image) และการแปลงเสียงเป็นข้อความ (Speech-to-Text) ความสำคัญ ของ Open WebUI ใช้งานง่ายผ่านเว็บเบราว์เซอร์ผู้ใช้สามารถเข้าถึงโมเดล AI ได้ทันทีผ่านเว็บ เบรว์เซอร์ โดยไม่ต้องติดตั้งซอฟต์แวร์เพิ่มเติมรองรับการใช้งานบนอุปกรณ์หลากหลาย เช่น คอมพิวเตอร์ แท็บเล็ต และสมาร์ตโฟนอินเทอร์เน็ตเพชที่เป็นมิตรต่อผู้ใช้ช่วยลดความซับซ้อนในการใช้งาน AI รองรับการ ทำงานแบบโอเพนซอร์สนักพัฒนาและองค์กรสามารถปรับแต่ง Open WebUI ได้ตาม ความต้องการไม่มีค่าใช้จ่ายในการใช้งานพื้นฐาน ทำให้เข้าถึงได้ง่ายสามารถติดตั้งและรันบนเซิร์ฟเวอร์ ส่วนตัวเพื่อเพิ่มความปลอดภัยของข้อมูลเชื่อมต่อกับโมเดล AI ได้หลายประเภทรองรับโมเดล NLP เช่น GPT, LLaMA, Mistral สำหรับงานประมวลผลภาษา ใช้งานกับโมเดลสร้างภาพ เช่น Stable Diffusion, Midjourney (ผ่าน API), DALL-E ทำงานร่วมกับโมเดลเสียง เช่น Whisper สำหรับการแปลงเสียงเป็น ข้อความช่วยให้ AI เข้าถึงได้ง่ายขึ้น ลดความยุ่งยากในการเรียกใช้งานโมเดล AI ผ่านคำสั่งหรือโค้ด ออกแบบให้ใช้งานได้ทั้งผู้ใช้ทั่วไป นักพัฒนา และองค์กรธุรกิจสนับสนุนการทำงานร่วมกันในทีม ด้วย อินเทอร์เน็ตที่เข้าใจง่ายและปรับแต่งได้ตามความต้องการปลอดภัยและควบคุมข้อมูลได้ผู้ใช้สามารถ ติดตั้ง Open WebUI บนเซิร์ฟเวอร์ส่วนตัว (Self-hosting) เพื่อควบคุมข้อมูลทั้งหมดได้ด้วยตนเองลด ความเสี่ยงเรื่องความเป็นส่วนตัวและความปลอดภัยของข้อมูลช่วยให้ผู้ใช้มีอำนาจเต็มในการจัดการและ ควบคุมข้อมูลที่ถูกส่งไปยังโมเดล A



ภาพที่ 2.1 สัญลักษณ์ของ โอเพนเว็บยูไอ  
ที่มา: <https://docs.openwebui.com/brand/>

### 2.3.4 โอลาม่า (Ollama)


คือเครื่องมือที่ถูกออกแบบมาเพื่อช่วยให้ผู้ใช้สามารถสร้างและจัดการโมเดลภาษา (Language Models — LLMs) ได้อย่างสะดวกสบายบนคอมพิวเตอร์ส่วนตัว โดยไม่จำเป็นต้องพึ่งพา เซิร์ฟเวอร์ภายนอกหรือบริการคลาวด์ ช่วยลดความซับซ้อนในการใช้งาน และเปิดโอกาสให้ผู้ใช้สามารถ ควบคุมกระบวนการสร้างและใช้งานโมเดลได้อย่างเต็มที่ จุดเด่นของ Ollama หนึ่งในจุดเด่นที่สำคัญของ Ollama คือความสามารถในการสร้างโมเดลเฉพาะทาง ตามความต้องการ ผ่านกระบวนการฝึก (Training) และการปรับแต่งโมเดล (Fine-Tuning) ด้วยชุด ข้อมูลที่เหมาะสมกับบริบทที่ผู้ใช้งานต้องการ เช่น การวิเคราะห์ความคิดเห็นของผู้ใช้ การตรวจจับ ความรู้สึกจากข้อความ หรือการสร้างเนื้อหาใหม่ ๆ แบบอัตโนมัติ Ollama รองรับการทำงานแบบ ออฟไลน์อย่างสมบูรณ์ การประมวลผลทั้งหมดเกิดขึ้นภายในเครื่องของผู้ใช้เอง ซึ่งช่วยเพิ่มความ ปลอดภัยของข้อมูล และลดความเสี่ยงจากการรั่วไหล เนื่องจากข้อมูลทั้งหมดจะไม่ถูกส่งออกไปยัง เซิร์ฟเวอร์ภายนอก สิ่งนี้ทำให้ Ollama เป็นเครื่องมือที่เหมาะสมสำหรับองค์กรหรือบุคคลที่ให้ความสำคัญ กับความเป็นส่วนตัวและความปลอดภัยของข้อมูล อีกหนึ่งข้อได้เปรียบของ Ollama คือความสามารถ ในการทำงานได้โดยไม่ต้องเชื่อมต่อกับอินเทอร์เน็ต ทำให้ผู้ใช้สามารถใช้งานโมเดลได้ทุกที่ทุกเวลา แม้ใน สภาพแวดล้อมที่ไม่มีสัญญาณอินเทอร์เน็ต หรือในสถานที่ที่การเชื่อมต่อกับเซิร์ฟเวอร์ภายนอกอาจมี ข้อจำกัด กระบวนการทำงานของ Ollama เบื้องหลังการทำงานของ Ollama คือการนำเทคโนโลยี Deep Learning มาใช้ในการประมวลผลข้อมูลภาษา ผ่านการสร้างโครงข่ายประสาทเทียมที่มีโครงสร้าง ซับซ้อน เพื่อเลียนแบบการทำงานของสมองมนุษย์ กระบวนการเรียนรู้ของโมเดลผ่านขั้นตอนดังนี้: Training (การฝึกโมเดล): Ollama จะเรียนรู้จากข้อมูลจำนวนมาก (Big Data) เพื่อเข้าใจบริบทของ ภาษา และสามารถคาดเดาคำถัดไปได้อย่างแม่นยำ Fine-Tuning (การปรับแต่งโมเดล): ขั้นตอนนี้ผู้ใช้ สามารถเพิ่มข้อมูลเฉพาะทาง เพื่อให้โมเดล ตอบสนองตามความต้องการได้ดียิ่งขึ้น Inference (การใช้งานโมเดล): เมื่อโมเดลได้รับการฝึกแล้ว ผู้ใช้สามารถเรียกใช้งานโมเดลผ่านคำสั่ง CLI หรือ สร้างอินเทอร์เฟซผู้ใช้สำหรับใช้งาน Ollama ได้ข้อดีของ Ollama ความปลอดภัยของข้อมูล: ผู้ใช้สามารถเก็บข้อมูลทั้งหมดไว้ในเครื่องของตนเองโดยไม่ต้องส่งข้อมูลออกไปยังเซิร์ฟเวอร์ภายนอก ลด ต้นทุน: ไม่ต้องเสียค่าใช้จ่ายในการเช่าเซิร์ฟเวอร์คลาวด์ และไม่ต้องใช้บริการ Subscription รายเดือน ควบคุมได้อย่างเต็มที่: ผู้ใช้สามารถควบคุมการฝึกและใช้งานโมเดลได้ด้วยตนเองทุกขั้นตอน รองรับการใช้งานแบบออฟไลน์: ทำงานได้แม้ไม่มีอินเทอร์เน็ต เหมาะสำหรับงานที่ต้องการ ความเสถียร ของระบบ Ollama เป็นเครื่องมือที่ตอบโจทย์สำหรับผู้ที่ต้องการสร้างและจัดการโมเดลภาษา ได้อย่าง อิสระบนคอมพิวเตอร์ส่วนตัว โดยเน้นความปลอดภัยของข้อมูล ความสะดวกในการใช้งาน และลด ต้นทุนจากการใช้บริการคลาวด์ ด้วยความสามารถในการฝึกและปรับแต่งโมเดลตาม ความต้องการ Ollama จึงเหมาะสำหรับนักพัฒนา นักวิจัย และองค์กรที่ต้องการโซลูชัน AI เฉพาะทางที่ ปลอดภัยและมีประสิทธิภาพ



ภาพที่ 2.2 สัญลักษณ์ของ โอลาม่า  
ที่มา: <https://kodora.ai/ai-tool/ollama/>

### 2.3.5 ลามาเวอร์ชันสามจุดสอง (Llama 3.2)


Llama 3.2 เป็นการพัฒนาเวอร์ชันล่าสุดของโมเดล LLaMA โดย Meta ที่มุ่งเน้นไปที่การเสริมความสามารถในการประมวลผลข้อมูลทั้งภาพและข้อความ โมเดลนี้มีการปรับปรุงเพื่อเพิ่มประสิทธิภาพในการให้คำตอบที่แม่นยำและเกี่ยวข้องมากขึ้น รวมถึงการขยายขอบเขตการใช้งานในหลากหลายสาขา โดยเฉพาะในด้านการศึกษาการแพทย์ การตลาด และการบริการลูกค้า LLaMA 3.2 สามารถรับข้อมูลจากทั้งภาพและข้อความ ซึ่งช่วยให้มันสามารถเข้าใจและตอบสนองต่อ คำถามที่เกี่ยวข้องกับภาพได้ เช่น การถามคำถามเกี่ยวกับสิ่งที่อยู่ในภาพหรือการสร้างคำบรรยาย สำหรับภาพ โดยสามารถระบุสิ่งที่มีอยู่ในภาพได้อย่างชัดเจน รวมถึงการให้คำอธิบายเกี่ยวกับบริบทของ ภาพนั้นๆ นอกจากนี้โมเดลนี้ยังได้รับการปรับปรุงให้สามารถเข้าใจบริบทได้ดีขึ้น ซึ่งทำให้สามารถให้ คำตอบที่มีคุณภาพสูงและเหมาะสมกับคำถามในหลากหลายสถานการณ์ได้ในแง่ของการใช้งาน LLaMA 3.2 สามารถนำไปใช้ในหลายสาขา ไม่ว่าจะเป็นการศึกษา การแพทย์ การตลาด หรือการบริการ ลูกค้า ซึ่ง จะช่วยให้สามารถให้ข้อมูลที่ถูกต้องและเป็นประโยชน์ได้อย่างรวดเร็วและแม่นยำ ตัวอย่างการ ใช้งาน ของ LLaMA 3.2 ได้แก่ การถามคำถามเกี่ยวกับภาพ (Visual Question Answering หรือ VQA) เช่น "ในภาพนี้มีอะไรบ้าง?" หรือการสร้างคำบรรยายให้กับภาพที่แสดงให้เห็นถึงสิ่งที่เกิดขึ้นในภาพนั้น ๆ LLaMA 3.2 ได้รับการพัฒนาให้สามารถประมวลผลข้อมูลที่ซับซ้อนทั้งในรูปแบบข้อความและภาพ ทำให้โมเดลนี้เป็นเครื่องมือที่มีความสามารถสูงในการทำงานหลากหลายประเภท ซึ่งจะส่งผลต่อการเปลี่ยนแปลงวิธีที่เราติดต่อสื่อสารและใช้เทคโนโลยี AI ในชีวิตประจำวัน โดยในอนาคตเราคาดว่า AI อย่าง LLaMA 3.2 จะกลายเป็นเครื่องมือที่สำคัญในทุกภาคส่วนของชีวิตมนุษย์ ไม่ว่าจะเป็นในงาน การศึกษา การวิจัย การพัฒนาแอปพลิเคชัน หรือการบริการลูกค้า



ภาพที่ 2.3 สัญลักษณ์ของ ลามาเวอร์ชันสามจุดสอง  
ที่มา: <https://www.unsloth.ai/blog/llama3-2>

### 2.3.6 ดี็อกเกอร์ (Docker)

Docker คือแพลตฟอร์มสำหรับการพัฒนา จัดส่ง และรันแอปพลิเคชันด้วย Containerization Docker คือแพลตฟอร์มที่ช่วยให้ผู้พัฒนาแอปพลิเคชันสามารถสร้างบรรจุ (Package) จัดส่ง (Deploy) และรันแอปพลิเคชันได้อย่างยืดหยุ่นผ่านแนวคิดที่เรียกว่า Containerization ซึ่งเป็นการแยกแอปพลิเคชันและสิ่งแวดล้อมที่มันต้องการออกจากระบบปฏิบัติการหลัก ทำให้แอปพลิเคชันสามารถทำงานได้ อย่างอิสระและเสถียรบนทุกสภาพแวดล้อม ไม่ว่าจะเป็นเครื่องคอมพิวเตอร์ของนักพัฒนา เซิร์ฟเวอร์หรือระบบคลาวด์ก็ตาม Containerization คือการนำแอปพลิเคชันและทุกองค์ประกอบที่จำเป็น เช่น ไลบรารี เครื่องมือสนับสนุน และการตั้งค่าต่าง ๆ บรรจุไว้ในหน่วยที่เรียกว่า Container ทำให้แอปพลิเคชันสามารถทำงานได้อย่างอิสระจากระบบปฏิบัติการและฮาร์ดแวร์ที่ใช้งานอยู่ ต่างจากการใช้ Virtual Machine (VM) ที่ต้องสร้างระบบปฏิบัติการแยกออกมาในแต่ละ VM การใช้ Container จะใช้ ทรัพยากรของระบบปฏิบัติการหลักร่วมกันได้ ทำให้เบากว่า ใช้ทรัพยากรน้อยกว่า และรวดเร็วกว่ามาก องค์ประกอบสำคัญของ Docker Engine เป็นหัวใจสำคัญของ Docker ที่ทำหน้าที่รัน Container และ จัดการทุกอย่างที่เกี่ยวข้องกับ Container บนเครื่องของคุณ Docker Image เป็นแม่แบบ (Template) สำหรับสร้าง Container ซึ่งจะบรรจุแอปพลิเคชันและทุกอย่างที่จำเป็นในการรันแอปพลิเคชัน Docker Container เป็นหน่วยปฏิบัติการที่รันแอปพลิเคชันจริง ๆ โดยสร้างขึ้นจาก Docker Image แต่ ละ Container จะมีสภาพแวดล้อมเป็นของตัวเอง และสามารถทำงานแยกจาก Container อื่นได้ Docker Hub เป็นที่เก็บ Docker Image ออนไลน์ที่ใช้ร่วมกันได้ทั่วโลก นักพัฒนาสามารถดาวน์โหลด Image จาก Docker Hub มาใช้ได้ทันที หรืออัปโหลด Image ที่สร้างเองไปแบ่งปันให้ผู้อื่นใช้งานก็ได้ Docker Compose ใช้สำหรับการจัดการหลาย Container พร้อมกัน โดยการเขียนไฟล์ docker-compose.yml เพื่อกำหนดโครงสร้างทั้งหมดในระบบ เช่น การเชื่อมโยงระหว่าง Container ฐานข้อมูล และแอปพลิเคชัน ประโยชน์ของ Docker ทำงานได้ทุกที่ Docker ช่วยให้แอปพลิเคชัน ทำงานได้เหมือนกันทุกสภาพแวดล้อม ไม่ว่าจะเป็นรันบนเครื่องพัฒนา เซิร์ฟเวอร์ หรือคลาวด์ก็ตาม ประหยัดทรัพยากร Container ใช้ทรัพยากรร่วมกับระบบปฏิบัติการหลัก ทำให้กินแรมน้อยกว่าและใช้ พื้นที่เก็บข้อมูลน้อยกว่า VM สะดวกในการพัฒนา นักพัฒนาสามารถสร้าง Container ที่มีทุกอย่างพร้อม ใช้งาน แล้วแชร์ให้ทีมงานทุกคนใช้งาน Container เดียวกันได้ ทำให้ลดปัญหา "รันได้บนเครื่องฉันแต่ไม่ รันบนเครื่องเธอ" ได้อย่างดี Deployment ที่รวดเร็วการจัดส่งแอปพลิเคชัน (Deployment) ทำได้ง่าย และรวดเร็วกว่า เพราะ Container บรรจุทุกอย่างที่แอปพลิเคชันต้องการมาแล้ว สามารถย้ายไปใช้งาน ได้ทันทีความปลอดภัยแต่ละ Container ทำงานแยกจากกัน ให้ความปลอดภัยสูงขึ้น และหากมีการ โจมตีหรือปัญหาเกิดขึ้นใน Container หนึ่ง จะไม่ส่งผลกระทบต่อ Container อื่น ๆ Docker คือ เครื่องมือที่ช่วยให้การพัฒนาและการส่งมอบแอปพลิเคชันเป็นเรื่องง่ายขึ้นผ่านแนวคิด Containerization โดยไม่ต้องกังวลเกี่ยวกับความแตกต่างของระบบปฏิบัติการหรือการตั้งค่าต่าง ๆ การใช้ Docker ทำให้แอปพลิเคชันทำงานได้อย่างเสถียรบนทุกแพลตฟอร์ม ประหยัดทรัพยากร และ รองรับการ Deployment ได้อย่างรวดเร็ว ไม่ว่าจะเป็นนักพัฒนารายบุคคล ทีมพัฒนาซอฟต์แวร์ หรือ องค์กรขนาดใหญ่ Docker เป็นเครื่องมือที่ช่วยเพิ่มประสิทธิภาพในการพัฒนาและการจัดการแอปพลิเคชันอย่างมหาศาล จัดแบบให้ดีขึ้นหน่อยๆ



ภาพที่ 2.4 สัญลักษณ์ของ ด็อกเกอร์

ที่มา: <https://engineering.thinknet.co.th/docker101-ch1-400ab21f0e7c>

### 2.3.7 เอ็นจีร็อก (Ngrok)

Ngrok คือเครื่องมือสำหรับการสร้าง Tunnel เชื่อมต่อจากเครื่องคอมพิวเตอร์ภายในสู่ ภายนอก Ngrok คือเครื่องมือที่ช่วยให้ผู้ใช้สามารถสร้างช่องทางเชื่อมต่อจากเครื่องคอมพิวเตอร์ภายใน (local machine) ไปยังอินเทอร์เน็ตได้อย่างง่ายดาย โดยมันทำให้บริการที่รันอยู่บนเครื่องของผู้ใช้ สามารถเข้าถึงได้จากภายนอก แม้ว่าจะอยู่หลังไฟร์วอลล์หรือในเครือข่ายส่วนตัวที่ไม่สามารถเข้าถึงได้ จากอินเทอร์เน็ตโดยตรง โดยทั่วไปแล้วการเปิดให้บริการจากเครื่องภายในไปยังภายนอกนั้นต้องใช้การตั้งค่าพอร์ตบนเราเตอร์หรือการเปิดไฟร์วอลล์ ซึ่งมักจะมีความซับซ้อนและไม่สะดวก แต่ Ngrok แก้ปัญหานี้ได้อย่างยอดเยี่ยม โดยการทำให้เครื่องของคุณสามารถสร้าง tunnel ที่สามารถเข้าถึงได้จาก อินเทอร์เน็ตภายนอกโดยตรงและปลอดภัย วิธีการทำงานของ Ngrok เมื่อคุณรัน Ngrok บนเครื่องของคุณ มันจะสร้าง URL ที่เป็น public address ชั่วคราวที่สามารถเข้าถึงได้จากภายนอก URL นี้จะ นำไปสู่เครื่องคอมพิวเตอร์ของคุณที่กำลังรันบริการอยู่ เช่น เว็บแอปพลิเคชัน หรือ API ที่คุณกำลัง พัฒนา โดย Ngrok จะสร้าง tunnel เชื่อมต่อจากเครื่องไปยัง server ของ Ngrok บนคลาวด์ และจะทำหน้าที่เป็นตัวกลางในการส่งข้อมูลระหว่างผู้ใช้ภายนอกและแอปพลิเคชันที่รันอยู่บนเครื่อง ของคุณการทำงานของ Ngrok ใช้การส่งข้อมูลผ่านทางช่องทางนี้อย่างปลอดภัย โดยไม่จำเป็นต้อง ปรับแต่งระบบเครือข่ายหรือเปิดพอร์ตบนเราเตอร์ สิ่งที่ต้องทำคือติดตั้ง Ngrok และรันคำสั่งจาก เครื่องของคุณเพื่อเปิดใช้งาน tunnel และรับ URL ที่ผู้ใช้ภายนอกสามารถเข้าถึงได้จากอินเทอร์เน็ต ประโยชน์หลักของ Ngrok หนึ่งในประโยชน์ที่สำคัญที่สุดของ Ngrok คือการช่วยให้ผู้ใช้สามารถแชร์ และ เข้าถึงแอปพลิเคชันที่กำลังพัฒนาได้จากที่ไหนก็ได้โดยไม่ต้องตั้งค่าอะไรเพิ่มเติมในระบบเครือข่ายซึ่งเหมาะสำหรับการพัฒนาและทดสอบแอปพลิเคชันในช่วงเริ่มต้น โดยไม่ต้องตั้งค่าอะไรซับซ้อน ทำให้ประหยัดเวลาและลดความยุ่งยากในการเชื่อมต่อกับเครือข่าย Ngrok รองรับหลายโปรโตคอลเช่น HTTP, HTTPS, TCP, และ WebSocket ซึ่งช่วยให้มันสามารถใช้งานได้หลากหลายประเภทของบริการ ไม่ว่าจะเป็นการทดสอบเว็บแอปพลิเคชัน , API, หรือแอปพลิเคชันที่ใช้ WebSocket ซึ่งมีประโยชน์มาก ในการทดสอบแอปพลิเคชันในสภาพแวดล้อมที่มีการเชื่อมต่อจากภายนอก การใช้งาน Ngrok การใช้งาน Ngrok นั้นง่ายมาก ผู้ใช้เพียงแค่ดาวน์โหลดโปรแกรมจาก

เว็บไซต์ของ Ngrok และรันคำสั่งในเครื่อง คอมพิวเตอร์ของตัวเองเพื่อสร้าง tunnel ที่สามารถเข้าถึงจากภายนอกได้ทันที นอกจากนี้ Ngrok ยังรองรับการตั้งค่าขั้นสูง เช่น การกำหนดพอร์ตที่ต้องการเชื่อมต่อ และสามารถใช้หลาย tunnel ในเวลาเดียวกันได้ Ngrok จะสร้าง URL ที่ผู้ใช้สามารถนำไปแชร์ให้กับคนอื่นเพื่อทดสอบหรือดูแอปพลิเคชันที่กำลังพัฒนาอยู่ โดยไม่ต้องทำการตั้งค่าไฟร์วอลล์หรือปรับการตั้งค่าเครือข่ายของเครื่องคอมพิวเตอร์เลย การใช้ Ngrok ในงานพัฒนา Ngrok เป็นเครื่องมือที่เหมาะสมอย่างยิ่งในการใช้พัฒนาแอปพลิเคชันที่ต้องการการเข้าถึงจากภายนอก โดยเฉพาะในการทดสอบเว็บแอปพลิเคชันหรือการแสดงผลโมให้กับ ทีมงานหรือผู้ใช้อื่น ๆ โดยไม่ต้องไปยุ่งยากกับการตั้งค่าเครือข่ายที่ซับซ้อน ตัวอย่างเช่น ในการพัฒนา เว็บแอปพลิเคชันที่ต้องการการเข้าถึงจากเครื่องคอมพิวเตอร์อื่นในเครือข่ายภายนอก เช่น เมื่อต้องการ ให้ทีมพัฒนาเข้าถึงแอปพลิเคชันที่กำลังทดสอบอยู่ นอกจากนี้ Ngrok ยังเหมาะสมกับการใช้งานใน ระบบที่มีการเชื่อมต่อแบบ WebSocket หรือการเชื่อมต่อแบบ TCP ที่ต้องการช่องทางการส่งข้อมูลที่ปลอดภัยและเชื่อถือได้ การใช้ Ngrok สามารถช่วยให้คุณทำงานได้ง่ายขึ้นและลดเวลาในการตั้งค่าระบบ ต่าง ๆ ให้ยุ่งยากน้อยลง ความปลอดภัยในการใช้งาน Ngrok หนึ่งในคุณสมบัติที่ทำให้ Ngrok เป็นที่นิยม คือความปลอดภัยสูงในการใช้งาน ทุกการเชื่อมต่อผ่าน Ngrok จะได้รับการเข้ารหัส (HTTPS) โดยไม่ต้องตั้งค่าเพิ่มเติม ซึ่งช่วยให้การส่งข้อมูลระหว่างผู้ใช้ภายนอกกับแอปพลิเคชันที่คุณกำลังพัฒนาเป็นไป อย่างปลอดภัย ไม่ว่าจะเป็นข้อมูลที่ละเอียดหรือไม่สำคัญก็ตาม Ngrok เป็นเครื่องมือที่ช่วยให้คุณ สามารถเชื่อมต่อบริการที่กำลังพัฒนาอยู่บนเครื่องของคุณกับโลกภายนอกได้อย่างรวดเร็วและปลอดภัย โดยไม่ต้องยุ่งยากกับการตั้งค่าเครือข่ายหรือการเปิดพอร์ต ซึ่งเหมาะสมอย่างยิ่งสำหรับนักพัฒนาและทีมพัฒนาที่ต้องการเข้าถึงแอปพลิเคชันที่กำลังทดสอบจากที่ต่าง ๆ หรือในกรณีที่ไมสะดวกในการตั้งค่าระบบเครือข่าย




ภาพที่ 2.6 สัญลักษณ์ของ เอ็นจีร็อก  
ที่มา <https://github.com/NGROK>

### 2.3.8 ไลน์เดเวลอปเปอร์ (LINE Developers)

LINE Developers คือแพลตฟอร์มที่พัฒนาโดย LINE Corporation ซึ่งเป็นบริษัทที่สร้างแอปพลิเคชันแชท LINE ซึ่งได้รับความนิยมในหลายประเทศทั่วโลก โดย LINE Developers เป็นเครื่องมือที่ช่วยให้นักพัฒนาสามารถสร้างแอปพลิเคชันหรือบริการที่สามารถทำงานร่วมกับ LINE ได้ผ่าน API (Application Programming Interface) และฟีเจอร์ต่างๆ ที่ LINE เสนอให้ LINE API เป็นเครื่องมือที่เปิดโอกาสให้นักพัฒนาสามารถเชื่อมต่อแอปพลิเคชันที่พัฒนาเข้ากับระบบ LINE ได้อย่าง

ง่ายตาย ซึ่งช่วยให้สามารถสร้างฟีเจอร์ต่างๆ ที่มีประโยชน์มากมายสำหรับแอปพลิเคชัน หรือบริการที่ต้องการใช้งานกับ LINE เช่น การส่งข้อความ, การรับข้อความ, การใช้งานการล็อกอินผ่าน LINE, การพัฒนา LINE Bot, การรับชำระเงินผ่าน LINE Pay และอีกหลายฟีเจอร์ที่ช่วยให้นักพัฒนา สามารถสร้างประสบการณ์การใช้งานที่ดีกับผู้ใช้บน LINE ได้ LINE Messaging API ช่วยให้นักพัฒนา สามารถสร้างแอปพลิเคชันที่สามารถส่งและรับข้อความจากผู้ใช้ใน LINE ได้ โดยผ่านบอท (Bot) ซึ่ง สามารถส่งข้อความประเภทต่างๆ เช่น ข้อความตัวอักษร, รูปภาพ, วิดีโอ หรือสติ๊กเกอร์ นอกจากนี้ยังสามารถสร้างการสนทนาอัตโนมัติเพื่อให้บริการลูกค้าหรือสนับสนุนกิจกรรมต่างๆ ผ่านแอปพลิเคชันของคุณได้ การใช้ LINE Messaging API ช่วยให้การติดต่อสื่อสารกับลูกค้าหรือผู้ใช้งานสามารถทำได้ อย่างรวดเร็วและสะดวกสบาย LINE Login เป็นฟีเจอร์ที่ช่วยให้ผู้ใช้สามารถล็อกอินเข้าสู่แอปพลิเคชันของคุณโดยใช้บัญชี LINE ของพวกเขา การใช้ LINE Login ช่วยให้นักพัฒนาประหยัดเวลาในการสร้างระบบ การลงทะเบียนและล็อกอินใหม่ ๆ และยังช่วยให้ผู้ใช้สามารถเข้าสู่แอปพลิเคชันของคุณได้ ง่ายและรวดเร็วเพียงแค่อัปโหลดบัญชี LINE โดยไม่ต้องกรอกข้อมูลส่วนตัวหรือรหัสผ่านใหม่ LINE Pay เป็นบริการการ ชำระเงินออนไลน์ที่พัฒนาโดย LINE ซึ่งช่วยให้ธุรกิจสามารถรับชำระเงินจากผู้ใช้งานผ่าน แอป LINE ได้อย่าง สะดวกและปลอดภัย โดยไม่ต้องสร้างระบบการชำระเงินจากต้นทางเอง นักพัฒนาสามารถใช้งาน LINE Pay API ในการรับชำระเงินจากผู้ใช้งานในแอปพลิเคชันของตัวเองได้ ซึ่งช่วยให้นักพัฒนาสามารถรวม การชำระเงินเข้ากับแอปพลิเคชันได้ง่ายและรวดเร็ว LINE Beacon เป็นเครื่องมือที่ช่วยให้แอปพลิเคชัน LINE สามารถเชื่อมต่อกับสถานที่จริง โดยการใช้เทคโนโลยีบีคอน (Beacon) ที่สามารถส่งข้อมูลหรือ โปรโมชันไปยังผู้ใช้ที่เข้าใกล้กับเครื่อง Beacon ที่ตั้งอยู่ในสถานที่ ต่างๆ นักพัฒนาสามารถใช้ LINE Beacon เพื่อให้บริการเฉพาะทางที่เกี่ยวข้องกับตำแหน่งที่ตั้ง เช่น การส่งโปรโมชัน, การแจ้งเตือน หรือ การบริการต่างๆ ตามสถานที่ที่ผู้ใช้เข้ามาใกล้กับ Beacon ที่ตั้ง อยู่ LINE for Business คือบริการที่ช่วย ให้ธุรกิจสามารถสร้างช่องทางการติดต่อและการส่งข้อมูล ให้กับลูกค้าโดยตรงผ่าน LINE โดยไม่ต้อง พัฒนาแพลตฟอร์มใหม่ๆ ผู้ประกอบการสามารถใช้ LINE Official Account เพื่อเชื่อมต่อกับลูกค้าและ ใช้เครื่องมือต่างๆ ที่ LINE เสนอ เช่น การส่งโปรโมชัน, การจัดการข้อความ, การทำการตลาดผ่าน LINE การใช้งาน LINE Developers เริ่มต้นได้ง่าย ๆ โดยการสร้างบัญชี LINE Developer และสมัครใช้งาน LINE API ผ่านเว็บไซต์ของ LINE Developers จากนั้นนักพัฒนาสามารถสร้าง LINE Official Account หรือ LINE Bot แล้วนำไปใช้ในแอปพลิเคชัน ของตัวเองได้ โดยจะต้องเชื่อมต่อกับ LINE API ผ่านการใช้ Access Token และ API Call ต่าง ๆ ที่ LINE ให้มา LINE Developers เป็นแพลตฟอร์มที่เปิดโอกาสให้นักพัฒนาสามารถสร้างแอปพลิเคชัน หรือบริการที่ สามารถเชื่อมต่อกับ LINE ได้อย่างง่ายดาย โดยการใช้งาน LINE API และฟีเจอร์ต่างๆ ที่ LINE เสนอ ไม่ว่าจะเป็นการส่งข้อความ, การล็อกอินผ่าน LINE, การชำระเงินผ่าน LINE Pay หรือ การใช้ Beacon เพื่อ เชื่อมต่อกับสถานที่จริง LINE Developers ช่วยให้นักพัฒนาสามารถสร้างแอปพลิเคชันที่เชื่อมต่อกับ ผู้ใช้ใน LINE ได้อย่างมีประสิทธิภาพและสร้างประสบการณ์ที่ดีให้กับผู้ใช้งาน บน LINE




ภาพที่ 2.7 สัญลักษณ์ของ ไลน์เดवलอปเปอร์

ที่มา: <https://open.spotify.com/show/5oN6OeJOm5LXiudpHfznQi>

### 2.3.9 ไลน์เมสเสจจิงเอพีไอ (LINE Messaging API)

Messaging API ของ LINE คือชุดเครื่องมือที่ช่วยให้นักพัฒนาสามารถสร้างแชทบอท (chatbots) และบริการที่สามารถโต้ตอบกับผู้ใช้ผ่านแอปพลิเคชัน LINE โดยตรง ซึ่งทำให้การสื่อสาร ระหว่างแอปพลิเคชันและผู้ใช้เกิดขึ้นได้อย่างราบรื่นและมีประสิทธิภาพมากขึ้น ด้วยการใช้ API นี้ นักพัฒนาสามารถส่งข้อความที่มีหลากหลายรูปแบบให้กับผู้ใช้ที่แชทกับบอทหรือบัญชี LINE ของตนเอง ได้ไม่ว่าจะเป็นข้อความตัวอักษร, ภาพ, วิดีโอ, ปุ่มกด, การ์ดโต้ตอบที่สามารถทำให้การสื่อสารในแอปมี ความน่าสนใจและมีความสามารถที่มากขึ้น การใช้งาน Messaging API ทำให้นักพัฒนาสามารถสร้าง ฟังก์ชันต่างๆ ที่รองรับการสื่อสารที่มีความซับซ้อนและตอบโต้ได้ดีขึ้น ทั้งยังสามารถใช้งานได้หลาย กรณี เช่น การให้บริการลูกค้าออนไลน์ การจัดการคำถามที่พบบ่อย (FAQ) การจัดการคำสั่งซื้อและการ ยืนยันคำสั่งซื้อ การแจ้งเตือนผู้ใช้หรือการโต้ตอบกับผู้ใช้ที่มีลักษณะเป็นแบบอัตโนมัติ หรือแม้แต่การ สร้างแคมเปญการตลาดที่สามารถกระตุ้นให้ผู้ใช้ทำกิจกรรมต่างๆ ได้ หนึ่งในคุณสมบัติที่สำคัญของ Messaging API คือความสามารถในการจัดการข้อความได้หลากหลายประเภท โดยนักพัฒนาสามารถ ส่งข้อความธรรมดา (text message) หรืออาจจะส่งเป็นข้อความที่มีการผสมผสานกับข้อมูลเพิ่มเติม เช่น ปุ่มที่ผู้ใช้สามารถคลิกเพื่อดำเนินการบางอย่าง (action buttons), การ์ดที่สามารถแสดงข้อมูล หลากๆ ชนิดพร้อมกันในลักษณะที่สวยงาม และแม้กระทั่งการส่งภาพหรือวิดีโอที่สามารถเพิ่มความ น่าสนใจให้กับการโต้ตอบ การใช้ Messaging API ยังช่วยให้นักพัฒนาสามารถควบคุมการสนทนาได้ อย่างมีประสิทธิภาพ เนื่องจากมันรองรับการตอบสนองต่อข้อความจากผู้ใช้ในเวลาจริง และสามารถตั้งค่าการตอบกลับอัตโนมัติตามคำถามหรือคำสั่งที่ได้รับ ซึ่งทำให้ผู้ใช้สามารถได้รับการตอบกลับที่รวดเร็ว และเหมาะสมกับความต้องการ นอกจากนี้, การตั้งค่าคำสั่งต่างๆ ที่เกี่ยวข้องกับการโต้ตอบของบอทยัง ช่วยให้การสื่อสารในระบบสามารถยืดหยุ่นตามสถานการณ์ได้ ด้วยฟังก์ชันการส่งข้อความที่รองรับหลาย รูปแบบ, การใช้งาน Messaging API ทำให้นักพัฒนาสามารถปรับใช้ในกรณีการใช้งานที่หลากหลาย เช่น การพัฒนาแอป

พลีเคชันสำหรับการให้บริการลูกค้าแบบออนไลน์, การสร้างแคมเปญการตลาดที่ ต้องการให้ผู้ใช้มีส่วนร่วมผ่านการคลิกปุ่มต่างๆ, การจัดการกับข้อมูลต่างๆ ที่ผู้ใช้ต้องการรับทราบ, และ การสร้างประสบการณ์ที่เชื่อมโยงกับระบบอื่นๆ ผ่านการรับส่งข้อมูลแบบเรียลไทม์ (real-time interactions) การใช้ Messaging API ยังสามารถเพิ่มความสามารถในการขยายตัวให้กับแอปพลิเคชัน ของนักพัฒนา, โดยสามารถส่งข้อความไปยังผู้ใช้จำนวนมากได้อย่างมีประสิทธิภาพภายในระยะเวลาอันสั้น, ซึ่งสำคัญมากในกรณีของการสร้างการโฆษณา, โปรโมชั่น, หรือการแจ้งเตือนต่างๆ ที่มีการตอบรับ จากผู้ใช้หลายรายพร้อมกัน ในภาพรวม, LINE Messaging API เป็นเครื่องมือที่ช่วยให้นักพัฒนาสามารถ สร้างแอปพลิเคชันที่สามารถโต้ตอบกับผู้ใช้ได้หลากหลายวิธี, ตั้งแต่การส่งข้อความธรรมดา ไปจนถึงการ ส่งการ์ดโต้ตอบหรือปุ่มที่สามารถกระตุ้นให้ผู้ใช้มีส่วนร่วมในการตอบสนองต่อข้อความที่ส่งไป ทั้งนี้, ข้อดีของ Messaging API คือความยืดหยุ่นที่มีให้นักพัฒนาที่สามารถใช้ API ในการตอบโต้การ สื่อสารแบบทันที, พร้อมทั้งสามารถพัฒนาแอปพลิเคชันที่มีประสิทธิภาพสูงในระบบของ LINE ได้อย่าง ง่ายดาย



ภาพที่ 2.8 รูปแบบการทำงานของ ไลน์เมสเสจจิงเอพีไอ  
ที่มา: <https://linedevth.line.me/th/messaging-api>

### 2.3.10 ไลน์ล็อกอินเอพีไอ (LINE Login API)

LINE Login API คือเครื่องมือที่ให้บริการโดย LINE ซึ่งช่วยให้นักพัฒนาสามารถให้ผู้ใช้ เข้าสู่ระบบ (login) ในแอปพลิเคชันหรือเว็บไซต์ของตนได้โดยใช้บัญชี LINE แทนการสร้างบัญชีใหม่หรือ ลงทะเบียนใหม่ การใช้ LINE Login API ช่วยให้ผู้ใช้งานสามารถเข้าสู่ระบบได้ง่ายและสะดวกมากยิ่งขึ้น โดย ไม่ต้องจำรหัสผ่านหลายตัว และยังช่วยให้ผู้ใช้สามารถเข้าสู่ระบบได้เร็วขึ้นโดยการใช้ข้อมูลที่มีอยู่ใน บัญชี LINE ของตน ซึ่งทำให้ประสบการณ์การใช้งานแอปพลิเคชันหรือเว็บไซต์ของนักพัฒนามีความ สะดวกและเป็นมิตรกับผู้ใช้มากขึ้น การใช้ LINE Login API ทำให้ไม่ต้องเสียเวลาในการสร้างและจัดการ บัญชีผู้ใช้ใหม่ รวมถึงไม่ต้องกังวลเกี่ยวกับการรักษาความปลอดภัยของรหัสผ่านในระบบของตนเอง เพราะผู้ใช้สามารถใช้บัญชี LINE ที่มีอยู่แล้วในการเข้าสู่ระบบได้ โดยระบบจะทำการตรวจสอบตัวตน ของผู้ใช้ผ่าน LINE API และสามารถนำข้อมูลผู้ใช้ที่ได้รับมาใช้ในการปรับปรุงประสบการณ์การใช้งาน หรือการให้บริการต่างๆ ได้ตามความต้องการ เมื่อผู้ใช้เข้าสู่ระบบผ่าน LINE Login API นักพัฒนา สามารถได้รับข้อมูลพื้นฐานของผู้ใช้ เช่น ชื่อ, รูปโปรไฟล์, อีเมล (หากผู้ใช้ยินยอมให้ข้อมูลเหล่านี้) ซึ่ง สามารถนำไปใช้ในการปรับแต่งและพัฒนาฟีเจอร์ต่างๆ ในแอปพลิเคชันหรือเว็บไซต์ เช่น การตั้งค่าโปร ไฟล์, การบันทึกประวัติการใช้งาน, หรือการส่งการแจ้งเตือนที่

เกี่ยวข้องกับผู้ใช้ ความปลอดภัยของการ ใช้งาน LINE Login API ยังได้รับการดูแลอย่างดีจาก LINE ซึ่งมีระบบการตรวจสอบและยืนยันตัวตน ของผู้ใช้ที่เชื่อถือได้ โดยใช้ OAuth 2.0 เป็นมาตรฐานในการยืนยันตัวตนและการให้สิทธิ์การเข้าถึงข้อมูล ของผู้ใช้ ซึ่งระบบนี้มีการรักษาความปลอดภัยสูงและช่วยป้องกันการเข้าถึงข้อมูลส่วนบุคคลของผู้ใช้โดยไม่ได้รับอนุญาต การใช้ LINE Login API ยังช่วยให้การพัฒนาแอปพลิเคชันหรือเว็บไซต์มีความง่ายตาย มากขึ้น เนื่องจากนักพัฒนาสามารถรวมฟังก์ชันการเข้าสู่ระบบของ LINE เข้าไปในแอปพลิเคชันของตน ได้โดยไม่ต้องจัดการกับกระบวนการลงทะเบียนหรือจัดการฐานข้อมูลผู้ใช้ใหม่ ทั้งนี้ยังสามารถเข้าถึง ฟีเจอร์อื่นๆ ที่ LINE ให้บริการ เช่น การแชร์ข้อมูลจากแอปพลิเคชันไปยัง LINE หรือการเชื่อมต่อกับ บริการอื่นๆ ของ LINE ผ่านการใช้ งาน API อื่นๆ โดยรวมแล้ว, LINE Login API ไม่เพียงแต่ช่วยให้การ เข้าสู่ระบบง่ายและสะดวก แต่ยังช่วยเพิ่มความปลอดภัยและประสิทธิภาพในการจัดการข้อมูลผู้ใช้ใน แอปพลิเคชันหรือเว็บไซต์ และสามารถนำไปใช้ในแอปพลิเคชันหรือบริการต่างๆ ที่ต้องการการเข้าสู่ ระบบที่รวดเร็วและปลอดภัย โดยไม่ต้องมีขั้นตอนซับซ้อนในการจัดการกับบัญชีผู้ใช้หรือรหัสผ่าน หลายๆ ตัว

### 2.3.11 โปสต์แมน (Postman)

โปสต์แมน (Postman) คือเครื่องมือที่มีความสำคัญในการพัฒนาและทดสอบ API (Application Programming Interface) โดยเฉพาะส าหรับการทดสอบว่า API ที่สร้างขึ้นสามารถทำงานได้ตามที่คาดหวังหรือไม่ เครื่องมือนี้ได้รับความนิยมในหมู่นักพัฒนาและทีมงานที่ทำงาน เกี่ยวข้อง กับการพัฒนาแอปพลิเคชันและการเชื่อมต่อกับบริการต่าง ๆ ผ่าน API เนื่องจากความ สะดวกในการใช้งานและความสามารถในการช่วยพัฒนาระบบต่าง ๆ อย่างมีประสิทธิภาพ Postman ใช้สำหรับการส่งคำขอ (request) ไปยัง API ที่นักพัฒนากำหนดไว้ โดยสามารถส่งค่าไปในส่วนต่าง ๆ เช่น header หรือ body เพื่อทดสอบว่า API สามารถตอบกลับมาได้ตามที่คาดหวังหรือไม่ ไม่ว่าจะเป็น การทดสอบคำขอที่มี parameter ต่าง ๆ รวมถึงการทดสอบคำขอแบบ GET, POST, PUT, DELETE และคำขอ HTTP อื่น ๆ ที่ใช้ในการทำงานกับ API ทั้งนี้ Postman ยังสามารถแสดงผลการ ตอบกลับจาก API ในรูปแบบที่ เข้าใจง่าย เช่น ข้อความ, JSON, XML, หรือ HTML ซึ่งท าให้ผู้พัฒนา สามารถวิเคราะห์และตรวจสอบ ผลลัพธ์ได้อย่างรวดเร็ว Postman ยังสามารถสร้างและจัดการชุดคำ ขอ API (API collections) ซึ่ง นักพัฒนาสามารถจัดเก็บคำขอที่เกี่ยวข้องหรือที่ใช้บ่อยในโปรเจกต์ ต่าง ๆ เอาไว้ในชุดเดียวกัน ช่วยให้ สามารถแชร์และทำงานร่วมกับผู้อื่นได้สะดวกมากยิ่งขึ้น รวมถึง สามารถแบ่งปันคำขอเหล่านี้กับทีมงาน หรือบุคคลอื่นที่เกี่ยวข้อง ซึ่งจะช่วยลดเวลาในการทดสอบ API ใหม่ ๆ และทำให้การทำงานร่วมกันมี ประสิทธิภาพมากขึ้น อีกหนึ่งฟีเจอร์ที่ Postman รองรับ คือการสร้าง API mock server ซึ่งเป็น เครื่องมือที่ช่วยให้สามารถทดสอบ API ได้แม้ว่า API ยังไม่ได้ พัฒนาเสร็จสมบูรณ์ โดยการสร้าง mock server นี้ นักพัฒนาสามารถจำลองการตอบกลับจาก API ที่ยังไม่ได้พัฒนาได้ เพื่อให้สามารถทดสอบ การทำงานของแอปพลิเคชันหรือระบบที่ใช้ API นั้น ๆ ได้ ล่วงหน้า นอกจากนี้ Postman ยังสามารถ ตรวจสอบประสิทธิภาพ (performance testing) ของ API ได้ โดยการทดสอบความสามารถในการ รองรับจำนวนคำขอที่มาก ๆ หรือการทดสอบความเร็ว ในการตอบกลับของ API ในสถานการณ์ต่าง ๆ ซึ่งช่วยให้สามารถระบุปัญหาหรือข้อบกพร่องที่อาจ เกิดขึ้นใน API และสามารถปรับปรุงให้มี ประสิทธิภาพดียิ่งขึ้น การใช้งาน Postman ช่วยให้การ พัฒนาและทดสอบ API เป็นไปอย่างรวดเร็วและมีประสิทธิภาพ นักพัฒนาสามารถตรวจสอบและ

ทดสอบ API ได้ในขั้นตอนต่าง ๆ ของการพัฒนา รวมถึง สามารถจัดการและเก็บข้อมูลคำขอ API ได้อย่างสะดวก ทำให้การทำงานร่วมกันในทีมพัฒนาหรือการ ทดสอบ API เป็นเรื่องที่ย่ายและไม่ซับซ้อน



ภาพที่ 2.9 สัญลักษณ์ของ โพสต์แมน

ที่มา: <https://appsource.microsoft.com/enus/product/office/wa200007499?tab=overview>

### 2.3.12 รีทรีวัลออกเมนเต็ดเจเนอเรชัน (Retrieval Augmented Generation)

Retrieval-Augmented Generation (RAG) คือเทคนิคที่รวมกระบวนการดึงข้อมูลและการ สร้างข้อความเข้าด้วยกัน เพื่อยกระดับความแม่นยำและความเกี่ยวข้องของผลลัพธ์ที่ได้จากโมเดลภาษา ขนาดใหญ่ (Large Language Model — LLM) ซึ่งเป็นโมเดลที่ได้รับการฝึกฝนด้วยข้อมูลจำนวน มหาศาลและสามารถประมวลผลภาษาได้อย่างซับซ้อน RAG มีบทบาทสำคัญในการช่วยให้ LLM สามารถเข้าถึงข้อมูลใหม่หรือข้อมูลเฉพาะทางได้ทันที โดยไม่จำเป็นต้องฝึกฝนโมเดลใหม่ทุกครั้งที่มีข้อมูล เปลี่ยนแปลงหลักการสำคัญของ RAG คือการนำข้อมูลจากแหล่งภายนอก เช่น ฐานข้อมูล เอกสาร ภายใน เว็บไซต์ หรือ API มาใช้เสริมเป็นบริบทให้กับ LLM ในระหว่างกระบวนการสร้างข้อความ ช่วยให้คำตอบที่ได้มีความถูกต้อง ครบคลุม และทันสมัยมากขึ้น โดยเฉพาะอย่างยิ่งในงานที่ต้องอาศัย ข้อมูลเฉพาะทางหรือข้อมูลที่อัปเดตอยู่ตลอดเวลา กระบวนการทำงานของ RAG เริ่มต้นจากผู้ใช้งาน คำถามหรือคำขอ (Query) เข้าไปในระบบ จากนั้นระบบจะค้นหาข้อมูลที่เกี่ยวข้องจากแหล่งข้อมูลที่ ระบุไว้ล่วงหน้า ด้วยเทคนิคการค้นหาขั้นสูง เช่น Dense Passage Retrieval (DPR), BM25, หรือ Vector Search หลังจากดึงข้อมูลที่ตรงกับคำถามได้แล้ว ข้อมูลเหล่านั้นจะถูกส่งต่อไปให้ LLM ใช้เป็น บริบทในการสร้างคำตอบ กระบวนการนี้ทำให้โมเดลไม่เพียงแต่สร้างข้อความตามความรู้เดิมที่ถูกฝึกมา เท่านั้น แต่ยังสามารถใช้ข้อมูลใหม่ที่ค้นหาได้มาประกอบการตอบ ทำให้ผลลัพธ์มีความแม่นยำและ เกี่ยวข้องมากยิ่งขึ้น ข้อดีของ RAG คือความสามารถในการอัปเดตข้อมูลได้แบบเรียลไทม์โดยไม่ต้องฝึก โมเดลใหม่ ซึ่งช่วยลดต้นทุนและเวลาในการดูแลรักษาระบบ นอกจากนี้ยังลดโอกาสเกิดข้อผิดพลาดที่ มักเกิดขึ้นกับ LLM เช่น การสร้างข้อมูลที่ไม่มีอยู่จริง (Hallucination) เพราะโมเดลสามารถอ้างอิงข้อมูล จริงจากแหล่งที่เชื่อถือได้ก่อนจะสร้างคำตอบ RAG ยังช่วยเพิ่มประสิทธิภาพในการประมวลผลคำถามที่ ซับซ้อน ซึ่งต้องอาศัยข้อมูลจำนวนมากหรือข้อมูลที่มีความเฉพาะทางสูง การใช้งาน RAG เหมาะสำหรับ หลากหลายบริบท เช่น ระบบสนับสนุนลูกค้าที่ต้องตอบคำถามจากฐานความรู้ภายในบริษัท, ระบบ วิเคราะห์ข้อมูลที่ต้องดึง

ข้อมูลจากแหล่งข้อมูลเฉพาะทาง, หรือระบบค้นคว้าวิจัยที่ต้องอ้างอิงงานวิจัย ล่าสุด นอกจากนี้ RAG ยังสามารถใช้ในงานที่ต้องการอัปเดตข้อมูลอย่างต่อเนื่อง เช่น การรายงานข่าว หรือการตรวจสอบข้อมูลในตลาดการเงิน อย่างไรก็ตาม การนำ RAG มาใช้ก็มีความท้าทายอยู่บ้าง เช่น การออกแบบระบบค้นหาให้มีประสิทธิภาพ การจัดการบริบทไม่ให้มากเกินไปจนโมเดลสับสน หรือการเพิ่มเวลาในการประมวลผลเนื่องจากต้องมีการค้นหาข้อมูลก่อนการสร้างคำตอบ แต่หาก ออกแบบระบบอย่างเหมาะสม RAG จะช่วยยกระดับประสิทธิภาพของ LLM ได้อย่างมหาศาล โดยสรุป Retrieval-Augmented Generation เป็นเทคนิคที่ช่วยให้โมเดลภาษาขนาดใหญ่สามารถสร้างคำตอบ ที่แม่นยำ ครอบคลุม และมีบริบทมากขึ้น ผ่านการค้นหาและอ้างอิงข้อมูลจากแหล่งข้อมูลภายนอกก่อน การสร้างคำตอบ ทำให้ RAG เป็นเครื่องมือสำคัญในการพัฒนาระบบที่ต้องการข้อมูลที่ถูกต้องและทันสมัยตลอดเวลา

### 2.3.13 เอ็นเอฟเอ็น (n8n)

คือ ระบบสร้างกระบวนการทำงานอัตโนมัติแบบโอเพ่นซอร์สน8n (อ่านว่า “เอ็น-เอท-เอ็น”) คือแพลตฟอร์มระบบอัตโนมัติ (Automation Platform) แบบโอเพ่นซอร์ส (Open-source) ที่ถูกออกแบบมาเพื่อให้ผู้ใช้งานสามารถเชื่อมโยงบริการหรือแอปพลิเคชันต่าง ๆ เข้าด้วยกันได้อย่างง่ายดาย โดยไม่จำเป็นต้องมีทักษะการเขียนโปรแกรมในระดับสูงนอกจากนี้ n8n ยังรองรับการเขียนโค้ดแบบกำหนดเองด้วย JavaScript เพื่อเพิ่มความยืดหยุ่นให้กับการสร้างเวิร์กโฟลว์ (Workflow) ที่ตอบโจทย์การทำงานได้ลึกซึ้งและเฉพาะทางมากขึ้น เหมาะสำหรับทั้งนักพัฒนาและผู้ใช้ทั่วไปที่ต้องการสร้างระบบอัตโนมัติด้วยตนเองหลักการทำงานของ n8nระบบของ n8n ใช้แนวคิดหลักคือ Workflow ซึ่งประกอบด้วย Node ต่าง ๆ ที่เชื่อมต่อกันในลักษณะแผนผัง (Flowchart) เพื่อกำหนดลำดับขั้นตอนของการทำงานอย่างเป็นระบบโครงสร้างสำคัญ: Workflow: กระบวนการทำงานแบบอัตโนมัติที่กำหนดไว้ เช่น การดึงข้อมูล วิเคราะห์ ส่งผลลัพธ์ Node: หน่วยย่อยใน workflow ที่ทำหน้าที่เฉพาะ เช่น ดึงข้อมูล, ส่ง API, ส่งข้อความ ฯลฯ Trigger Node: จุดเริ่มต้นของ workflow เช่น Webhook, Cron (ตามเวลา), หรือมีอีเมลเข้า Action Node: การกระทำ เช่น ส่งข้อมูลไปยังปลายทาง, แจ้งเตือน, เขียนฐานข้อมูล Logic Node: การประมวลผลเชิงตรรกะ เช่น การตรวจสอบเงื่อนไข (IF), การแบ่งเส้นทาง (Switch), การตั้งค่าข้อมูล (Set)จุดเด่นของ n8nโอเพ่นซอร์ส n8n เปิดให้ใช้งานฟรี และสามารถนำซอร์สโค้ดไปปรับแต่งหรือพัฒนาเพิ่มเติมได้ ติดตั้งและใช้งานได้หลายรูปแบบ ทั้งแบบ Self-hosted (ติดตั้งในเซิร์ฟเวอร์ของตนเอง) และแบบ Cloud ที่ n8n ให้บริการ รองรับการทำงานเชื่อมต่อกว่า 350 แอป เช่น Google Sheets, Gmail, Slack, Telegram, Facebook, PostgreSQL ฯลฯใช้งานง่ายผ่าน UI แบบลากวาง (Visual Drag & Drop) เหมาะสำหรับผู้ใช้ทุกระดับรองรับการเขียน JavaScript เพิ่มความยืดหยุ่นในการประมวลผลข้อมูล หรือสร้างเงื่อนไขที่ซับซ้อน



ภาพที่ 2.10 สัญลักษณ์ของ เอ็นเอทเอ็น  
ที่มา <https://www.noqode.fr/en/outils/n8n>

#### 2.3.14 โฮสติงเกอร์ (Hostinger)

คือเป็นผู้ให้บริการเว็บโฮสติ้งและจดทะเบียนชื่อโดเมนที่ก่อตั้งขึ้นในปี ค.ศ. 2004 มีสำนักงานใหญ่ตั้งอยู่ที่ประเทศลิทัวเนีย โดยให้บริการด้านโครงสร้างพื้นฐานสำหรับเว็บไซต์และเว็บแอปพลิเคชันผ่านเครือข่ายอินเทอร์เน็ต ไม่ว่าจะเป็นบริการเว็บโฮสติ้ง คลาวด์โฮสติ้ง เซิร์ฟเวอร์เสมือน (VPS) การจัดการฐานข้อมูล และการจดทะเบียนโดเมน ซึ่งช่วยให้ผู้ใช้งานสามารถพัฒนาติดตั้ง และเผยแพร่ระบบสารสนเทศได้อย่างมีประสิทธิภาพแนวคิดสำคัญของ Hostinger คือการให้บริการโฮสติ้งที่มีประสิทธิภาพ ใช้งานง่าย และมีต้นทุนที่เหมาะสม โดยอาศัยเทคโนโลยี Cloud Computing และระบบเซิร์ฟเวอร์สมัยใหม่ในการบริหารจัดการทรัพยากร ทำให้สามารถรองรับการเข้าถึงข้อมูลจากผู้ใช้งานจำนวนมากได้อย่างมีประสิทธิภาพ นอกจากนี้ยังมีเครื่องมือสำหรับบริหารจัดการเว็บไซต์และระบบรักษาความปลอดภัยที่ช่วยอำนวยความสะดวกให้แก่ผู้พัฒนา และผู้ดูแลระบบหลักการทำงานของ Hostinger คือการจัดเตรียมพื้นที่บนเซิร์ฟเวอร์สำหรับจัดเก็บไฟล์เว็บไซต์ ฐานข้อมูล และทรัพยากรต่าง ๆ ของระบบ เมื่อผู้ใช้งานเข้าถึงเว็บไซต์ผ่านชื่อโดเมน ระบบ DNS จะทำการแปลงชื่อโดเมนเป็นหมายเลข IP Address และส่งคำร้องขอไปยังเซิร์ฟเวอร์ จากนั้นเซิร์ฟเวอร์จะประมวลผลคำสั่ง ดึงข้อมูลที่เกี่ยวข้อง และส่งผลลัพธ์กลับมาที่เว็บเบราว์เซอร์ของผู้ใช้งาน ทำให้สามารถเข้าถึงข้อมูลและใช้งานระบบได้ผ่านเครือข่ายอินเทอร์เน็ตด้วยคุณสมบัติที่รองรับการพัฒนาเว็บไซต์ เว็บแอปพลิเคชัน และระบบฐานข้อมูล Hostinger จึงเป็นแพลตฟอร์มที่ได้รับความนิยมสำหรับการนำระบบสารสนเทศไปใช้งานจริง รวมถึงสามารถประยุกต์ใช้ในการเผยแพร่ระบบปัญญาประดิษฐ์และระบบ Retrieval-Augmented Generation (RAG) โดยช่วยลดภาระในการจัดการโครงสร้างพื้นฐานด้านเซิร์ฟเวอร์ และเพิ่มความสะดวกในการบริหารจัดการระบบของนักพัฒนา



ภาพที่ 2.11 สัญลักษณ์ของ โฮสติงเกอร์  
ที่มา: <https://www.trustpilot.com/review/hostinger.com>

### 2.3.15 เครื่องมือและเกณฑ์การประเมินประสิทธิภาพระบบ

#### 2.3.15.1 Ragas (รากัส)

Ragas (Retrieval-Augmented Generation Assessment) เป็นกรอบการประเมินผลที่ถูกพัฒนาขึ้นเพื่อใช้วัดประสิทธิภาพของระบบ Retrieval-Augmented Generation (RAG) โดยมุ่งเน้นการประเมินทั้งคุณภาพของกระบวนการค้นคืนข้อมูล (Retrieval) และคุณภาพของการสร้างคำตอบ (Generation) ของโมเดลภาษาขนาดใหญ่ (Large Language Model: LLM) ภายในระบบเดียวกัน เนื่องจากระบบ RAG ประกอบด้วยการค้นหาข้อมูลจากแหล่งความรู้ภายนอกและการสร้างคำตอบจากข้อมูลที่ค้นคืนมา การประเมินผลด้วยวิธีการวัดความถูกต้องของคำตอบเพียงอย่างเดียวอาจไม่สามารถสะท้อนประสิทธิภาพของระบบได้อย่างครบถ้วน RAGAS จึงถูกพัฒนาขึ้นเพื่อช่วยประเมินประสิทธิภาพของระบบในหลายมิติ โดยใช้โมเดลภาษาขนาดใหญ่เป็นผู้วิเคราะห์และให้คะแนนผลลัพธ์ที่เกิดขึ้น RAGAS สามารถประเมินคุณภาพของระบบได้โดยอาศัยองค์ประกอบสำคัญ ได้แก่ คำถาม (Question) คำตอบที่สร้างขึ้นโดยระบบ (Answer) ข้อมูลที่ถูกค้นคืนมา (Retrieved Context) และคำตอบอ้างอิง (Ground Truth) ในบางตัวชี้วัด จากนั้นจะนำข้อมูลดังกล่าวมาวิเคราะห์เพื่อวัดคุณภาพของระบบในด้านต่าง ๆ เช่น ความเกี่ยวข้องของคำตอบ ความถูกต้องของข้อมูล และประสิทธิภาพของกระบวนการค้นคืนข้อมูล

##### ก.หลักการทำงานของ RAGAS

การทำงานของ RAGAS เริ่มจากการนำคำถามเข้าสู่ระบบ Retrieval-Augmented Generation ซึ่งระบบจะค้นคืนข้อมูลที่เกี่ยวข้องจากฐานความรู้ จากนั้นโมเดลภาษาจะสร้างคำตอบโดยอาศัยข้อมูลที่ค้นคืนมา เมื่อได้ผลลัพธ์แล้ว RAGAS จะทำการประเมินคุณภาพของคำตอบและข้อมูลที่ถูกค้นคืนมาโดยใช้ตัวชี้วัดที่กำหนดไว้กระบวนการดังกล่าวช่วยให้นักวิจัยสามารถวิเคราะห์ได้ว่าปัญหาที่เกิดขึ้นมาจากการค้นคืนข้อมูลหรือส่วนของการสร้างคำตอบ ทำให้สามารถปรับปรุงประสิทธิภาพของระบบได้อย่างมีประสิทธิภาพมากยิ่งขึ้น

##### ข.ตัวชี้วัดของ RAGAS

ข.1 Answer Relevancy เป็นตัวชี้วัดที่ใช้วัดระดับความสอดคล้องระหว่างคำถามและคำตอบที่ระบบสร้างขึ้น โดยพิจารณาว่าคำตอบสามารถตอบประเด็นที่ผู้ใช้งานต้องการทราบได้ครบถ้วนและตรงตามคำถามหรือไม่ หากคำตอบมีเนื้อหาที่เกี่ยวข้องกับคำถามและไม่ออกนอกประเด็น จะได้รับคะแนนสูง ในทางตรงกันข้าม หากคำตอบไม่สามารถตอบคำถามได้อย่างตรงประเด็นหรือมีเนื้อหาที่ไม่เกี่ยวข้องจำนวนมาก คะแนนจะลดลง

ข.2 Faithfulness เป็นตัวชี้วัดที่ใช้ประเมินว่าคำตอบที่สร้างขึ้นมีความสอดคล้องกับข้อมูลที่ถูกค้นคืนมาหรือไม่ กล่าวคือ ข้อมูลที่ปรากฏในคำตอบ ควรมีหลักฐานสนับสนุนจากข้อมูลใน Retrieved Context ตัวชี้วัดนี้มีบทบาทสำคัญในการตรวจสอบปัญหา Hallucination ของโมเดลภาษาขนาดใหญ่ ซึ่งเป็นกรณีที่โมเดลสร้างข้อมูลที่ไม่มีอยู่จริงหรือไม่มีหลักฐานรองรับจากแหล่งข้อมูลที่ค้นคืนมา หากคำตอบอ้างอิงข้อมูลจาก Context ได้อย่างถูกต้อง จะได้รับคะแนนสูง แต่หากมีการเพิ่มเติมข้อมูลที่ไม่ปรากฏใน Context คะแนนจะลดลง

ข.3 Context Precision เป็นตัวชี้วัดที่ใช้ประเมินคุณภาพของข้อมูลที่ระบบค้นคืนมา โดยวัดว่าสัดส่วนของข้อมูลที่เกี่ยวข้องกับคำถามมีมากน้อยเพียงใด

หากระบบสามารถค้นคืนเฉพาะข้อมูลที่เกี่ยวข้องกับคำถามได้เป็นส่วนใหญ่ จะได้รับคะแนนสูง แต่หากมีข้อมูลที่ไม่เกี่ยวข้องจำนวนมากปะปนอยู่ในผลลัพธ์ คะแนนจะลดลง ตัวชี้วัดนี้จึงสะท้อนประสิทธิภาพของกระบวนการค้นคืนข้อมูลโดยตรง

ข.4 Context Recall เป็นตัวชี้วัดที่ใช้ประเมินความครบถ้วนของข้อมูลที่ถูกค้นคืนมา โดยวัดว่าระบบสามารถค้นคืนข้อมูลสำคัญที่จำเป็นต่อการตอบคำถามได้ครบถ้วนเพียงใดหากข้อมูลสำคัญทั้งหมดถูกค้นคืนมา ระบบจะได้รับคะแนนสูง แต่หากข้อมูลที่จำเป็นบางส่วนไม่ถูกค้นคืนมา คะแนนจะลดลง ตัวชี้วัดนี้ช่วยสะท้อนความสามารถของ Retriever ในการเข้าถึงข้อมูลที่เกี่ยวข้องจากฐานความรู้

### 2.3.15.2 Deepeval (ดีพีอีแวล)

Deepeval เป็นกรอบงานสำหรับการประเมินประสิทธิภาพของระบบปัญญาประดิษฐ์ที่ใช้แบบจำลองภาษาขนาดใหญ่ (Large Language Models: LLMs) ซึ่งได้รับการพัฒนาขึ้นเพื่อสนับสนุนการทดสอบและตรวจสอบคุณภาพของผลลัพธ์ที่สร้างขึ้นจากโมเดลภาษา โดยเฉพาะระบบที่เกี่ยวข้องกับการตอบคำถาม (Question Answering System) แชทบอต (Chatbot) และระบบ Retrieval-Augmented Generation (RAG) DeepEval ได้รับการออกแบบโดยนำแนวคิดจากการทดสอบซอฟต์แวร์ (Software Testing) มาประยุกต์ใช้กับระบบปัญญาประดิษฐ์ เพื่อให้สามารถตรวจสอบและวัดผลการทำงานของโมเดลได้อย่างเป็นระบบและมีมาตรฐาน คล้ายกับการทดสอบหน่วย (Unit Testing) และการทดสอบการทำงานของระบบ (System Testing) ที่ใช้ในงานวิศวกรรมซอฟต์แวร์ โดยผู้พัฒนาสามารถกำหนดชุดข้อมูลทดสอบเกณฑ์การประเมิน และตัวชี้วัดต่าง ๆ เพื่อวิเคราะห์คุณภาพของคำตอบที่โมเดลสร้างขึ้นความสำคัญของ DeepEval เกิดจากข้อจำกัดของการประเมินผลแบบดั้งเดิมที่มักอาศัยการเปรียบเทียบคำตอบกับคำตอบอ้างอิงเพียงอย่างเดียว ซึ่งไม่สามารถสะท้อนคุณภาพของคำตอบที่สร้างขึ้นด้วยภาษาธรรมชาติได้อย่างครบถ้วน เนื่องจากคำตอบที่ถูกต้องอาจมีรูปแบบการใช้ภาษาที่หลากหลาย แม้ว่าจะสื่อความหมายเดียวกันก็ตาม DeepEval จึงนำเทคนิคการประเมินโดยใช้แบบจำลองภาษาเป็นผู้ตัดสิน (LLM-as-a-Judge) มาใช้ในการวิเคราะห์คุณภาพของคำตอบจากหลายมิติ เช่น ความเกี่ยวข้องกับคำถาม ความถูกต้องของข้อมูล ความสอดคล้องกับบริบท และความน่าเชื่อถือของเนื้อหา นอกจากนี้ DeepEval ยังรองรับตัวชี้วัดที่หลากหลายสำหรับการประเมินระบบ RAG และระบบ LLM ทำให้สามารถตรวจสอบประสิทธิภาพของทั้งกระบวนการค้นคืนข้อมูล (Retrieval) และกระบวนการสร้างคำตอบ (Generation) ได้อย่างครอบคลุม ส่งผลให้นักพัฒนาและนักวิจัยสามารถวิเคราะห์จุดแข็ง จุดอ่อน และปรับปรุงประสิทธิภาพของระบบได้อย่างมีประสิทธิภาพมากยิ่งขึ้นแนวคิดของ DeepEval แนวคิดหลักของ DeepEval คือการประเมินคุณภาพของระบบที่ใช้แบบจำลองภาษาขนาดใหญ่ด้วยวิธีการที่ใกล้เคียงกับการประเมินโดยมนุษย์มากที่สุด โดยอาศัยความสามารถของแบบจำลองภาษาในการวิเคราะห์และตัดสินคุณภาพของผลลัพธ์ที่สร้างขึ้น แนวคิดดังกล่าวเรียกว่า LLM-as-a-Judge ซึ่งเป็นแนวทางที่ได้รับความนิยมอย่างแพร่หลายในการประเมินระบบ Generative AI ในปัจจุบัน เดิมทีการประเมินผลระบบประมวลผลภาษาธรรมชาติมักใช้วิธีการเปรียบเทียบคำตอบกับคำตอบอ้างอิงโดยตรง เช่น การคำนวณความคล้ายคลึงของข้อความหรือการวัดจำนวนคำที่ตรงกัน

อย่างไรก็ตาม วิธีการดังกล่าวมีข้อจำกัดในการประเมินคำตอบที่สร้างขึ้นจาก LLM เนื่องจากคำตอบที่ถูกต้องสามารถแสดงออกได้หลายรูปแบบ แม้จะใช้คำศัพท์หรือโครงสร้างประโยคที่แตกต่างกันก็ตาม DeepEval จึงนำแนวคิด LLM-as-a-Judge มาใช้ โดยให้แบบจำลองภาษาทำหน้าที่เป็นผู้ประเมินคำตอบที่สร้างขึ้นผ่านเกณฑ์ที่กำหนดไว้ล่วงหน้า เช่น การพิจารณาว่าคำตอบมีความเกี่ยวข้องกับคำถามหรือไม่ มีการอ้างอิงข้อมูลจากบริบทอย่างถูกต้องหรือไม่ หรือมีข้อมูลที่ถูกต้องมากขึ้นโดยไม่มีหลักฐานสนับสนุนหรือไม่ วิธีการดังกล่าวช่วยให้การประเมินผลมีความยืดหยุ่นและสามารถสะท้อนคุณภาพของคำตอบในเชิงความหมายได้ดีกว่าการเปรียบเทียบข้อความแบบดั้งเดิมสำหรับระบบ Retrieval-Augmented Generation (RAG) DeepEval มีแนวคิดในการประเมินทั้งสององค์ประกอบสำคัญของระบบ ได้แก่ กระบวนการค้นคืนข้อมูล (Retrieval) และกระบวนการสร้างคำตอบ (Generation) โดยไม่เพียงตรวจสอบว่าคำตอบสุดท้ายมีความถูกต้องหรือไม่ แต่ยังวิเคราะห์ว่าข้อมูลที่ถูกรับคืนมีความเกี่ยวข้องกับคำถามเพียงใด และข้อมูลดังกล่าวถูกนำมาใช้ในการสร้างคำตอบอย่างเหมาะสมหรือไม่ นอกจากนี้ DeepEval ยังมุ่งเน้นการประเมินแบบอัตโนมัติ (Automated Evaluation) เพื่อให้สามารถประเมินชุดข้อมูลจำนวนมากได้อย่างรวดเร็ว ลดภาระของผู้ประเมินที่เป็นมนุษย์ และช่วยให้การเปรียบเทียบประสิทธิภาพระหว่างโมเดลหรือระบบต่าง ๆ สามารถดำเนินการได้อย่างเป็นมาตรฐานและทำซ้ำได้ (Reproducibility) ซึ่งเป็นคุณสมบัติสำคัญในการวิจัยและพัฒนาระบบปัญญาประดิษฐ์ในปัจจุบัน

#### ก. หลักการทำงานของ DeepEval

เป็นกรอบงานสำหรับการประเมินคุณภาพของระบบที่ใช้แบบจำลองภาษาขนาดใหญ่ (Large Language Models: LLMs) โดยอาศัยแนวคิดการประเมินแบบอัตโนมัติ (Automated Evaluation) และการใช้แบบจำลองภาษาเป็นผู้ตัดสิน (LLM-as-a-Judge) เพื่อวิเคราะห์คุณภาพของผลลัพธ์ที่สร้างขึ้นจากระบบปัญญาประดิษฐ์ หลักการทำงานของ DeepEval มุ่งเน้นการตรวจสอบว่าคำตอบที่สร้างขึ้นมีคุณภาพเพียงใดเมื่อเปรียบเทียบกับข้อมูลอ้างอิง คำถามที่ได้รับ และบริบทที่เกี่ยวข้อง ในการประเมินผล DeepEval จะรับข้อมูลจากระบบที่ต้องการทดสอบ ซึ่งโดยทั่วไปประกอบด้วยคำถามของผู้ใช้ (Input Question) คำตอบที่ระบบสร้างขึ้น (Actual Output) คำตอบอ้างอิง (Expected Output) และข้อมูลบริบทที่ถูกรับคืนมา (Retrieved Context) จากนั้นจะนำข้อมูลดังกล่าวเข้าสู่กระบวนการประเมินผ่านตัวชี้วัด (Metrics) ที่กำหนดไว้สำหรับระบบ Retrieval-Augmented Generation (RAG) DeepEval จะประเมินทั้งกระบวนการค้นคืนข้อมูลและกระบวนการสร้างคำตอบร่วมกัน โดยตรวจสอบว่าข้อมูลที่ระบบค้นคืนมามีความเกี่ยวข้องกับคำถามหรือไม่ และคำตอบที่สร้างขึ้นอ้างอิงจากข้อมูลดังกล่าวอย่างถูกต้องเพียงใด วิธีการนี้ช่วยให้สามารถวิเคราะห์ประสิทธิภาพของระบบได้ครอบคลุมมากกว่าการพิจารณาคำตอบสุดท้ายเพียงอย่างเดียว กระบวนการทำงานของ DeepEval สามารถแบ่งออกเป็น 5 ขั้นตอนหลัก ดังนี้

### ก.1 การเตรียมข้อมูลทดสอบ (Test Case Preparation)

ขั้นตอนแรกคือการจัดเตรียมข้อมูลสำหรับการประเมิน ซึ่งประกอบด้วยองค์ประกอบสำคัญ ได้แก่

- ก.1.1 คำถามที่ใช้ทดสอบระบบ (Input)
- ก.1.2 คำตอบที่ระบบสร้างขึ้น (Actual Output)
- ก.1.3 คำตอบอ้างอิง (Expected Output)
- ก.1.4 ข้อมูลบริบทที่ใช้ในการตอบคำถาม (Context)

ข้อมูลดังกล่าวจะถูกจัดเก็บในรูปแบบ Test Case เพื่อใช้เป็นข้อมูลนำเข้าสำหรับกระบวนการประเมิน

### ก.2 การเลือกตัวชี้วัด (Metric Selection)

หลังจากเตรียมข้อมูลเรียบร้อยแล้ว ผู้วิจัยหรือผู้พัฒนาจะกำหนดตัวชี้วัดที่ใช้ในการประเมิน โดยแต่ละตัวชี้วัดจะวิเคราะห์คุณภาพของระบบในมิติที่แตกต่างกัน ตัวอย่างเช่น

- ก.2.1 Answer Relevancy สำหรับวัดความเกี่ยวข้องของคำตอบ
- ก.2.2 Hallucination สำหรับตรวจจับข้อมูลที่ถูกแต่งขึ้น
- ก.2.3 Contextual Precision สำหรับประเมินคุณภาพของข้อมูลที่ค้นคืนมา
- ก.2.4 Contextual Recall สำหรับประเมินความครอบคลุมของข้อมูลที่ค้นคืนมา

การเลือกตัวชี้วัดที่เหมาะสมจะช่วยให้ผลการประเมินสะท้อนประสิทธิภาพของระบบได้อย่างถูกต้อง

### ก.3 การประเมินด้วย LLM-as-a-Judge

เมื่อได้รับข้อมูลและตัวชี้วัดที่กำหนดแล้ว DeepEval จะส่งข้อมูลเข้าสู่แบบจำลองภาษาที่ทำหน้าที่เป็นผู้ประเมิน (Evaluation Model) โมเดลผู้ประเมินจะได้รับข้อมูล เช่น คำถาม คำตอบ และบริบท จากนั้นจะวิเคราะห์ตามเกณฑ์ของตัวชี้วัดแต่ละประเภท ตัวอย่างเช่น ในการประเมิน Hallucination โมเดลจะตรวจสอบว่าข้อมูลในคำตอบสามารถอ้างอิงได้จากบริบทที่กำหนดหรือไม่ หากพบข้อมูลที่ไม่มีหลักฐานสนับสนุน คะแนนจะลดลงแนวทางดังกล่าวช่วยให้การประเมินสามารถพิจารณาความหมายของข้อความได้ดีกว่าการเปรียบเทียบข้อความแบบตรงตัว (Exact Match) หรือการนับคำที่ตรงกันเพียงอย่างเดียว

### ก.4 การคำนวณคะแนน (Score Calculation)

หลังจากกระบวนการวิเคราะห์เสร็จสิ้น DeepEval จะคำนวณคะแนนตามเกณฑ์ของแต่ละตัวชี้วัด โดยคะแนนส่วนใหญ่อยู่ในช่วง 0 ถึง 1

คะแนนใกล้ 1 หมายถึงมีคุณภาพสูง

คะแนนใกล้ 0 หมายถึงมีคุณภาพต่ำ

คะแนนที่ได้สามารถนำไปใช้เปรียบเทียบประสิทธิภาพระหว่างโมเดล ระบบ หรือชุดการตั้งค่าต่าง ๆ ได้ ตัวอย่างเช่น ในงานวิจัยเกี่ยวกับระบบ RAG อาจนำคะแนนเฉลี่ยของ Answer Relevancy,

Hallucination, Contextual Precision และ Contextual Recall มาเปรียบเทียบประสิทธิภาพของแต่ละรูปแบบการค้นคืนข้อมูลหรือแต่ละโมเดลที่ใช้สร้างคำตอบ

#### ก.5 การวิเคราะห์และสรุปผล (Result Analysis)

ขั้นตอนสุดท้ายคือการรวบรวมและวิเคราะห์ผลการประเมิน โดย DeepEval สามารถแสดงผลในรูปแบบคะแนนรายข้อ คะแนนเฉลี่ย หรือรายงานสรุปผลการประเมินทั้งหมดผลลัพธ์ที่ได้ช่วยให้นักวิจัยสามารถระบุจุดแข็งและจุดอ่อนของระบบได้อย่างชัดเจน เช่น หากระบบมีคะแนน Contextual Recall ต่ำ อาจแสดงว่าระบบค้นคืนข้อมูลสำคัญได้ไม่ครบถ้วน หรือหากมีคะแนน Hallucination ต่ำ อาจหมายถึงระบบมีแนวโน้มสร้างข้อมูลที่ไม่อยู่ในแหล่งข้อมูลอ้างอิง ดังนั้น DeepEval จึงเป็นเครื่องมือที่ช่วยให้การประเมินระบบ LLM และระบบ RAG สามารถดำเนินการได้อย่างเป็นระบบ มีมาตรฐาน และสามารถนำผลลัพธ์ไปใช้ในการปรับปรุงประสิทธิภาพของระบบได้อย่างมีประสิทธิภาพ

#### ข.ตัวชี้วัด DeepEval

DeepEval มีตัวชี้วัด (Metrics) หลายประเภทสำหรับประเมินประสิทธิภาพของระบบที่ใช้แบบจำลองภาษาขนาดใหญ่ (Large Language Models: LLMs) และระบบ Retrieval-Augmented Generation (RAG) โดยตัวชี้วัดแต่ละประเภทได้รับการออกแบบมาเพื่อวิเคราะห์คุณภาพของผลลัพธ์ในมิติที่ต่างกัน ทั้งด้านความเกี่ยวข้องของคำตอบ ความถูกต้องของข้อมูล และประสิทธิภาพของการค้นคืนข้อมูล ในงานวิจัยนี้ได้เลือกใช้ตัวชี้วัด 4 ประเภท ได้แก่ Answer Relevancy, Hallucination, Contextual Precision และ Contextual Recall ซึ่งมีรายละเอียดดังนี้

ข.1 Answer Relevancy เป็นตัวชี้วัดที่ใช้ประเมินระดับความเกี่ยวข้องระหว่างคำถามและคำตอบที่ระบบสร้างขึ้น โดยมีวัตถุประสงค์เพื่อวัดว่าคำตอบสามารถตอบสนองต่อความต้องการของผู้ใช้งานได้ตรงตามประเด็นที่ถามหรือไม่ หลักการทำงานของตัวชี้วัดนี้คือการวิเคราะห์ความสอดคล้องเชิงความหมาย (Semantic Similarity) ระหว่างคำถามและคำตอบ โดยใช้แบบจำลองภาษาทำหน้าที่ประเมินว่าคำตอบมีเนื้อหาที่เกี่ยวข้องกับคำถามมากน้อยเพียงใด หากคำตอบสามารถตอบคำถามได้ตรงประเด็น ครบถ้วน และไม่ออกนอกเรื่อง จะได้รับคะแนนในระดับสูงในทางกลับกัน หากคำตอบมีเนื้อหาที่ไม่เกี่ยวข้อง หรือตอบเพียงบางส่วน คะแนนจะลดลงตามลำดับ ตัวชี้วัด Answer Relevancy มีความสำคัญต่อระบบ RAG เนื่องจากแม้ว่าระบบจะสามารถค้นคืนข้อมูลที่ถูกต้องได้ แต่หากไม่สามารถนำข้อมูลดังกล่าวมาสร้างคำตอบที่สอดคล้องกับคำถามของผู้ใช้ ก็อาจส่งผลให้ประสิทธิภาพโดยรวมของระบบลดลง ดังนั้นตัวชี้วัดนี้จึงสะท้อนถึงคุณภาพของกระบวนการสร้างคำตอบ (Generation) โดยตรง

ข.2 Hallucination เป็นตัวชี้วัดที่ใช้ตรวจสอบว่าคำตอบที่ระบบสร้างขึ้นมีข้อมูลที่ถูกแต่งขึ้นหรือไม่มีหลักฐานสนับสนุนจากข้อมูลอ้างอิงหรือไม่ โดยคำว่า Hallucination ในบริบทของปัญญาประดิษฐ์ หมายถึงการที่แบบจำลองภาษาสร้างข้อมูลที่ดูเหมือนถูกต้อง แต่ในความเป็นจริงไม่ปรากฏอยู่ในแหล่งข้อมูลที่เกี่ยวข้องหรือไม่สามารถตรวจสอบความถูกต้องได้ หลักการประเมินของตัวชี้วัดนี้จะเปรียบเทียบเนื้อหาในคำตอบกับข้อมูลบริบท (Context) ที่ระบบค้นคืนมา หากคำตอบอ้างอิงข้อมูลที่มีอยู่จริงในบริบทและสามารถตรวจสอบได้ จะได้รับคะแนนสูง แต่หากพบ

ข้อความหรือข้อเท็จจริงที่ไม่มีอยู่ในบริบท หรือมีการสรุปข้อมูลเกินกว่าหลักฐานที่มีอยู่ คะแนนจะลดลงHallucination ถือเป็นหนึ่งในปัญหาสำคัญของระบบ LLM และ RAG เนื่องจากอาจทำให้ผู้ใช้ได้รับข้อมูลที่ไม่ถูกต้อง ดังนั้นตัวชี้วัดนี้จึงมีบทบาทสำคัญในการประเมินความน่าเชื่อถือของระบบ และช่วยลดความเสี่ยงจากการนำข้อมูลที่คลาดเคลื่อนไปใช้งานจริง

ข.3 Contextual Precision เป็นตัวชี้วัดที่ใช้ประเมินคุณภาพและความแม่นยำของข้อมูลที่ระบบค้นคืนมา (Retrieved Context) โดยมุ่งเน้นตรวจสอบว่าข้อมูลที่ถูกรetrievalมานั้นมีความเกี่ยวข้องกับคำถามมากน้อยเพียงใดหลักการของตัวชี้วัดนี้คล้ายกับแนวคิด Precision ในงานด้าน Information Retrieval ซึ่งให้ความสำคัญกับสัดส่วนของข้อมูลที่เกี่ยวข้องต่อข้อมูลทั้งหมดที่ถูกค้นคืนมา หากระบบสามารถค้นคืนเฉพาะข้อมูลที่เกี่ยวข้องกับคำถามได้เป็นส่วนใหญ่ จะได้รับคะแนนสูง แต่หากมีข้อมูลที่ไม่เกี่ยวข้องจำนวนมากปะปนอยู่ด้วย คะแนนจะลดลงตัวอย่างเช่น หากผู้ใช้งานถามเกี่ยวกับเงื่อนไขการกู้ยืมเงินเพื่อการศึกษา แต่ระบบค้นคืนเอกสารที่เกี่ยวข้องกับการสมัครทุนประเภทอื่นจำนวนมากร่วมด้วย แม้ว่าจะมีข้อมูลที่เกี่ยวข้องอยู่บางส่วน แต่คุณภาพของการค้นคืนข้อมูลจะลดลง ส่งผลให้คะแนน Contextual Precision ต่ำลงตัวชี้วัดนี้ช่วยสะท้อนประสิทธิภาพของกระบวนการค้นคืนข้อมูล (Retrieval) ว่าสามารถเลือกข้อมูลที่ตรงกับความต้องการของผู้ใช้ได้ดีเพียงใด

ข.4 Contextual Recall เป็นตัวชี้วัดที่ใช้ประเมินความครบถ้วนของข้อมูลที่ระบบค้นคืนมา โดยมุ่งเน้นตรวจสอบว่าระบบสามารถดึงข้อมูลสำคัญที่จำเป็นต่อการตอบคำถามได้ครบถ้วนหรือไม่แนวคิดของตัวชี้วัดนี้สอดคล้องกับหลักการ Recall ในงานด้าน Information Retrieval ซึ่งให้ความสำคัญกับการค้นพบข้อมูลที่เกี่ยวข้องทั้งหมด หากระบบสามารถดึงข้อมูลสำคัญที่จำเป็นต่อการตอบคำถามได้ครบถ้วน จะได้รับคะแนนสูง แต่หากข้อมูลสำคัญบางส่วนหายไป หรือไม่ได้ถูกค้นคืนมา คะแนนจะลดลงตัวอย่างเช่น หากคำตอบที่ถูกต้องจำเป็นต้องอาศัยข้อมูล 5 ประเด็น แต่ระบบสามารถค้นคืนได้เพียง 3 ประเด็น แม้ว่าข้อมูลที่ค้นคืนมาจะมีความเกี่ยวข้องทั้งหมด แต่ยั้งถือว่าขาดความครบถ้วน ส่งผลให้คะแนน Contextual Recall ลดลง Contextual Recall มีความสำคัญอย่างยิ่งต่อระบบ RAG เนื่องจากการสร้างคำตอบที่มีคุณภาพจำเป็นต้องอาศัยข้อมูลที่ครบถ้วนจากขั้นตอน Retrieval หากข้อมูลสำคัญบางส่วนไม่ถูกค้นคืนมา อาจส่งผลให้คำตอบไม่สมบูรณ์หรือคลาดเคลื่อนได้

### 2.3.15.3 Trulens (ทรูเลนส์)

เป็นเฟรมเวิร์กสำหรับการประเมินและติดตามการทำงานของระบบปัญญาประดิษฐ์ที่ใช้แบบจำลองภาษาขนาดใหญ่ (Large Language Models: LLMs) โดยได้รับการพัฒนาขึ้นเพื่อช่วยตรวจสอบคุณภาพของระบบ Retrieval-Augmented Generation (RAG) ซึ่งเป็นสถาปัตยกรรมที่ผสานการค้นคืนข้อมูลจากแหล่งความรู้ภายนอกเข้ากับการสร้างคำตอบของโมเดลภาษา TruLens มุ่งเน้นการประเมินคุณภาพของผลลัพธ์ในแต่ละขั้นตอนของกระบวนการทำงาน ตั้งแต่การค้นคืนข้อมูล การสร้างคำตอบ ไปจนถึงการวิเคราะห์ความสัมพันธ์ระหว่างคำถาม ข้อมูลที่ถูกค้นคืน และคำตอบที่สร้างขึ้น แนวคิดสำคัญของ TruLens คือการช่วยให้ผู้พัฒนาสามารถระบุสาเหตุของข้อผิดพลาดที่เกิดขึ้นภายในระบบ RAG ได้อย่างเป็นระบบ เช่น การดึงข้อมูลที่ไม่เกี่ยวข้อง การสร้างคำตอบที่ไม่ตรงกับข้อมูลอ้างอิง หรือการตอบคำถามไม่ตรงตามความต้องการของผู้ใช้งาน

ทั้งนี้ TruLens ใช้กระบวนการประเมินที่เรียกว่า RAG Triad ซึ่งเป็นกรอบแนวคิดที่ได้รับการออกแบบมาเพื่อวิเคราะห์คุณภาพของระบบ RAG โดยเฉพาะ

#### ก.หลักการทำงานของ TruLens

เริ่มต้นจากการติดตามข้อมูลที่เกิดขึ้นภายในระบบระหว่างการประมวลผล ไม่ว่าจะเป็นข้อมูลนำเข้า ข้อมูลที่ถูกเรียกใช้ในช่วงการทำงาน กระบวนการประมวลผลภายใน และผลลัพธ์ที่สร้างขึ้น โดยข้อมูลเหล่านี้จะถูกบันทึกในลักษณะของ Trace หรือ บันทึกลำดับการทำงาน ซึ่งช่วยให้สามารถตรวจสอบความสัมพันธ์ระหว่างข้อมูลนำเข้า กระบวนการประมวลผล และผลลัพธ์ได้อย่างละเอียด หลังจากรวบรวมข้อมูลแล้ว TruLens จะนำข้อมูลดังกล่าวเข้าสู่กระบวนการประเมินผลผ่านกลไกที่เรียกว่า Feedback Functions ซึ่งเป็นชุดฟังก์ชันที่ถูกออกแบบมาเพื่อวัดคุณภาพของผลลัพธ์ในมิติต่าง ๆ โดย Feedback Functions สามารถใช้แบบจำลองภาษาขนาดใหญ่เป็นผู้ประเมินผลตามแนวคิด LLM-as-a-Judge เพื่อวิเคราะห์ความสอดคล้อง ความเกี่ยวข้อง และความน่าเชื่อถือของผลลัพธ์ที่ระบบสร้างขึ้น ในการประเมินผล TruLens จะวิเคราะห์ความสัมพันธ์ระหว่างองค์ประกอบต่าง ๆ ภายในระบบ โดยพิจารณาว่าข้อมูลที่ถูกนำมาใช้ในการประมวลผลมีความเหมาะสมหรือไม่ ผลลัพธ์ที่สร้างขึ้นมีความสอดคล้องกับข้อมูลอ้างอิงหรือไม่ และผลลัพธ์สามารถตอบสนองต่อวัตถุประสงค์ของการใช้งานได้มากน้อยเพียงใด กระบวนการดังกล่าวช่วยให้สามารถประเมินคุณภาพของระบบได้ในหลายมิติ มากกว่าการพิจารณาความถูกต้องของผลลัพธ์เพียงอย่างเดียว นอกจากนี้ TruLens ยังมีความสามารถในการติดตามข้อมูลเชิงลึกเกี่ยวกับการทำงานของระบบ เช่น ลำดับขั้นตอนการประมวลผล ระยะเวลาในการตอบสนอง การเรียกใช้องค์ประกอบต่าง ๆ ภายในระบบ และผลการประเมินจากตัวชี้วัดแต่ละประเภท ข้อมูลเหล่านี้สามารถนำมาใช้วิเคราะห์ประสิทธิภาพของระบบ ปรับปรุงกระบวนการทำงาน และระบุสาเหตุของปัญหาที่อาจเกิดขึ้นได้อย่างมีประสิทธิภาพ ผลการประเมินที่ได้จาก TruLens จะถูกจัดเก็บและนำเสนอในรูปแบบของคะแนน รายงาน หรือแดชบอร์ด เพื่อช่วยให้ผู้พัฒนาหรือผู้วิจัยสามารถติดตามคุณภาพของระบบ วิเคราะห์แนวโน้มของผลลัพธ์ และเปรียบเทียบประสิทธิภาพของการตั้งค่าหรือแนวทางการพัฒนาที่แตกต่างกันได้อย่างเป็นระบบ ดังนั้น หลักการทำงานของ TruLens จึงเป็นกระบวนการที่ประกอบด้วย การติดตามข้อมูล การบันทึกลำดับการทำงาน การประเมินผลผ่านตัวชี้วัดที่กำหนด และการนำเสนอผลการวิเคราะห์ในรูปแบบที่สามารถตรวจสอบได้ ซึ่งช่วยเพิ่มความโปร่งใส ความน่าเชื่อถือ และประสิทธิภาพในการพัฒนาระบบปัญญาประดิษฐ์ที่ใช้แบบจำลองภาษาขนาดใหญ่

#### ข.ตัวชี้วัด TruLens

TruLens ใช้กรอบการประเมินที่เรียกว่า **\*\*RAG Triad\*\*** ซึ่งเป็นแนวคิดสำหรับประเมินคุณภาพของระบบ Retrieval-Augmented Generation (RAG) โดยพิจารณาความสัมพันธ์ระหว่างองค์ประกอบหลักของระบบ ได้แก่ ข้อมูลนำเข้า ข้อมูลที่ถูกค้นคืน และผลลัพธ์ที่สร้างขึ้นจากแบบจำลองภาษา กรอบการประเมินดังกล่าวประกอบด้วยตัวชี้วัดหลัก 3 ด้าน ได้แก่ Context Relevance, Groundedness และ Answer Relevance ซึ่งถูกออกแบบมาเพื่อวิเคราะห์ประสิทธิภาพของระบบในแต่ละขั้นตอนอย่างเป็นระบบ

ข.1 Context Relevance เป็นตัวชี้วัดที่ใช้ประเมินระดับความเกี่ยวข้องระหว่างข้อมูลที่ระบบค้นคืนมากับข้อมูลนำเข้าของระบบ โดยมีวัตถุประสงค์เพื่อวิเคราะห์

ประสิทธิภาพของกระบวนการค้นคืนข้อมูลว่ามีความสามารถในการเลือกข้อมูลที่มีความสัมพันธ์กับความต้องการของผู้ใช้ได้มากน้อยเพียงใด ตัวชี้วัดนี้สะท้อนคุณภาพของกระบวนการ Retrieval ซึ่งเป็นขั้นตอนสำคัญของระบบ Retrieval-Augmented Generation เนื่องจากข้อมูลที่ถูกค้นคืนมาจะถูกนำไปใช้เป็นบริบทสำหรับกระบวนการสร้างคำตอบในลำดับถัดไป คุณภาพของข้อมูลดังกล่าวจึงมีผลโดยตรงต่อประสิทธิภาพของระบบโดยรวม การที่ระบบสามารถค้นคืนข้อมูลที่มีความเกี่ยวข้องในระดับสูงย่อมช่วยเพิ่มโอกาสในการสร้างผลลัพธ์ที่มีความถูกต้องและสอดคล้องกับความต้องการของผู้ใช้ ในทางตรงกันข้าม หากข้อมูลที่ค้นคืนมาไม่มีความเกี่ยวข้องต่ำ อาจส่งผลให้คุณภาพของผลลัพธ์ลดลง แม้ว่าจะใช้แบบจำลองภาษาที่มีประสิทธิภาพสูงก็ตาม ดังนั้น Context Relevance จึงเป็นตัวชี้วัดที่ใช้ประเมินความเหมาะสมของข้อมูลที่ถูกเลือกมาใช้ในการบวนการสร้างคำตอบ และสะท้อนประสิทธิภาพของกลไกการค้นคืนข้อมูลโดยตรง

ข.2 Groundedness เป็นตัวชี้วัดที่ใช้ประเมินระดับความสอดคล้องระหว่างผลลัพธ์ที่สร้างขึ้นกับข้อมูลอ้างอิงที่ระบบใช้ในการประมวลผล โดยมุ่งเน้นการตรวจสอบว่าข้อมูลที่ปรากฏในผลลัพธ์สามารถเชื่อมโยงกลับไปยังแหล่งข้อมูลหรือบริบทที่ใช้ในการสร้างผลลัพธ์ได้หรือไม่ ตัวชี้วัดนี้มีความสำคัญต่อการประเมินความน่าเชื่อถือของระบบ เนื่องจากแบบจำลองภาษาขนาดใหญ่มีความสามารถในการสร้างข้อความใหม่จากความรู้ที่เรียนรู้มา ส่งผลให้มีโอกาสเกิดการสร้างข้อมูลที่ไม่มีแหล่งอ้างอิงรองรับได้ การประเมิน Groundedness จึงช่วยตรวจสอบว่าผลลัพธ์ที่สร้างขึ้นมีพื้นฐานมาจากข้อมูลที่ได้รับจริง หรือเป็นข้อมูลที่เกิดจากกระบวนการคาดการณ์ของแบบจำลองภาษาโดยปราศจากหลักฐานสนับสนุน Groundedness สะท้อนความสามารถของระบบในการรักษาความสอดคล้องระหว่างข้อมูลอ้างอิงและผลลัพธ์ที่สร้างขึ้น ซึ่งมีบทบาทสำคัญต่อความน่าเชื่อถือ ความถูกต้อง และความโปร่งใสของระบบปัญญาประดิษฐ์

ข.3 Answer Relevance เป็นตัวชี้วัดที่ใช้ประเมินระดับความสอดคล้องระหว่างผลลัพธ์ที่สร้างขึ้นกับวัตถุประสงค์ของข้อมูลนำเข้า โดยมุ่งเน้นการวิเคราะห์ว่าผลลัพธ์สามารถตอบสนองต่อความต้องการหรือเจตนาของผู้ใช้ได้อย่างเหมาะสมเพียงใด ตัวชี้วัดนี้สะท้อนคุณภาพของกระบวนการสร้างผลลัพธ์ (Generation Process) และแสดงถึงความสามารถของแบบจำลองภาษาในการทำความเข้าใจข้อมูลนำเข้า การตีความบริบท และการสังเคราะห์ข้อมูลเพื่อสร้างผลลัพธ์ที่มีความเกี่ยวข้องกับวัตถุประสงค์ของการใช้งาน การประเมิน Answer Relevance ให้มีความสำคัญกับความตรงประเด็น ความครบถ้วน และความสอดคล้องของผลลัพธ์ โดยไม่พิจารณาเฉพาะความสัมพันธ์กับข้อมูลอ้างอิงเพียงอย่างเดียว แต่ยังพิจารณาถึงความสามารถของผลลัพธ์ในการตอบสนองต่อเป้าหมายของการสื่อสารหรือการใช้งานอีกด้วย

#### 2.3.15.4 LLM-as-a-Judge (แอลแอลเอ็ม แอส อะ จัจจ์)

LLM-as-a-Judge เป็นแนวทางการนำแบบจำลองภาษาขนาดใหญ่ หรือ Large Language Model (LLM) มาใช้ทำหน้าที่เป็นผู้ประเมินคุณภาพของคำตอบที่สร้างขึ้นโดยระบบปัญญาประดิษฐ์ แนวทางดังกล่าวช่วยให้สามารถตรวจสอบคำตอบจำนวนมากได้โดยอัตโนมัติ โดยเฉพาะคำตอบในลักษณะปลายเปิด ซึ่งอาจมีรูปแบบการเขียนแตกต่างกัน แต่ยังคงมีความหมายถูกต้องเหมือนกัน การประเมินด้วยวิธีนี้จึงไม่ได้พิจารณาเฉพาะความเหมือนของคำหรือประโยคเท่านั้น แต่ยังสามารถพิจารณาความหมาย ความครบถ้วน และความชัดเจนของคำตอบได้ด้วย

### ก.หลักการทำงานของ LLM-as-a-Judge

เริ่มจากการนำคำถาม คำตอบที่ระบบสร้างขึ้น และข้อมูลอ้างอิงเข้าสู่แบบจำลองภาษาที่ทำหน้าที่เป็นผู้ประเมิน โดยข้อมูลอ้างอิงอาจอยู่ในรูปแบบของ Ground Truth หรือคำตอบมาตรฐานที่กำหนดไว้ล่วงหน้า จากนั้นจึงระบุเกณฑ์การประเมินอย่างชัดเจนเพื่อให้แบบจำลองใช้เป็นกรอบในการพิจารณาคุณภาพของคำตอบ เมื่อประเมินเสร็จแล้ว แบบจำลองจะคืนผลลัพธ์ในรูปแบบคะแนน คำตัดสิน หรือคำอธิบายเหตุผลประกอบ สำหรับการวิจัยนี้ ผู้วิจัยใช้ Gemini เป็นผู้ประเมินคำตอบของระบบ Retrieval-Augmented Generation (RAG) โดยกำหนดให้ประเมินคำตอบทีละข้อ และเปรียบเทียบคำตอบที่ระบบสร้างขึ้นกับ Ground Truth เท่านั้น ไม่ใช่ข้อมูลจากบริบทที่ค้นคืนมา และไม่ใช้คะแนนจาก Framework อื่นในการตัดสิน เพื่อให้คะแนนจาก Gemini เป็นผลการประเมินที่แยกออกจากเครื่องมืออื่นอย่างชัดเจน เกณฑ์การประเมินที่กำหนดประกอบด้วย 3 ด้าน ได้แก่ ความถูกต้องของคำตอบ (Accuracy) ความครบถ้วนของเนื้อหา (Completeness) และความชัดเจนของคำตอบ (Clarity) โดยแต่ละด้านมีคะแนนอยู่ในช่วง 0.0 ถึง 1.0 ความถูกต้องใช้วัดว่าคำตอบสอดคล้องกับ Ground Truth หรือไม่ ความครบถ้วนใช้วัดว่าคำตอบครอบคลุมสาระสำคัญที่ควรมีหรือไม่ และความชัดเจนใช้วัดว่าคำตอบอ่านเข้าใจง่าย กระชับ และตอบตรงคำถามหรือไม่ หลังจาก Gemini ประเมินคำตอบในแต่ละด้านแล้ว ผู้วิจัยนำคะแนนทั้งสามด้านมาคำนวณค่าเฉลี่ย เพื่อใช้เป็นคะแนนจาก LLM-as-a-Judge สำหรับคำถามแต่ละข้อ จากนั้นจึงนำคะแนนของคำถามทั้งหมดมาสรุปผลในระดับการทดลอง เช่น ค่าเฉลี่ย ส่วนเบี่ยงเบนมาตรฐาน ค่าต่ำสุด และค่าสูงสุด เพื่อใช้เปรียบเทียบประสิทธิภาพของระบบ RAG ที่มีการตั้งค่าแตกต่างกัน เช่น ขนาดของข้อความที่แบ่งเป็นส่วนย่อย และจำนวนบริบทที่ค้นคืนมารูปแบบการประเมินที่ใช้ในการวิจัยนี้สามารถเรียกได้ว่าเป็นการประเมินแบบ Pointwise Reference-based Rubric Scoring เนื่องจากการประเมินคำตอบทีละคำตอบ ใช้ Ground Truth เป็นข้อมูลอ้างอิง และกำหนดเกณฑ์การให้คะแนนไว้อย่างชัดเจน วิธีดังกล่าวเหมาะสำหรับการวิเคราะห์คุณภาพของคำตอบจากระบบ RAG เพราะสามารถเปลี่ยนผลการประเมินเชิงคุณภาพให้เป็นคะแนนเชิงปริมาณ และนำไปวิเคราะห์ทางสถิติได้

## บทที่ 3

### วิธีการดำเนินงาน

บทนี้เป็นบทที่คณะผู้จัดทำโครงการได้กล่าวถึงขั้นตอนวิธีการดำเนินการพัฒนาแชทบอทถามตอบด้วยโมเดลภาษาขนาดใหญ่ กรณีศึกษาของพัฒนานักศึกษามหาวิทยาลัยราชภัฏนครปฐม

#### 3.1 การศึกษาเบื้องต้น

จากการศึกษาเบื้องต้นพบว่า กองพัฒนานักศึกษามหาวิทยาลัยราชภัฏนครปฐม ใช้บุคลากรสำหรับการบริหารจัดการและเผยแพร่ข้อมูลข่าวสารต่าง ๆ ที่เกี่ยวข้องกับกิจกรรมนักศึกษา และการบริการสนับสนุนนักศึกษา เพื่ออำนวยความสะดวกในการสื่อสารระหว่างกองพัฒนานักศึกษากับนักศึกษา คณะอาจารย์ และบุคลากรภายในมหาวิทยาลัย โดยเผยแพร่ข่าวสารทางเว็บไซต์ของมหาวิทยาลัย หรือ ติดต่อสอบถามที่ตึกกองพัฒนานักศึกษามหาวิทยาลัยราชภัฏนครปฐม

ดังนั้น เพื่อไม่ให้นักศึกษา คณะอาจารย์ และบุคลากรภายในมหาวิทยาลัย รับข้อมูลการบริหารจัดการและเผยแพร่ข้อมูลข่าวสารต่าง ๆ ที่เกี่ยวข้องกับกิจกรรมนักศึกษา ล่าช้า หรือ อัปเดตไม่ทัน คณะผู้จัดทำโครงการได้ทำการสร้างการพัฒนาแชทบอทถามตอบด้วยโมเดลภาษาขนาดใหญ่ กรณีศึกษาของพัฒนานักศึกษามหาวิทยาลัยราชภัฏนครปฐม โดยแบ่งได้เป็น 4 กลุ่มได้แก่ กยศ.ทุนการศึกษา งานทหาร งานนักศึกษาวิชาทหาร

#### 3.2 การกำหนดความต้องการของระบบ

การกำหนดความต้องการของระบบในดำเนินการพัฒนาแชทบอทถามตอบด้วยโมเดลภาษาขนาดใหญ่ กรณีศึกษาของพัฒนานักศึกษามหาวิทยาลัยราชภัฏนครปฐม มีดังต่อไปนี้

##### 3.2.1 เก็บความต้องการของระบบ

คณะผู้จัดทำได้ศึกษาความต้องการของหน่วยงานกองพัฒนานักศึกษาและวิเคราะห์ข้อมูลที่เกี่ยวข้อง เพื่อกำหนดขอบเขตการพัฒนาระบบตอบคำถามอัตโนมัติด้วยเทคนิค Retrieval-Augmented Generation (RAG) รวมถึงกำหนดแนวทางการประเมินประสิทธิภาพของระบบด้วยชุดคำถามจำนวน 100 ข้อ และเครื่องมือประเมินผล ได้แก่ RAGAS, DeepEval, TruLens และ LLM-as-a-Judge

##### 3.2.2 ขอบเขตของระบบ

3.2.2.1 ระบบสามารถตอบคำถามเกี่ยวกับข้อมูลของกองพัฒนานักศึกษามหาวิทยาลัยราชภัฏนครปฐม ได้แก่ กองทุนเงินให้กู้ยืมเพื่อการศึกษา (กยศ.) ทุนการศึกษา งานทหาร และนักศึกษาวิชาทหาร โดยอาศัยเทคนิค Retrieval-Augmented Generation (RAG) เพื่อค้นคืนข้อมูลที่เกี่ยวข้องและสร้างคำตอบที่สอดคล้องกับบริบทของคำถาม

3.2.2.2 ระบบสามารถจัดเก็บเอกสารและข้อมูลที่เกี่ยวข้องกับกองพัฒนานักศึกษามหาวิทยาลัยราชภัฏนครปฐม เพื่อนำไปใช้เป็นแหล่งข้อมูลสำหรับการค้นคืนข้อมูลในระบบ RAG

3.2.2.3 ระบบสามารถค้นคืนข้อมูลที่เกี่ยวข้องจากฐานข้อมูลเวกเตอร์ด้วยเทคนิค Similarity Search เพื่อใช้เป็นบริบทในการสร้างคำตอบ

3.2.2.4 ระบบสามารถสร้างคำตอบโดยอาศัยข้อมูลที่ค้นคืนได้ร่วมกับโมเดลภาษาขนาดใหญ่ Google Gemini เพื่อให้คำตอบมีความถูกต้องและสอดคล้องกับบริบทของคำถาม

3.2.2.5 ระบบสามารถจัดเก็บผลลัพธ์การตอบคำถามจากชุดคำถามทดสอบจำนวน 100 ข้อ เพื่อนำไปใช้ในการประเมินประสิทธิภาพของระบบ

3.2.2.6 ระบบสามารถประเมินประสิทธิภาพการตอบคำถามด้วยเครื่องมือ RAGAS, DeepEval, TruLens และ LLM-as-a-Judge เพื่อวิเคราะห์คุณภาพของการค้นคืนข้อมูล ความสอดคล้องของคำตอบกับข้อมูลอ้างอิง ความถูกต้องของคำตอบ และประสิทธิภาพโดยรวมของระบบ Retrieval-Augmented Generation (RAG)

### 3.2.3 ซอฟต์แวร์ที่ใช้กับระบบงาน

3.2.3.1 ระบบปฏิบัติการ Microsoft Windows 10

3.2.3.2 Ollama เป็นซอฟต์แวร์ที่ใช้สำหรับประมวลผลโมเดล Embedding โดยใช้โมเดล nomic-embed-text เพื่อแปลงข้อความจากเอกสารให้อยู่ในรูปแบบเวกเตอร์ (Vector Embedding) สำหรับนำไปใช้ในการค้นคืนข้อมูลในระบบ Retrieval-Augmented Generation (RAG)

3.2.3.3 Supabase เป็นระบบฐานข้อมูลที่ใช้จัดเก็บข้อมูลเอกสาร ข้อมูลกำกับ (Metadata) และเวกเตอร์ Embedding โดยรองรับการค้นหาข้อมูลที่มีความใกล้เคียงกันด้วยเทคนิค Similarity Search ผ่านส่วนขยาย pgvector

3.2.3.4 n8n เป็นแพลตฟอร์มสำหรับออกแบบและจัดการ Workflow แบบอัตโนมัติ ทำหน้าที่เชื่อมโยงการทำงานระหว่างผู้ใช้งาน ระบบฐานข้อมูลเวกเตอร์ และโมเดลภาษาขนาดใหญ่ เพื่อให้กระบวนการตอบคำถามดำเนินการได้อย่างอัตโนมัติ

3.2.3.5 Google Gemini เป็นโมเดลภาษาขนาดใหญ่ (Large Language Model: LLM) ที่ใช้ในการสร้างคำตอบจากข้อมูลที่ค้นคืนได้จากฐานข้อมูลเวกเตอร์ เพื่อให้ผู้ใช้งานได้รับคำตอบที่ถูกต้องและสอดคล้องกับบริบทของคำถาม

3.2.3.6 LINE Messaging API ใช้เป็นช่องทางรับส่งข้อความระหว่างผู้ใช้งานและระบบตอบคำถามอัตโนมัติ โดยทำหน้าที่รับคำถามจากผู้ใช้งานและส่งคำตอบกลับผ่านแอปพลิเคชัน LINE

3.2.3.7 Hostinger คือ ผู้ให้บริการเว็บโฮสติ้ง (Web Hosting) และจดทะเบียนโดเมน (Domain Registration) ระดับสากล ให้บริการเช่าพื้นที่จัดเก็บข้อมูลเว็บไซต์และระบบออนไลน์ในรูปแบบต่าง ๆ เช่น Shared Hosting, VPS Hosting, Cloud Hosting และบริการสำหรับ WordPress

### 3.2.4 เครื่องมือที่ใช้ในการประเมินผล

3.2.4.1 RAGAS ใช้สำหรับประเมินคุณภาพของระบบ Retrieval-Augmented Generation ในด้านความเกี่ยวข้องของคำตอบ ความถูกต้องของข้อมูลอ้างอิง และประสิทธิภาพของการค้นคืนข้อมูล

3.2.4.2 DeepEval ใช้สำหรับประเมินคุณภาพคำตอบและตรวจสอบความถูกต้องของข้อมูลที่สร้างขึ้นจากโมเดลภาษาขนาดใหญ่

3.2.4.3 TruLens ใช้สำหรับประเมินประสิทธิภาพของระบบ RAG ตามแนวคิด RAG Triad ซึ่งประกอบด้วย Context Relevance, Groundedness และ Answer Relevance

3.2.4.4 LLM-as-a-Judge ใช้โมเดลภาษาขนาดใหญ่ในการประเมินคุณภาพคำตอบที่ระบบสร้างขึ้น โดยเปรียบเทียบกับคำตอบอ้างอิงและเกณฑ์การประเมินที่กำหนด


## 3.3 การออกแบบระบบ

การออกแบบระบบการพัฒนาแชทบอทถามตอบด้วยโมเดลภาษาขนาดใหญ่ กรณีศึกษาของพัฒนานักศึกษามหาวิทยาลัยราชภัฏนครปฐม

### 3.3.1 ภาพรวมการทำงานของระบบ

โดยในส่วนนี้จะเป็นการอธิบายภาพรวมการทำงานของระบบทั้งหมดและการทำงานในแต่ละส่วนของการพัฒนาแชทบอทถามตอบด้วยโมเดลภาษาขนาดใหญ่ กรณีศึกษาของพัฒนานักศึกษามหาวิทยาลัยราชภัฏนครปฐม ดังนี้

3.3.1.1 ภาพรวมการทำงานของระบบทั้งหมดที่เกี่ยวข้องกับการสร้างการพัฒนาแชทบอทถามตอบด้วยโมเดลภาษาขนาดใหญ่ กรณีศึกษาของพัฒนานักศึกษามหาวิทยาลัยราชภัฏนครปฐม โดยมีส่วนประกอบต่าง ๆ ดังนี้



ภาพที่ 3.1 ภาพรวมการทำงานของระบบ

1) ส่วนรวบรวมข้อมูล ระบบทำการรวบรวมเอกสารและข้อมูลที่เกี่ยวข้องกับกองพัฒนานักศึกษา เช่น กองทุนเงินให้กู้ยืมเพื่อการศึกษา (กยศ.) ทุนการศึกษา งานทหาร และนักศึกษาวิชาทหาร เพื่อนำมาใช้เป็นแหล่งข้อมูลสำหรับระบบตอบคำถาม

2) ส่วนเตรียมข้อมูล เอกสารที่รวบรวมได้จะถูกนำเข้าสู่กระบวนการเตรียมข้อมูล โดยทำการแบ่งข้อความออกเป็นส่วนย่อย (Chunking) เพื่อให้เหมาะสมต่อการประมวลผลและการค้นคืนข้อมูล

3) ส่วนสร้างเวกเตอร์ตัวแทนข้อความ (Embedding Model) ระบบใช้ Ollama ร่วมกับโมเดล nomic-embed-text ในการแปลงข้อความให้อยู่ในรูปแบบเวกเตอร์ (Embedding) เพื่อให้สามารถค้นหาข้อมูลที่มีความเกี่ยวข้องกันในเชิงความหมายได้อย่างมีประสิทธิภาพ

4) ส่วนจัดเก็บข้อมูล ระบบใช้ Supabase ร่วมกับส่วนขยาย pgvector สำหรับจัดเก็บข้อมูลเอกสาร ข้อมูลกำกับ (Metadata) และเวกเตอร์ Embedding เพื่อใช้เป็นแหล่งข้อมูลสำหรับการค้นคืนข้อมูล

5) ส่วนจัดการกระบวนการทำงาน (Workflow Management) ระบบใช้ n8n เป็นแพลตฟอร์มสำหรับจัดการลำดับการทำงาน โดยทำหน้าที่เชื่อมโยงกระบวนการรับคำถาม การค้นคืนข้อมูล และการสร้างคำตอบให้สามารถทำงานร่วมกันได้อย่างอัตโนมัติ

6) ส่วนค้นคืนข้อมูล (Retrieval) เมื่อระบบได้รับคำถาม ระบบจะทำการแปลงคำถามให้อยู่ในรูปแบบเวกเตอร์ และค้นคืนข้อมูลที่มีความเกี่ยวข้องจากฐานข้อมูลเวกเตอร์ด้วยเทคนิค Similarity Search เพื่อนำข้อมูลที่ค้นคืนได้มาใช้เป็นบริบทในการสร้างคำตอบ


7) ส่วนสร้างคำตอบ (Answer Generation) ระบบใช้ Google Gemini ซึ่งเป็นโมเดลภาษาขนาดใหญ่ (Large Language Model: LLM) ในการสร้างคำตอบจากคำถามร่วมกับข้อมูลที่ค้นคืนได้ เพื่อให้คำตอบมีความถูกต้อง ครบถ้วน และสอดคล้องกับบริบทของคำถาม

8) ส่วนจัดเตรียมข้อมูลสำหรับการประเมินผล (Evaluation Dataset) ผู้จัดทำจัดเตรียมชุดคำถามทดสอบจำนวน 100 ข้อ พร้อมคำตอบอ้างอิง (Ground Truth) ที่สร้างขึ้นด้วยโมเดลภาษาขนาดใหญ่และผ่านการตรวจสอบความถูกต้องจากเอกสารต้นฉบับ เพื่อใช้เป็นข้อมูลอ้างอิงในการประเมินผล

9) ส่วนประเมินประสิทธิภาพระบบ (Evaluation Framework) ผลลัพธ์ที่ได้จากการตอบคำถามของระบบจะถูกนำมาเปรียบเทียบกับคำตอบอ้างอิง (Ground Truth) และประเมินด้วยเครื่องมือ RAGAS, DeepEval, TruLens และ LLM-as-a-Judge เพื่อวิเคราะห์คุณภาพของการค้นคืนข้อมูล ความสอดคล้องของคำตอบกับข้อมูลอ้างอิง ความถูกต้องของคำตอบ และประสิทธิภาพโดยรวมของระบบ Retrieval-Augmented Generation (RAG)

### 3.3.1.2 แผนภาพกระแสข้อมูลระดับภาพรวม (Data Flow Diagram : Context Diagram)


แผนภาพกระแสข้อมูลระดับภาพรวมแสดงความสัมพันธ์ระหว่างระบบตอบคำถามอัตโนมัติด้วยโมเดลภาษาขนาดใหญ่กับแหล่งข้อมูลและเครื่องมือที่เกี่ยวข้องโดยระบบรับข้อมูลจากเอกสารของกองพัฒนานักศึกษาและชุดคำถามทดสอบจำนวน 100 ข้อ เพื่อนำมาประมวลผลและสร้างคำตอบ จากนั้นคำตอบที่ได้จะถูกส่งไปยังเครื่องมือประเมินผล ได้แก่ RAGAS, DeepEval, TruLens และ LLM-as-a-Judge เพื่อประเมินประสิทธิภาพของระบบ และสรุปผลออกมาเป็นผลการประเมินระบบ



ภาพที่ 3.2 แผนภาพกระแสข้อมูลระดับภาพรวม


### 3.3.1.3 แผนภาพกระแสข้อมูลระดับที่ 1 (Data Flow Diagram Level 1 )

แผนภาพนี้แสดงกระบวนการไหลของข้อมูลภายในระบบแชทบอทถามตอบด้วยโมเดลภาษาขนาดใหญ่ โดยเริ่มจากการนำเอกสารข้อมูลของกองพัฒนานักศึกษามาเตรียมข้อมูล แบ่งข้อความ และสร้างเวกเตอร์ตัวแทนข้อความ เพื่อจัดเก็บในฐานข้อมูลเวกเตอร์สำหรับการค้นคืนข้อมูล จากนั้นระบบจะนำชุดคำถามทดสอบจำนวน 100 ข้อเข้าสู่กระบวนการค้นคืนข้อมูลที่เกี่ยวข้องและส่งข้อมูลบริบทที่ค้นคืนได้ไปยังโมเดล Google Gemini เพื่อสร้างคำตอบตามแนวคิด Retrieval-Augmented Generation (RAG) ขณะเดียวกันระบบจะสร้างคำตอบอ้างอิง (Ground Truth) จากเอกสารต้นทางเพื่อใช้เป็นเกณฑ์ในการประเมินผล สุดท้ายคำตอบที่ระบบสร้างขึ้น ข้อมูลบริบท และคำตอบอ้างอิง จะถูกนำไปประเมินด้วยเครื่องมือ RAGAS, DeepEval, TruLens และ LLM-as-a-Judge เพื่อวิเคราะห์คุณภาพของการค้นคืนข้อมูล ความถูกต้องของคำตอบ และประสิทธิภาพโดยรวมของระบบ ก่อนสรุปออกมาเป็นผลการประเมินระบบ



ภาพที่ 3.3 แผนภาพกระแสข้อมูลระดับที่ 1

### 3.3.1.4 แผนภาพกระบวนการทำงานและการประเมินประสิทธิภาพของระบบ



ภาพที่ 3.4 แผนภาพกระบวนการทำงานและการประเมินประสิทธิภาพของระบบ

### 3.3.2 การออกแบบฐานข้อมูล (Database Design)

3.3.2.1 แผนภาพนี้แสดงโครงสร้างฐานข้อมูลของระบบตอบคำถามอัตโนมัติด้วยเทคนิค Retrieval-Augmented Generation (RAG) โดยใช้ฐานข้อมูล Supabase Vector Database สำหรับจัดเก็บข้อมูลเอกสารและเวกเตอร์ตัวแทนข้อความ ซึ่งมีรายละเอียดดังนี้

1) ตาราง Documents ใช้สำหรับจัดเก็บข้อมูลเอกสารที่นำมาใช้เป็นฐานความรู้ของระบบ โดยประกอบด้วยฟิลด์สำคัญ ได้แก่

id : ใช้สำหรับเก็บรหัสประจำเอกสาร

content : ใช้สำหรับจัดเก็บเนื้อหาของเอกสารที่ผ่านการแบ่งข้อความแล้ว

metadata : ใช้สำหรับจัดเก็บข้อมูลประกอบของเอกสาร เช่น ตำแหน่งข้อความหรือข้อมูลอ้างอิง

embedding : ใช้สำหรับจัดเก็บเวกเตอร์ตัวแทนข้อความที่สร้างจากโมเดล Embedding เพื่อรองรับการค้นคืนข้อมูล


2) ระบบใช้ฐานข้อมูลเวกเตอร์ (Vector Database) ในการจัดเก็บข้อมูล Embedding ของเอกสาร เพื่อให้สามารถค้นหาข้อมูลตามความหมายของข้อความได้อย่างมีประสิทธิภาพ

3) ฟังก์ชัน match\_documents() ใช้สำหรับค้นคืนข้อมูลที่เกี่ยวข้องกับคำถามของผู้ใช้งาน โดยรับค่าเวกเตอร์ของคำถาม (query\_embedding) และคำนวณค่าความคล้ายคลึงระหว่างคำถามกับเอกสารภายในฐานข้อมูล

4) พารามิเตอร์ match\_count ใช้กำหนดจำนวนเอกสารที่ต้องการค้นคืนจากฐานข้อมูล เพื่อนำไปใช้เป็นข้อมูลบริบทในการสร้างคำตอบ

5) พารามิเตอร์ filter ใช้สำหรับกรองข้อมูลตามเงื่อนไขที่กำหนด เพื่อให้ผลการค้นคืนข้อมูลมีความตรงกับความต้องการมากยิ่งขึ้น

6) ผลลัพธ์จากฟังก์ชัน match\_documents() จะถูกนำไปใช้ในกระบวนการ Retrieval ของระบบ RAG เพื่อดึงข้อมูลที่มีความเกี่ยวข้องมากที่สุด ก่อนส่งต่อให้โมเดลภาษาขนาดใหญ่ใช้ในการสร้างคำตอบ



ภาพที่ 3.3 แผนภาพโครงสร้างฐานข้อมูล

### 3.3.2 พจนานุกรมข้อมูล (Data Dictionary)

ตารางที่ 3.1 พจนานุกรมข้อมูลของตาราง Documents

| ลำดับ<br>(No) | คุณสมบัติ<br>(Attribute) | คำอธิบาย<br>(Description)                   | ขนาด<br>(Width) | ประเภท<br>(Type) | ประเภทคีย์<br>(Key Type) |
|---------------|--------------------------|---------------------------------------------|-----------------|------------------|--------------------------|
| 1             | id                       | รหัสประจำเอกสาร                             | 8 Bytes         | bigserial        | PK                       |
| 2             | content                  | เนื้อหาเอกสารที่ผ่านการแบ่ง<br>ข้อความ      | -               | text             | -                        |
| 3             | metadata                 | ข้อมูลประกอบของเอกสาร                       | -               | jsonb            | -                        |
| 4             | embedding                | เวกเตอร์ตัวแทนข้อความ<br>สำหรับค้นคืนข้อมูล | -               | vector(768)      | -                        |

ตารางที่ 3.2 พจนานุกรมข้อมูลของฟังก์ชัน match\_documents()

| ลำดับ<br>(No) | คุณสมบัติ<br>(Attribute) | คำอธิบาย<br>(Description)             | ขนาด<br>(Width) | ประเภท<br>(Type) | ประเภทคีย์<br>(Key Type) |
|---------------|--------------------------|---------------------------------------|-----------------|------------------|--------------------------|
| 1             | query_embedding          | เวกเตอร์ของคำถามที่ใช้<br>ค้นหาข้อมูล | 768 มิติ        | vector(768)      | -                        |
| 2             | match_count              | จำนวนเอกสารที่<br>ต้องการค้นคืน       | 11              | integer          | -                        |
| 3             | filter                   | เงื่อนไขสำหรับกรอง<br>ข้อมูล          | -               | jsonb            | -                        |

## 3.4 การพัฒนาระบบ

การพัฒนาแชทบอทถามตอบด้วยโมเดลภาษาขนาดใหญ่ กรณีศึกษาของพัฒนานักศึกษา มหาวิทยาลัยราชภัฏนครปฐม ดำเนินการโดยใช้เอกสารของกองพัฒนานักศึกษา มหาวิทยาลัยราชภัฏนครปฐม เป็นฐานความรู้ และใช้ชุดคำถามทดสอบจำนวน 100 ข้อในการทดสอบและประเมินประสิทธิภาพของแชทบอท โดยมีขั้นตอนการพัฒนาดังต่อไปนี้

### 3.4.1 การเตรียมข้อมูลเอกสาร

ผู้จัดทำรวบรวมเอกสารและข้อมูลที่เกี่ยวข้องกับกองพัฒนานักศึกษา มหาวิทยาลัยราชภัฏนครปฐม ประกอบด้วยข้อมูลด้านกองทุนเงินให้กู้ยืมเพื่อการศึกษา (กยศ.) การศึกษา งานทหาร งานกิจกรรม และนักศึกษาวิชาทหาร จากนั้นดำเนินการตรวจสอบความถูกต้องของข้อมูลและจัดเตรียมให้อยู่ในรูปแบบข้อความสำหรับใช้เป็นฐานความรู้ของระบบ

### 3.4.2 การประมวลผลคำถามเบื้องต้น (Query Preprocessing)

ก่อนเข้าสู่กระบวนการค้นคืนข้อมูล ระบบจะดำเนินการประมวลผลคำถามเบื้องต้น (Query Preprocessing) เพื่อปรับปรุงคุณภาพของคำถามและเพิ่มประสิทธิภาพในการค้นคืนข้อมูล

โดยประกอบด้วยขั้นตอนดังต่อไปนี้ การทำความสะอาดข้อมูล (Query Cleaning) เป็นการตรวจสอบและลบอักขระหรือข้อมูลที่ไม่จำเป็นออกจากคำถาม การปรับรูปแบบข้อมูล (Normalization) เป็นการปรับรูปแบบข้อความให้อยู่ในรูปแบบมาตรฐาน เพื่อให้สามารถประมวลผลได้อย่างมีประสิทธิภาพ การปรับปรุงคำถาม (Query Reformulation) เป็นการปรับรูปแบบหรือโครงสร้างของคำถามให้มีความชัดเจนและเหมาะสมสำหรับกระบวนการค้นคืนข้อมูล กระบวนการดังกล่าวช่วยให้ระบบสามารถค้นคืนข้อมูลที่เกี่ยวข้องกับคำถามได้อย่างมีประสิทธิภาพมากยิ่งขึ้น และส่งผลต่อคุณภาพของคำตอบที่สร้างขึ้นในขั้นตอนถัดไป

#### 3.4.3 การแบ่งข้อความ (Chunking)

ข้อมูลเอกสารที่ผ่านการเตรียมข้อมูลแล้วถูกแบ่งออกเป็นส่วนย่อย (Chunk) เพื่อให้เหมาะสมกับกระบวนการสร้างเวกเตอร์ตัวแทนข้อความและการค้นคืนข้อมูล โดยในการวิจัยนี้ได้กำหนดค่าพารามิเตอร์สำหรับการทดลองจำนวน 2 ค่า ได้แก่ Chunk Size เท่ากับ 256 และ 512 และกำหนดค่า Chunk Overlap เท่ากับ 64 และ 128 เพื่อศึกษาผลกระทบของขนาดข้อความต่อประสิทธิภาพของระบบ

#### 3.4.4 การสร้างเวกเตอร์ตัวแทนข้อความ (Embedding)

หลังจากแบ่งข้อความแล้ว ระบบจะใช้ Ollama ร่วมกับโมเดล nomic-embed-text ในการแปลงข้อความให้อยู่ในรูปแบบเวกเตอร์ (Embedding) ซึ่งเป็นการแทนความหมายของข้อความในรูปแบบเชิงตัวเลข เพื่อให้สามารถนำไปใช้ในการค้นคืนข้อมูลตามความหมายของข้อความได้

#### 3.4.5 การจัดเก็บข้อมูลในฐานข้อมูลเวกเตอร์

เวกเตอร์ที่ได้จากกระบวนการ Embedding จะถูกจัดเก็บลงในฐานข้อมูลเวกเตอร์ Supabase Vector Database โดยภายในฐานข้อมูลจะจัดเก็บข้อมูลเอกสาร ข้อมูลประกอบ (Metadata) และเวกเตอร์ตัวแทนข้อความ เพื่รองรับการค้นคืนข้อมูลด้วยเทคนิค Similarity Search

#### 3.4.6 การค้นคืนข้อมูล (Retrieval)

ผู้จัดทำใช้ชุดคำถามทดสอบจำนวน 100 ข้อเป็นข้อมูลนำเข้าสู่ระบบ โดยระบบจะทำการแปลงคำถามให้อยู่ในรูปแบบเวกเตอร์และค้นคืนข้อมูลที่เกี่ยวข้องจากฐานข้อมูลเวกเตอร์ด้วยเทคนิค Similarity Search ผู้จัดทำกำหนดค่าพารามิเตอร์ Top-K จำนวน 2 ค่า ได้แก่ 3 และ 5 เพื่อใช้เปรียบเทียบประสิทธิภาพของการค้นคืนข้อมูล โดยค่า Top-K หมายถึงจำนวนข้อความหรือเอกสารที่มีความเกี่ยวข้องกับคำถามมากที่สุดที่ระบบจะนำมาใช้เป็นข้อมูลบริบทสำหรับการสร้างคำตอบ

#### 3.4.7 การเพิ่มข้อมูลบริบทในคำสั่ง (Prompt Augmentation)

หลังจากระบบค้นคืนข้อมูลที่เกี่ยวข้องจากฐานข้อมูลเวกเตอร์แล้ว ข้อมูลบริบทที่ค้นคืนได้จะถูกนำมาประกอบเข้ากับคำถาม เพื่อสร้างคำสั่ง (Prompt) สำหรับส่งให้โมเดลภาษาขนาดใหญ่ Google Gemini ในการสร้างคำตอบ กระบวนการ Prompt Augmentation เป็นส่วนสำคัญของเทคนิค Retrieval-Augmented Generation (RAG) เนื่องจากช่วยให้โมเดลสามารถอ้างอิงข้อมูลจากเอกสารต้นทางที่ค้นคืนได้จริง ทำให้คำตอบมีความถูกต้อง สอดคล้องกับบริบท และลดโอกาสใน

การสร้างข้อมูลที่ไม่ตรงกับแหล่งข้อมูลอ้างอิง ข้อมูลบริบทที่ถูกเพิ่มเข้าไปใน Prompt จะมาจากผลลัพธ์การค้นคืนข้อมูลด้วยเทคนิค Similarity Search ตามค่า Top-K ที่กำหนดในการทดลอง

#### 3.4.8 การพัฒนาเวิร์กโฟลว์ด้วยเอ็นเอทีเอ็น

ผู้จัดทำใช้เครื่องมือ เอ็นเอทีเอ็น ในการออกแบบและควบคุมลำดับการทำงานของระบบ โดยทำหน้าที่เชื่อมต่อระหว่างฐานข้อมูลเวกเตอร์ กระบวนการค้นคืนข้อมูล และโมเดลภาษาขนาดใหญ่ เพื่อให้สามารถดำเนินกระบวนการตอบคำถามได้โดยอัตโนมัติ

#### 3.4.8 การสร้างคำตอบด้วยโมเดลภาษาขนาดใหญ่

ระบบใช้ Google Gemini เป็นโมเดลภาษาขนาดใหญ่ในการสร้างคำตอบ โดยนำคำถามทดสอบและข้อมูลบริบทที่ค้นคืนได้จากฐานข้อมูลเวกเตอร์มาประกอบกันตามแนวคิด Retrieval-Augmented Generation (RAG) เพื่อสร้างคำตอบที่มีความถูกต้องและสอดคล้องกับข้อมูลอ้างอิง

#### 3.4.9 การสร้างกราวด์ทรูอัตโนมัติ

ผู้จัดทำใช้ชุดคำถามทดสอบจำนวน 100 ข้อร่วมกับข้อมูลเอกสารต้นทางในการสร้างคำตอบอ้างอิง (Ground Truth) โดยใช้โมเดลภาษาขนาดใหญ่ในการสร้างคำตอบอัตโนมัติจากข้อมูลเอกสารต้นทางที่กำหนดเป็นบริบท เพื่อใช้เป็นคำตอบอ้างอิงสำหรับการประเมินประสิทธิภาพของระบบ

#### 3.4.10 การประเมินประสิทธิภาพของระบบ

คำตอบที่ได้จากระบบสำหรับชุดคำถามทดสอบจำนวน 100 ข้อ และคำตอบอ้างอิง (Ground Truth) ถูกนำมาประเมินประสิทธิภาพโดยใช้เครื่องมือ RAGAS, DeepEval, TruLens และ LLM-as-a-Judge เพื่อวิเคราะห์คุณภาพของการค้นคืนข้อมูล ความเกี่ยวข้องของข้อมูลบริบท ความถูกต้องของคำตอบ ความสอดคล้องกับข้อมูลอ้างอิง และประสิทธิภาพโดยรวมของแชทบอทถามตอบด้วยโมเดลภาษาขนาดใหญ่

### 3.5 การทดสอบระบบ

ในการศึกษาและการพัฒนาระบบแชทบอทถามตอบด้วยโมเดลภาษาขนาดใหญ่ กรณีศึกษากองพัฒนานักศึกษามหาวิทยาลัยราชภัฏนครปฐมนั้น ผู้พัฒนาระบบได้มีการออกแบบขั้นตอนการทดสอบระบบ ดังต่อไปนี้

#### 3.5.1 ชุดคำถามทดสอบ

ผู้จัดทำจัดเตรียมชุดคำถามทดสอบจำนวน 100 ข้อ เพื่อใช้ในการทดสอบและประเมินประสิทธิภาพของระบบ โดยคำถามถูกออกแบบให้ครอบคลุมเนื้อหาสำคัญของกองพัฒนานักศึกษา และใช้เป็นชุดข้อมูลเดียวกันในการทดสอบทุกชุดการทดลอง เพื่อให้สามารถเปรียบเทียบผลลัพธ์ได้

#### 3.5.2 การกำหนดค่าการทดลอง

ผู้จัดทำได้กำหนดชุดการทดลองจำนวน 8 รูปแบบ โดยปรับค่าพารามิเตอร์ที่เกี่ยวข้องกับกระบวนการจัดเตรียมข้อมูลและการค้นคืนข้อมูล ได้แก่ Chunk Size, Chunk Overlap และ Top-K เพื่อศึกษาผลกระทบของค่าพารามิเตอร์ดังกล่าวต่อประสิทธิภาพของระบบ Retrieval-Augmented Generation (RAG) ในการทดลอง กำหนดค่า Chunk Size จำนวน 2 ระดับ ได้แก่

256 และ 512 ซึ่งใช้สำหรับกำหนดขนาดของข้อความในแต่ละส่วนย่อยของเอกสาร ส่วน Chunk Overlap กำหนดจำนวน 2 ระดับ ได้แก่ 64 และ 128 เพื่อศึกษาผลของการซ้อนทับของเนื้อหา ระหว่างข้อความแต่ละส่วน และกำหนดค่า Top-K จำนวน 2 ระดับ ได้แก่ 3 และ 5 ซึ่งเป็นจำนวน ข้อมูลหรือบริบทที่ระบบเลือกจากฐานข้อมูลเวกเตอร์เพื่อนำมาใช้ประกอบการสร้างคำตอบ การ กำหนดค่าดังกล่าวทำให้เกิดชุดการทดลองทั้งหมด 8 รูปแบบ โดยมีการผสมค่าพารามิเตอร์ที่แตกต่าง กัน ดังแสดงในตารางที่ 3.3 ทั้งนี้ ในแต่ละการทดลองใช้ ชุดคำถามทดสอบจำนวน 100 คำถามชุด เดียวกัน เพื่อให้ผลการทดลองสามารถนำมาเปรียบเทียบกันได้อย่างเหมาะสม และลดผลกระทบจาก ความแตกต่างของชุดคำถามที่ใช้ในการทดสอบ

**ตารางที่ 3.3** การกำหนดค่าพารามิเตอร์สำหรับการทดลอง

| Exp   | Chunk Size | Chunk Overlap | Top-K |
|-------|------------|---------------|-------|
| Exp 1 | 256        | 64            | 3     |
| Exp 2 | 256        | 64            | 5     |
| Exp 3 | 256        | 128           | 3     |
| Exp 4 | 256        | 128           | 5     |
| Exp 5 | 512        | 64            | 3     |
| Exp 6 | 512        | 64            | 5     |
| Exp 7 | 512        | 128           | 3     |
| Exp 8 | 512        | 128           | 5     |

### 3.5.3 ขั้นตอนการทดสอบระบบ

3.5.3.1 เตรียมเอกสารต้นทางและดำเนินการแบ่งข้อความตามค่าที่กำหนดในแต่ละชุดการทดลอง

3.5.3.2 สร้างเวกเตอร์ตัวแทนข้อความด้วยโมเดล nomic-embed-text ผ่าน Ollama

3.5.3.3 จัดเก็บข้อมูลและเวกเตอร์ตัวแทนข้อความลงใน Supabase Vector Database

3.5.3.4 นำชุดคำถามทดสอบจำนวน 100 ข้อเข้าสู่ระบบ

3.5.3.5 ค้นคืนข้อมูลที่เกี่ยวข้องจากฐานข้อมูลเวกเตอร์ด้วยเทคนิค Similarity Search ตามค่า Top-K ที่กำหนด

3.5.3.6 ส่งข้อมูลบริบทที่ค้นคืนได้ไปยัง Google Gemini เพื่อสร้างคำตอบ

3.5.3.7 สร้างคำตอบอ้างอิง (Ground Truth) จากข้อมูลเอกสารต้นทาง

3.5.3.8 บันทึกผลลัพธ์ที่ได้จากแต่ละชุดการทดลองเพื่อนำไปประเมินประสิทธิภาพในขั้นตอนถัดไป

### 3.5.4 เครื่องมือที่ใช้ในการทดสอบระบบ

3.5.4.1 Ollama Embedding : nomic-embed-text

#### 3.5.4.2 Supabase Vector Database

#### 3.5.4.3 Google Gemini

#### 3.5.4.4 RAGAS

#### 3.5.4.5 DeepEval

#### 3.5.4.6 TruLens

#### 3.5.4.7 LLM-as-a-Judge

### 3.6 การประเมินประสิทธิภาพของระบบ

จากการดำเนินการทดสอบระบบด้วยชุดคำถามจำนวน 100 ข้อแล้ว ผู้จัดทำได้นำผลลัพธ์ที่ได้จากระบบมาประเมินประสิทธิภาพ เพื่อวิเคราะห์คุณภาพของการค้นคืนข้อมูลและความถูกต้องของคำตอบที่สร้างขึ้น โดยใช้เครื่องมือประเมินผลหลายรูปแบบ ได้แก่ RAGAS, DeepEval, TruLens และ LLM-as-a-Judge ซึ่งสามารถประเมินได้ทั้งด้านความเกี่ยวข้องของข้อมูลบริบท ความถูกต้องของคำตอบ และคุณภาพโดยรวมของระบบตอบคำถามด้วยเทคนิค Retrieval-Augmented Generation (RAG)

#### 3.6.1 การประเมินด้วย RAGAS

RAGAS เป็นเฟรมเวิร์กสำหรับประเมินประสิทธิภาพของระบบ Retrieval-Augmented Generation (RAG) โดยมุ่งเน้นการวิเคราะห์คุณภาพของข้อมูลที่ค้นคืนได้และคำตอบที่สร้างขึ้น ในการวิจัยครั้งนี้ใช้ตัวชี้วัดดังต่อไปนี้

Answer Relevancy : ประเมินความเกี่ยวข้องระหว่างคำถามและคำตอบที่ระบบสร้างขึ้น

Faithfulness : ประเมินว่าคำตอบที่สร้างขึ้นสอดคล้องกับข้อมูลบริบทที่ค้นคืนมาเพียงใด

Context Precision : ประเมินความแม่นยำของข้อมูลบริบทที่ถูกค้นคืน

Context Recall : ประเมินความสามารถในการค้นคืนข้อมูลสำคัญที่เกี่ยวข้องกับคำถาม

#### 3.6.2 การประเมินด้วย DeepEval

DeepEval เป็นเครื่องมือประเมินคุณภาพของระบบตอบคำถามที่ใช้โมเดลภาษาขนาดใหญ่ โดยสามารถประเมินคุณภาพของคำตอบและข้อมูลบริบทได้ ในการวิจัยครั้งนี้ใช้ตัวชี้วัดดังต่อไปนี้

Answer Relevancy : ประเมินความเกี่ยวข้องของคำตอบกับคำถาม

Hallucination : ประเมินการสร้างข้อมูลที่ไม่สอดคล้องกับข้อมูลอ้างอิงหรือข้อมูลบริบท

Contextual Precision : ประเมินความแม่นยำของข้อมูลบริบทที่ค้นคืนได้

Contextual Recall : ประเมินความครบถ้วนของข้อมูลบริบทที่ค้นคืนได้

### 3.6.3 การประเมินด้วย TruLens

TruLens เป็นเครื่องมือสำหรับประเมินและตรวจสอบคุณภาพของระบบ Retrieval-Augmented Generation (RAG) โดยใช้แนวคิด RAG Triad ในการประเมิน ซึ่งประกอบด้วย

Context Relevance : ประเมินความเกี่ยวข้องระหว่างคำถามและข้อมูลบริบทที่ค้นคืนได้

Groundedness : ประเมินว่าคำตอบที่สร้างขึ้นมีพื้นฐานมาจากข้อมูลบริบทมากน้อยเพียงใด

Answer Relevance : ประเมินความเกี่ยวข้องระหว่างคำถามและคำตอบที่ระบบสร้างขึ้น

### 3.6.4 การประเมินด้วย LLM-as-a-Judge

LLM-as-a-Judge เป็นแนวทางการประเมินที่ใช้โมเดลภาษาขนาดใหญ่ทำหน้าที่เป็นผู้ประเมิน โดยเปรียบเทียบคำตอบที่ระบบสร้างขึ้นกับคำตอบอ้างอิง (Ground Truth) และข้อมูลบริบทที่ค้นคืนได้ เพื่อวิเคราะห์คุณภาพของคำตอบในด้านความถูกต้อง ความครบถ้วน ความสอดคล้องกับข้อมูลอ้างอิง และความเหมาะสมของคำตอบที่สร้างขึ้น

### 3.6.5 การวิเคราะห์ผลทางสถิติ

หลังจากได้รับผลการประเมินจากเครื่องมือ RAGAS, DeepEval, TruLens และ LLM-as-a-Judge แล้ว ผู้วิจัยได้ดำเนินการวิเคราะห์ผลทางสถิติเพื่อสรุปและเปรียบเทียบประสิทธิภาพของระบบในแต่ละชุดการทดลอง

การวิเคราะห์ผลทางสถิติประกอบด้วย

1) ค่าเฉลี่ย (Mean) ใช้สำหรับสรุปแนวโน้มโดยรวมของคะแนนประเมินที่ได้รับจากแต่ละเครื่องมือ

2) ส่วนเบี่ยงเบนมาตรฐาน (Standard Deviation: SD) ใช้สำหรับวิเคราะห์การกระจายตัวของคะแนนประเมินในแต่ละชุดการทดลอง

3) ค่าสหสัมพันธ์ (Correlation) ใช้สำหรับวิเคราะห์ความสัมพันธ์ระหว่างผลการประเมินที่ได้จากเครื่องมือแต่ละประเภท

4) ความสอดคล้องของผลการประเมิน (Consistency) ใช้สำหรับตรวจสอบความสม่ำเสมอของผลลัพธ์ที่ได้จากเครื่องมือประเมินหลายรูปแบบ

## บทที่ 4

### ผลการศึกษา


บทนี้เป็นการนำเสนอผลการดำเนินงานของการพัฒนาแชทบอทถามตอบด้วยโมเดลภาษาขนาดใหญ่กรณีศึกษาของพัฒนานักศึกษามหาวิทยาลัยราชภัฏนครปฐม

#### 4.1 ผลการศึกษา

จากการดำเนินงานวิเคราะห์และออกแบบระบบดำเนินการพัฒนาแชทบอทถามตอบด้วยโมเดลภาษาขนาดใหญ่ กรณีศึกษาของพัฒนานักศึกษามหาวิทยาลัยราชภัฏนครปฐม โดยมีองค์ประกอบดังนี้


##### 4.2.1 การเชื่อมต่อ Webhook กับ Line ใน N8N

##### 4.2.1.1 ในตอนขึ้นแรกทำการเข้าสู่ระบบ N8N โดยใส่ อีเมล และ รหัสผ่าน




ภาพที่ 4.1 หน้าล็อกอินเอ็นเอทเอ็น

##### 4.2.1.2 เมื่อเข้าสู่ระบบให้ทำการกดสร้าง Create workflow มุมบนขวามือ




ภาพที่ 4.2 การสร้างเวิร์กโฟลว์

4.2.1.3 ทำการกด Add first step จากนั้นค้นหาคำว่า Webhook แล้วเปลี่ยน HTTP Method จาก GET เป็น POST เพื่อให้ระบบสามารถรับข้อมูลที่ถูกส่งเข้ามาในรูปแบบ Request Body ได้ เช่น ข้อความจาก LINE Messaging API หรือข้อมูลจากระบบภายนอกอื่น ๆ



ภาพที่ 4.3 การตั้งค่าเว็บฮุก


4.2.1.4 ในขั้นตอนถัดไปทำการเข้า Line Developers และล็อกอินเข้าสู่ระบบมุมบนขวามือและทำตามขั้นตอนที่แสดงขึ้น



ภาพที่ 4.4 หน้าเว็บไลน์เดเวลอปเปอร์  
ที่มา: <https://developers.line.biz/en/>


ใหม่

#### 4.2.1.5 เมื่อเข้าสู่หน้าต่งนี้ให้ทำการกด Create a new provider สร้างผู้ให้บริการ




ภาพที่ 4.5 การสร้างโปรไวเดอร์

#### 4.2.1.6 ถัดมาสร้างชื่อที่ต้องการและกด Create




ภาพที่ 4.6 การสร้างชื่อโปรไวเดอร์

#### 4.2.1.7 เมื่อเข้ามาสู่หน้านี้ให้ทำการเลือก Create a Messaging API channel สร้างช่องทาง API สำหรับการส่งข้อความ



ภาพที่ 4.7 การสร้างเอพีไอ

#### 4.2.1.8 เมื่อเลือก Create a Messaging API channel สร้างช่องทาง API สำหรับการส่งข้อความ ให้ทำการกดสร้างบัญชีอย่างเป็นทางการ และทำตามขั้นตอนที่แสดงขึ้น



ภาพที่ 4.8 เลือกแชนแนลเอพีไอที่ต้องการ

#### 4.2.1.9 หลังจากสร้างบัญชีอย่างเป็นทางการ ให้กรอกรายละเอียดดังภาพ

**สร้าง LINE ออฟฟิเชียลแอคเคาท์**

ข้อมูลการเข้าสู่ระบบ

ชื่อผู้ใช้: **เริ่มใหม่ ลอกรหัสผ่าน**

ประเทศที่ใช้บริการ: **ไทย** คุณสมารถเลือกไม่แสดงส่วนข้อมูลไทย

ข้อมูลบัญชี

ชื่อบัญชี: **Test LLM** 8/20  
ชื่อจะแสดงในรายชื่อของ LINE และขอทำางเลข

อีเมล: **gameminkung3@gmail.com** 23/240

ประเทศที่ให้บริการ & ธุรกิจ: **ไทย**  
ประเทศที่ให้บริการและธุรกิจของคุณจะแสดงในรายชื่อของ LINE และขอทำางเลข

ชื่อบริษัท/ธุรกิจ: **Test LLM** 8/100

ประเภทธุรกิจ: **หน่วยงานราชการ** **หน่วยงานราชการ**

คลิกเพื่อดูการให้บริการ LINE Official Account

ภาพที่ 4.9 กรอกข้อมูลเพื่อสร้างบัญชี

#### 4.2.1.10 เมื่อกรอกรายละเอียดทุกอย่างเสร็จสิ้น กดคำว่า ภายหลัง เพื่อไปสู่นำต่างถัดไป

**ข้อมูลบัญชี**

ชื่อบัญชี: **Test LLM**

ประเภทธุรกิจ: **หน่วยงานราชการ · หน่วยงานราชการ**

เบส ID: **@144wedpu**

**ใช้ฟิเจอร์ได้มากยิ่งขึ้น ด้วยบัญชีรับรอง**

เพียงขอรับรองบัญชี คุณก็จะใช้ฟิเจอร์พิเศษต่างๆ ที่เต็มไปด้วยความสะดวกสำหรับบัญชีทางการของบริษัทและธุรกิจส่วนตัว

ได้รับป้ายรับรองบัญชี

ค้นหาบัญชีได้ในแอป LINE

ใช้ไอเทมที่มีส่วนลดแอดเดอ LINE ได้

**ขอรับรองบัญชี**


**ภายหลัง (ไปหน้าจอ Manager)**

\* หากไม่ต้องการขอรับรองบัญชี ขอให้เข้าสู่ระบบ LINE Official Account Manager เพื่อให้บริการ

\* บัญชีที่ถูกลบทิ้งไปไม่สามารถขอรับรองบัญชีได้

ภาพที่ 4.10 เมื่อสมัครเสร็จสิ้นทำการกดภายหลัง

4.2.1.11 เข้าสู่หน้านี้ทำการคลิกคำว่า แชท แถบเมนู 6 แถบ เข้าสู่ตั้งค่าการตอบกลับ



ภาพที่ 4.11 หน้าเมนูไลน์เดเวลอปเปอร์

4.2.1.12 ถัดมาทำการเปิดหน้าจอตั่งค่า Messaging API ในหัวข้อ Webhook เพื่อเปิดใช้งาน คลิกคำว่า ใช้ Messaging API ตั้งชื่อตามที่ต้องการและทำตามขั้นตอน เมื่อเสร็จสิ้นจะได้ดังภาพ

### Messaging API

Messaging API คือฟังก์ชันขั้นสูงสำหรับนักพัฒนา ที่ช่วยให้นักพัฒนาสามารถโปรโมทด้วยการสื่อสารแบบอินเทอร์แอคทีฟได้มากขึ้น โดยการรับส่งข้อความและแนกชั้นผ่าน API

[Messaging API คืออะไร](#)


[เอกสารเกี่ยวกับ API ของ LINE Developers](#)

| สถานะ         | กำลังใช้งาน                                                                                                                                                                   |
|---------------|-------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| ข้อมูลแชนแนล  | <div> <div>แชนแนล ID</div> <div>2010076867</div> <div>คัดลอก</div> </div> <div> <div>ความลับแชนแนล</div> <div>672d162427f9c6cc946922e6443e2ab1</div> <div>คัดลอก</div> </div> |
| ลิงก์ Webhook | <div> <div>https://</div> <div>บันทึก</div> </div>                                                                                                                            |

ตั้งค่าเพิ่มเติมได้ที่ [LINE Developers Console](#)

ภาพที่ 4.12 หน้าตั้งค่าแมสเสจจิงเอพีโอ

4.2.1.13 จากนั้นไปทำการ Copy ลิงก์ Webhook ใน N8N คลิกที่ Webhook 2 ครั้ง หน้าต่างจะขึ้นมามีภาพไปที่หัวข้อ Webhook URLs ที่แสดงขึ้นมา นำลิงก์ไปใส่ใน Line Messaging API



ภาพที่ 4.13 คัดลอกเว็บฮุกยูอาแอลจากเอ็นเอทเอ็น


4.2.1.14 หลังจากทำการ Copy ลิงก์ ไปใส่ใน Line Messaging API ถือว่าเป็นอันเสร็จสิ้น เป็นการเชื่อมต่อ Webhook กับ Line ใน N8N Webhook จำเป็นเพื่อให้ LINE ส่งข้อความของผู้ใช้มายังระบบเราแบบอัตโนมัติ ทำให้บอทสามารถรับข้อมูล ประมวลผล (เช่น AI / RAG) และตอบกลับได้ หากไม่มี Webhook บอทจะไม่สามารถทำงานอัตโนมัติได้



ภาพที่ 4.14 เว็บฮุกยูอาแอลจากเอ็นเอทเอ็น

## 4.2.2 การสร้างระบบและขั้นตอนการตั้งค่า Line Chatbot ใน N8N

4.2.2.1 หน้าที่คือภาพรวมระบบในการสร้าง Line Chatbot เชื่อมต่อกระบวนการทำงานอัตโนมัติ (Workflow) เพื่อกำหนดลำดับการทำงานของระบบ เช่น การรับข้อมูล การประมวลผลด้วย AI การค้นหาข้อมูล และการส่งผลลัพธ์กลับไปยังผู้ใช้งาน




ภาพที่ 4.15 ภาพรวมระบบการสร้างไลน์แชทบอท

4.2.2.2 ในขั้นตอนนี้คือหน้าตั้งค่า Edit Fields Node ที่ต่อมาจาก Webhook ใช้สำหรับแก้ไข จัดรูปแบบ หรือสร้างข้อมูลใหม่ก่อนส่งต่อไปยังขั้นตอนถัดไปใน Workflow โดยในภาพกำลังกำหนดข้อมูลรูปแบบ JSON เพื่อดึงค่าจาก Webhook เช่น user\_id, sender\_id และข้อความของผู้ใช้ เพื่อนำไปประมวลผลต่อในระบบ AI Chatbot โดยใช้ดังนี้


```
{
  "user_id": {{
    JSON.stringify($json.body.events[0].source.userId) }}
  "sender_id": {{
    JSON.stringify($json.body.events[0].replyToken) }}
  "message": {{
    JSON.stringify($json.body.events[0].message.text) }}
}
```

ภาพที่ 4.16 หน้าตั้งค่าอีดิทฟิลด์



ภาพที่ 4.17 หน้าตั้งค่าอีดีทไฟลด์

4.2.2.3 หน้าตั้งค่า AI Agent Node ใน n8n ใช้สำหรับกำหนดบทบาทและคำสั่งให้ระบบปัญญาประดิษฐ์ (AI) ทำงานตามเงื่อนไขที่กำหนด โดยสามารถกำหนด Prompt และ System Message เพื่อควบคุมรูปแบบการตอบของ AI เช่น การตอบคำถามของผู้ใช้งาน การค้นหาข้อมูลจากฐานข้อมูล และการสร้างคำตอบให้เหมาะสมกับงานของระบบ Chatbot



ภาพที่ 4.18 หน้าตั้งค่าเอไอเอเจนต์

คุณคือผู้ช่วยตอบแชทอย่างเป็นทางการของกองพัฒนานักศึกษา มหาวิทยาลัยราชภัฏนครปฐม  
หน้าที่ของคุณคือช่วยตอบคำถามของนักศึกษาและผู้ติดต่อ โดยใช้ข้อมูลที่ถูกต้องจากระบบของมหาวิทยาลัยเท่านั้น และห้ามแต่ง  
ข้อมูลเกินจริงครับ

ข้อความจากผู้ใช้: `{{ \$json.message }}`

ขั้นตอนการทำงาน :

#### 1. วิเคราะห์และทำความเข้าใจคำถาม

- \* ตรวจสอบคำสะกดหรือข้อความที่พิมพ์ผิด แล้วปรับให้อีกครั้งโดยคงความหมายเดิมครับ
- \* ตีความคำถามให้เกี่ยวข้องกับงานของกองพัฒนานักศึกษา เช่น :

- \* กยศ.
- \* ผ่อนผันทหาร
- \* นักศึกษาวิชาทหาร (รด.)
- \*ทุนการศึกษา

#### 2. ตรวจสอบข้อมูลก่อนตอบทุกครั้ง

- \* ใช้คำถามที่ปรับแล้วค้นหาข้อมูลจากฐานข้อมูลของกองพัฒนานักศึกษาก่อนทุกครั้งครับ
- \* หากพบข้อมูลที่ตรงกัน ให้ตอบโดยอ้างอิงจากข้อมูลนั้นเท่านั้นครับ
- \* หากไม่พบข้อมูลตรง ให้ค้นหาข้อมูลที่ใกล้เคียงที่สุดแล้วตรวจสอบความเกี่ยวข้องก่อนตอบครับ

#### 3. รูปแบบการตอบ

- \* ตอบด้วยภาษาสุภาพ อ่านง่าย เป็นธรรมชาติ เหมือนเจ้าหน้าที่ตอบแชทจริงครับ
- \* เรียบเรียงคำตอบใหม่ให้อ่านสั้นไหล แต่ห้ามเปลี่ยนความหมายของข้อมูลครับ
- \* หากมีขั้นตอนหรือข้อมูลสำคัญ ให้เว้นบรรทัดเพื่อให้อ่านง่ายครับ
- \* สามารถใช้อีโมจิเล็กน้อยได้หากเหมาะสมครับ
- \* ปิดท้ายข้อความด้วยคำว่า "ครับ" ทุกครั้งครับ

ภาพที่ 4.19 พรอมที่ใช้ตั้งค่าเอไอเอเงิน

#### 4. กฎสำคัญในการตอบ


- \* ❌ ห้ามเดา หรือแต่งข้อมูลที่ไม่มีอยู่จริงครับ
- \* ❌ ห้ามตอบจากความรู้ทั่วไป หากไม่มีข้อมูลรองรับครับ
- \* ❌ ห้ามเอ่ยถึงชื่อฐานข้อมูล ระบบค้นหา หรือกระบวนการทำงานเบื้องหลังครับ
- \* ? หากคำถามไม่เกี่ยวข้องกับกองพัฒนานักศึกษา ให้ตอบว่า:  
"ขอภัยในความไม่สะดวกครับ"
- \* ✅ หากไม่พบข้อมูล ให้ตอบว่า:  
"ขอทวนคำถามอีกครั้งได้ไหมครับ  
กองพัฒนานักศึกษาดูแลด้าน กยศ. ผ่อนผันทหาร ทุนการศึกษา และกิจกรรมนักศึกษาครับ"
- \* ? หากข้อมูลยังไม่ชัดเจน หรือมีหลายกรณี ให้สอบถามเพิ่มเติมอย่างสุภาพครับ

ภาพที่ 4.20 พรอมที่ใช้ตั้งค่าเอไอเอเงิน



ภาพที่ 4.21 กฎพร้อมที่ใช้ตั้งค่าเอไอเอเจนต์

4.2.2.4 หน้าตั้งค่า Code Node ใน n8n ใช้สำหรับเขียนโค้ดภาษา JavaScript เพื่อประมวลผลข้อมูลภายใน Workflow เช่น การจัดรูปแบบข้อความ การแก้ไขข้อมูล JSON การตรวจสอบข้อมูล และการเตรียมผลลัพธ์ก่อนส่งไปยังขั้นตอนถัดไปของระบบ โดยในภาพกำลังใช้โค้ดเพื่อจัดรูปแบบคำตอบจาก AI ให้แสดงผลอ่านง่ายและเหมาะสมสำหรับส่งกลับไปยัง LINE Chatbot



ภาพที่ 4.22 หน้าตั้งค่าโค้ดโน้ต

```


Edit JavaScript

1 let rawData = $input.first().json.output ?? $input.first().json.answer ?? $input.first().json;
2
3 function formatAnswer(text) {
4   return String(text)
5     .replace(/^`json`"/g, '')
6     .replace(/\\n/g, '\n')
7     .replace(/\\s\\s/g, ' ')
8     .replace(/\\s\\s/g, ' ')
9     .replace(/\\s\\s/g, ' ')
10    .trim();
11 }
12
13 let answer = '';
14
15 if (typeof rawData === 'string') {
16   answer = rawData;
17 } else if (rawData?.answer) {
18   answer = rawData.answer;
19 } else if (rawData?.output) {
20   answer = rawData.output;
21 } else if (rawData?.text) {
22   answer = rawData.text;
23 } else {
24   answer = JSON.stringify(rawData, null, 2);
25 }
26
27 return [
28   {
29     json: {
30       answer: formatAnswer(answer)
31     }
32   }
33 ];

```

ภาพที่ 4.23 หน้าตั้งค่าโค้ดโน้ต

4.2.2.5 หน้าตั้งค่า HTTP Request Node ใน n8n ใช้สำหรับส่งคำขอ (Request) ไปยัง API ภายนอกผ่านโปรโตคอล HTTP เช่น GET หรือ POST โดยในภาพกำลังใช้วิธี POST เพื่อส่งข้อความตอบกลับไปยัง LINE Messaging API พร้อมกำหนด URL, Header, Authorization และข้อมูล JSON สำหรับส่งข้อความจากระบบ Chatbot กลับไปยังผู้ใช้งาน



ภาพที่ 4.24 หน้าตั้งค่าเฮ็ดที่ทีพีรีพลาย


4.2.2.6 โค้ดนี้คือการกำหนด Flex Message ของ LINE Messaging API สำหรับส่งข้อความตอบกลับผู้ใช้ในรูปแบบการ์ด (Bubble) ผ่าน HTTP Request Node โดยใช้ข้อมูลคำตอบจาก AI (\$json.answer) มาแสดงผลในรูปแบบที่สวยงาม อ่านง่าย และมีการตกแต่งด้วยหัวข้อ เส้นคั่น และข้อความส่วนท้ายของกองพัฒนานักศึกษา NPRU เพื่อเพิ่มความน่าสนใจและสวยงาม

```
Expression
Anything inside {{ }} is JavaScript. Learn more

{{ {
  replyToken: $('Webhook').item.json.body.events[0].replyToken,
  messages: [
    {
      type: "flex",
      altText: "คำคมจากกองพัฒนานักศึกษา",
      contents: {
        type: "bubble",
        size: "mega",
        body: {
          type: "box",
          layout: "vertical",
          spacing: "md",
          contents: [
            {
              type: "text",
              text: "✖ ข้อมูลที่พบ",
              weight: "bold",
              size: "lg",
              color: "#1DB846"
            },
            {
              type: "separator",
              margin: "md"
            },
            {
              type: "text",
              text: $json.answer,
              size: "sm",
              color: "#333333",
              wrap: true,
              margin: "md"
            },
            {
              type: "separator",
              margin: "lg"
            },
            {
              type: "text",
              text: "กองพัฒนานักศึกษา NPRU",
              size: "xs",
              color: "#888888",
              align: "center",
              margin: "md"
            }
          ]
        }
      }
    }
  ]
}}
```


ภาพที่ 4.25 หน้าตั้งค่าเธรดที่ตีพิมพ์

4.2.2.7 หน้าตั้งค่า Google Gemini Chat Model Node ใน n8n ใช้สำหรับเชื่อมต่อโมเดลปัญญาประดิษฐ์ Google Gemini เข้ากับระบบ Workflow โดยกำหนด Credential สำหรับยืนยันตัวตนและเลือกโมเดล AI ที่ต้องการใช้งาน เช่น gemini-2.5-flash-lite เพื่อใช้ประมวลผลภาษา ตอบคำถาม และสร้างข้อความอัตโนมัติภายในระบบ Chatbot




ภาพที่ 4.26 หน้าตั้งค่าเชื่อมต่อกูเกิลจีมีไน

4.2.2.8 หน้าตั้งค่า Simple Memory Node ใน n8n ใช้สำหรับจัดเก็บข้อมูลการสนทนาชั่วคราวของผู้ใช้งาน เพื่อให้ AI สามารถจดจำข้อความก่อนหน้าและตอบโต้ต่อเนื่องได้ โดยสามารถกำหนด Session ID และจำนวนข้อความย้อนหลัง (Context Window Length) ที่ต้องการให้ AI ใช้อ้างอิงในการสนทนา ทำให้ระบบ Chatbot มีความต่อเนื่องและเข้าใจบริบทของผู้ใช้งานมากขึ้น



ภาพที่ 4.27 หน้าตั้งค่าเชื่อมต่อกูเกิลจีมีไน


4.2.2.9 หน้าตั้งค่า Supabase Vector Store Node ใน n8n ซึ่งเป็นส่วนที่ใช้เชื่อมต่อกับฐานข้อมูล Supabase เพื่อให้ระบบ AI Agent สามารถค้นหาข้อมูลจากเอกสารที่จัดเก็บไว้ในรูปแบบเวกเตอร์ได้ Node นี้ทำหน้าที่เป็นแหล่งความรู้ของระบบ Chatbot โดยเมื่อผู้ใช้งานส่งคำถามเข้ามา AI จะส่งคำค้นไปยัง Supabase Vector Store เพื่อค้นหาเอกสารหรือข้อความที่มีความหมายใกล้เคียงกับคำถาม จากนั้นจึงนำข้อมูลที่ค้นพบมาประกอบสร้างคำตอบในการตั้งค่า Operation Mode เป็น Retrieve Documents (As Tool for AI Agent) หมายความว่า Supabase Vector Store ถูกใช้งานเป็นเครื่องมือให้ AI Agent เรียกค้นข้อมูลเมื่อต้องการ ไม่ได้ตอบจากความรู้ของโมเดลเพียงอย่างเดียว แต่จะอ้างอิงจากข้อมูลที่เก็บไว้ในฐานข้อมูล ส่วน Table Name กำหนดเป็น documents คือชื่อตารางใน Supabase ที่ใช้เก็บข้อมูลเอกสารและเวกเตอร์ ส่วน Limit กำหนดไว้ที่ 50 หมายถึงจำนวนผลลัพธ์สูงสุดที่สามารถดึงกลับมาได้จากการค้นหา และ Query Name กำหนดเป็น match\_documents ซึ่งเป็นฟังก์ชันสำหรับค้นหาข้อมูลที่ตรงหรือใกล้เคียงกับคำถามของผู้ใช้



ภาพที่ 4.28 หน้าตั้งค่าเชื่อมต่อซูปาเบส


4.2.2.10 หน้ากำหนด Description ของ Supabase Vector Store ซึ่งใช้เป็นคำอธิบายหรือคำสั่งให้ AI Agent เข้าใจวิธีใช้งานเครื่องมือค้นหาข้อมูลจากฐานข้อมูลเวกเตอร์ โดยข้อความภายในจะกำหนดขอบเขตการทำงานของ AI อย่างชัดเจน เช่น ให้ค้นหาข้อมูลจาก

Supabase เท่านั้น ห้ามสร้างคำตอบขึ้นเอง และหากไม่พบข้อมูลที่ตรงกับคำถาม ให้แจ้งผู้ใช้งานว่า “ไม่พบคำตอบที่มีอยู่ในฐานข้อมูล” เพื่อควบคุมให้ระบบตอบคำถามจากข้อมูลจริงในฐานข้อมูลและลดการเกิดข้อมูลผิดพลาดจาก A




ภาพที่ 4.29 หน้าตั้งค่าซูปาเบส

4.2.2.11 หน้าตั้งค่า Embeddings Ollama Node ใน n8n ใช้สำหรับสร้างข้อมูลเวกเตอร์ (Embedding) จากข้อความด้วยโมเดลของ Ollama เพื่อให้ระบบสามารถนำข้อความไปค้นหาความหมายที่ใกล้เคียงกันในฐานข้อมูลเวกเตอร์ได้ การเลือกโมเดล nomic-embed-text:latest ซึ่งเป็นโมเดลสำหรับแปลงข้อความให้เป็นเวกเตอร์เชิงตัวเลข (Vector Embedding) โดยระบบจะนำข้อความจากเอกสารหรือคำถามของผู้ใช้งานมาแปลงเป็นเวกเตอร์ก่อนจัดเก็บลงใน Supabase Vector Store หรือใช้ในการค้นหาข้อมูลที่เกี่ยวข้อง Embedding มีบทบาทสำคัญในระบบ Retrieval-Augmented Generation (RAG) เพราะช่วยให้ AI สามารถค้นหาข้อมูลตาม “ความหมาย” ของข้อความ ไม่ใช่ค้นหาเฉพาะคำที่ตรงกันเท่านั้น เช่น แม้ผู้ใช้จะใช้คำถามต่างรูปแบบ ระบบก็ยังสามารถค้นหาเอกสารที่มีเนื้อหาใกล้เคียงกันได้ Node นี้จึงเป็นส่วนสำคัญที่ช่วยเพิ่มความแม่นยำในการค้นหาข้อมูลของระบบ Chatbot และทำให้การตอบคำถามจากฐานข้อมูลมีประสิทธิภาพมากขึ้น




ภาพที่ 4.30 หน้าตั้งค่าเชื่อมต่อเอ็มเบสดีงโมเดล






ภาพที่ 4.32 หน้าการตั้งค่าเชื่อมต่อกูเกิลไดรฟ์ระบบเร็ก

4.2.3.3 หน้าตั้งค่า Loop Over Items ใน n8n ใช้สำหรับให้ Workflow ทำงานซ้ำกับข้อมูลที่หลายรายการ เช่น เมื่อมีหลายไฟล์หรือหลายข้อมูลเข้ามา ระบบจะนำมาประมวลผลทีละชิ้นอัตโนมัติ การกำหนด Batch Size = 1 หมายถึงให้ระบบประมวลผลข้อมูลครั้งละ 1 รายการ เพื่อป้องกันข้อมูลซ้อนกันหรือทำงานผิดพลาดระหว่างการประมวลผลไฟล์หลายรายการ




ภาพที่ 4.33 หน้าการตั้งค่าลูปโอเวอร์ไอเทมระบบเร็ก

4.2.3.4 หน้าตั้งค่า Edit Fields Node ใน n8n ใช้สำหรับเลือก แก้ไข หรือสร้างข้อมูลใหม่ก่อนส่งต่อไปยังขั้นตอนถัดไปของ Workflow การสร้างฟิลด์ชื่อ file\_id และกำหนดค่าเป็น {{ \$json.id }} ซึ่งหมายถึงการดึงค่า ID ของไฟล์จากข้อมูลที่ได้รับมาก่อนหน้า เพื่อนำไปใช้งานต่อ เช่น ใช้ดาวน์โหลดไฟล์จาก Google Drive หรืออ้างอิงไฟล์ในขั้นตอนอื่นของระบบ ช่วยจัดรูปแบบข้อมูลให้เป็นระเบียบและเลือกเฉพาะข้อมูลที่ต้องการสำหรับการทำงานของ Workflow




ภาพที่ 4.34 หน้าการตั้งค่าอีดิทฟิลด์ระบบเร็ก

4.2.3.5 หน้าตั้งค่า Download File ของ Google Drive ใน n8n ใช้สำหรับดึงไฟล์จาก Google Drive เข้ามาใน Workflow เพื่อให้ระบบนำไฟล์ไปใช้งานต่อได้ เช่น อ่านข้อความ แยกเนื้อหา สรุปข้อมูล หรือบันทึกลงฐานข้อมูล การตั้งค่าเชื่อมต่อกับ Google Drive account เพื่อให้ n8n มีสิทธิ์เข้าถึงไฟล์ใน Google Drive จากนั้นเลือก Resource = File หมายถึงต้องการทำงานกับไฟล์ และเลือก Operation = Download หมายถึงให้ดาวน์โหลดไฟล์ออกมาจาก Google Drive ส่วนช่อง File เป็นตำแหน่งที่ใช้เลือกไฟล์ที่ต้องการดาวน์โหลด โดยอ้างอิงจากไฟล์ที่ได้มาจากขั้นตอนก่อนหน้า เช่น file\_id ที่ถูกดึงมาจาก Google Drive Trigger หรือ Edit Fields Node ในส่วน Google File Conversion เป็นการกำหนดรูปแบบไฟล์ที่จะถูกแปลงก่อนดาวน์โหลด เช่น Google Docs แปลงเป็น PDF, Google Slides แปลงเป็น PowerPoint และ Google Sheets แปลงเป็น CSV เพื่อให้ระบบสามารถนำไฟล์ไปประมวลผลต่อได้ง่ายขึ้น




ภาพที่ 4.35 หน้าการตั้งค่าเชื่อมต่อดาวน์โหลดไฟล์จากกูเกิลไดรฟ์ระบบแรก

4.2.3.6 หน้าตั้งค่า Switch Node ใช้สำหรับแยกเส้นทางการทำงานของ Workflow ตามประเภทของไฟล์ที่ดาวน์โหลดมาจาก Google Drive ในการตั้งค่า Mode = Rules หมายความว่า ระบบจะตรวจสอบข้อมูลตามเงื่อนไขที่กำหนดไว้ แล้วส่งไฟล์ไปยังเส้นทางที่ตรงกับเงื่อนไขนั้น เงื่อนไขที่ใช้ตรวจสอบคือ `{{ $binary.data.mimeType }}` ค่านี้คือชนิดของไฟล์ที่ระบบดาวน์โหลดมา เช่น PDF หรือ CSV ในภาพมีการตั้งค่าไว้ 2 เส้นทางได้แก่ Routing Rule 1 ถ้าไฟล์มีชนิดเป็น `application/pdf` ระบบจะส่งไฟล์ไปยังเส้นทางสำหรับประมวลผลไฟล์ PDF เช่น แยกข้อความจากเอกสาร PDF Routing Rule 2 ถ้าไฟล์มีชนิดเป็น `text/csv` ระบบจะส่งไฟล์ไปยังเส้นทางสำหรับประมวลผลไฟล์ CSV เช่น อ่านข้อมูลจากตาราง



ภาพที่ 4.36 หน้าการตั้งค่าสวิตช์ในตรระบบแรก


4.2.3.7 หน้าตั้งค่า Node Extract from File ทำหน้าที่สำหรับอ่านและดึงข้อมูลออกจากไฟล์ที่ระบบดาวน์โหลดมาจาก Google Drive เพื่อแปลงข้อมูลภายในเอกสารให้อยู่ในรูปแบบข้อความที่ระบบ AI สามารถเข้าใจและนำไปประมวลผลต่อได้ โดยใน Workflow นี้รองรับทั้งไฟล์ประเภท PDF และ CSV สำหรับไฟล์ PDF มีการตั้งค่า Operation เป็น Extract From PDF ซึ่งระบบจะเปิดไฟล์เอกสาร PDF แล้วดึงข้อความทั้งหมดภายในเอกสารออกมาให้อยู่ในรูปแบบข้อความธรรมดา เช่น ข้อมูลจากคู่มือ กยศ. เอกสารประกาศ หรือข้อมูลภายในมหาวิทยาลัยราชภัฏนครปฐม เพื่อให้ AI สามารถนำเนื้อหาไปวิเคราะห์ สรุป หรือจัดเก็บเป็นฐานความรู้ได้ ส่วนไฟล์ CSV มีการตั้งค่า Operation เป็น Extract From CSV ใช้สำหรับอ่านข้อมูลจากไฟล์ตาราง เช่น รายชื่อนักศึกษา ข้อมูลทุนการศึกษา หรือข้อมูลที่อยู่ในรูปแบบ Spreadsheet โดยระบบจะดึงข้อมูลแต่ละแถวและแต่ละคอลัมน์ออกมาให้อยู่ในรูปแบบที่สามารถประมวลผลต่อได้ ทั้งสอง Node ใช้ค่า Input Binary Field = data ซึ่งเป็นตำแหน่งที่เก็บไฟล์ที่ถูกดาวน์โหลดมาจากขั้นตอน Download File ก่อนหน้า โดย Node จะนำไฟล์ในช่อง data มาอ่านและแปลงข้อมูลภายในออกมา หลังจากดึงข้อมูลจากไฟล์เรียบร้อยแล้ว ข้อมูลข้อความที่ได้จะถูกส่งต่อไปยังขั้นตอนถัดไปของระบบ เช่น การสรุปเนื้อหาด้วย AI การสร้าง Metadata การแปลงข้อความเป็นเวกเตอร์ (Embedding) และการจัดเก็บลงใน Supabase Vector Store เพื่อใช้เป็นฐานข้อมูลสำหรับ AI Chatbot ในการค้นหาและตอบคำถามของผู้ใช้งาน




ภาพที่ 4.37 หน้าการตั้งค่าเอ็กซ์แทร็กไฟล์สำหรับดึงข้อมูลระบบเร็ก



4.2.3.9 หน้าตั้งค่า AI Agent Node ที่ใช้สำหรับตรวจสอบและแก้ไขข้อความที่ดึงมาจากไฟล์เอกสาร ก่อนนำข้อมูลไปใช้งานต่อในระบบ RAG Chatbot ในช่อง Prompt (User Message) มีการใส่คำสั่งให้ AI ทำหน้าที่ตรวจสอบภาษาไทย โดยให้แก้ไขคำผิด แก้คำสะกด และปรับคำที่ไม่เหมาะสมให้ถูกต้อง แต่มีเงื่อนไขสำคัญคือ ห้ามเปลี่ยนความหมายเดิมของเนื้อหาข้อความที่นำมาให้ AI ตรวจสอบถูกดึงมาจากตัวแปร `{{ $json.data }}` ซึ่งเป็นข้อมูลที่ได้จากขั้นตอนก่อนหน้า เช่น ข้อความที่แยกมาจากไฟล์ PDF หรือ CSV หลังจาก AI ตรวจสอบแล้ว ระบบจะได้ข้อความที่สะอาดขึ้น ถูกต้องขึ้น และพร้อมสำหรับส่งต่อไปยังขั้นตอนถัดไป เช่น การแบ่งข้อความ การสรุป การสร้าง Embedding และการจัดเก็บลง Supabase Vector Store




ภาพที่ 4.40 หน้าการตั้งค่าเอไอเอจิ้นระบบเร็ก




ภาพที่ 4.41 หน้าการตั้งค่าพรมเอไอเอจิ้นระบบเร็ก

4.2.3.10 Google Gemini Chat Model ใช้สำหรับเชื่อมต่อ AI Agent เข้ากับ โมเดล Google Gemini (gemini-2.5-flash-lite) เพื่อประมวลผลข้อความภายในระบบ เช่น การ ตรวจสอบคำผิด วิเคราะห์ข้อมูล และตอบคำถาม




ภาพที่ 4.42 หน้าการตั้งค่าเชื่อมต่อโมเดลจีมีไนในระบบเร็ก

4.2.3.11 การตั้งค่า Create Metadata Title & Description ใช้สำหรับให้ AI สร้าง ข้อมูลกำกับเอกสาร หรือ Metadata ก่อนนำข้อมูลไปเก็บในฐานข้อมูลเวกเตอร์ จะรับข้อความที่ผ่านการตรวจสอบและแก้ไขจากขั้นตอนก่อนหน้านี้ แล้วส่งให้ AI วิเคราะห์เนื้อหา จากนั้นสร้างข้อมูลสำคัญออกมา เช่น Title คือชื่อเรื่องของเอกสาร Description คือคำอธิบายสั้น ๆ ว่าเอกสารนี้เกี่ยวกับอะไร ในภาพมีการใช้ข้อมูลจากตัวแปร `{{ $json.output }}` ซึ่งเป็นข้อความที่ได้จาก AI Agent ก่อนหน้านี้ แล้วนำมาสร้าง Title และ Description เพื่อใช้ประกอบการจัดเก็บข้อมูลใน Supabase Vector Store มีการเปิดใช้งาน Require Specific Output Format เพื่อบังคับให้ AI ส่งผลลัพธ์ออกมาตามรูปแบบที่กำหนด เช่น JSON ทำให้ข้อมูลที่ได้นั้นมีโครงสร้างชัดเจน ไม่ปะปนกัน และนำไปใช้งานต่อได้ง่าย




ภาพที่ 4.43 หน้าการตั้งค่าคีย์เวิร์ดเมตาดาต้าในระบบเร็ก




ภาพที่ 4.44 หน้าการตั้งค่าคำสั่งคือเอทเมต้าด้าในระบบเร็ก

4.2.3.12 Google Gemini Chat Model ที่เชื่อมต่อกับ Create Metadata Title & Description เพื่อใช้โมเดล AI ของ Google Gemini ในการวิเคราะห์ข้อความและสร้าง Metadata ของเอกสาร เช่น ชื่อเรื่อง (Title) และคำอธิบาย (Description)




ภาพที่ 4.45 หน้าการตั้งค่าเชื่อมโมเดลกูเกิลจิมี่ในคือเอทเมต้าด้าระบบเร็ก

4.2.3.13 Structured Output Parser ที่เชื่อมต่อกับ Node Create Metadata Title & Description ใช้สำหรับกำหนดรูปแบบผลลัพธ์ที่ AI ต้องส่งกลับหลังจากสร้าง Metadata ของเอกสาร โดยบังคับให้ AI ตอบข้อมูลในรูปแบบ JSON ที่มีโครงสร้างชัดเจน เช่น title และ description ช่วยให้ข้อมูล Metadata ที่ AI สร้างขึ้นมีรูปแบบเป็นมาตรฐาน สามารถนำไปใช้งานต่อใน Workflow ได้อย่างถูกต้อง เช่น การจัดเก็บลง Supabase Vector Store หรือใช้ในการค้นหาเอกสารในระบบ RAG โดยช่วยลดปัญหาข้อมูลผิดรูปแบบและทำให้ระบบประมวลผลอัตโนมัติมีประสิทธิภาพมากขึ้น




ภาพที่ 4.46 หน้าการตั้งค่าสตรัคเจอร์เอาท์พุตพาร์เซอร์ระบบเร็ก




ภาพที่ 4.47 หน้าการตั้งค่าสตรัคเจอร์เอาท์พุตพาร์เซอร์ระบบเร็ก

4.2.3.13 Code Node นี้ใช้ภาษา JavaScript สำหรับจัดการข้อความก่อนนำไปสร้าง Embedding โดยกำหนด ChunkSize = 1000 เพื่อแบ่งข้อความแต่ละชุดให้มีขนาดประมาณ 1,000 ตัวอักษร และกำหนด ChunkOverlap = 200 เพื่อให้แต่ละชุดมีข้อความซ้อนทับกัน 200 ตัวอักษร ช่วยรักษาบริบทของเนื้อหาไม่ให้ขาดตอน ระบบจะดึงข้อความจาก AI Agent ผ่านคำสั่ง \$('AI Agent').first().json.output จากนั้นล้างข้อความด้วยคำสั่ง replace() เพื่อลบข้อความในวงเล็บที่มีคำว่า “ปรับ” ออก แล้วจึงวนลูปแบ่งข้อความออกเป็นหลายส่วน โดยพยายามตัดข้อความตามตำแหน่งที่เหมาะสม เช่น การขึ้นบรรทัดใหม่ จุดจบประโยค หรือช่องว่าง เพื่อไม่ให้ตัดกลางประโยค มากเกินไปเมื่อแบ่งข้อความเสร็จ ระบบจะส่งออกข้อมูลในรูปแบบ JSON โดยมี texts เป็นรายการข้อความที่ถูกแบ่งแล้ว และ input\_type: "search\_document" เพื่อเตรียมข้อมูลสำหรับการสร้าง Embedding และจัดเก็บลงฐานข้อมูลเวกเตอร์ในขั้นตอนถัดไปของระบบ RAG




ภาพที่ 4.48 หน้าการตั้งค่าโค้ดโน้ตระบบแรก




ภาพที่ 4.49 หน้าการตั้งค่าโค้ดโน้ตระบบแรก

4.2.3.14 Split Out Node ใช้สำหรับแยกข้อมูลที่อยู่ในรูปแบบรายการออกมาเป็นรายการย่อยทีละชิ้น เพื่อให้ Workflow สามารถนำข้อมูลแต่ละส่วนไปประมวลผลต่อแยกกันได้ในภาพมีการตั้งค่า Fields to Split Out = texts หมายความว่า ระบบจะนำข้อมูลในฟิลด์ texts ซึ่งได้มาจาก Code Node ก่อนหน้า มาแยกออกเป็นหลายรายการ โดย texts คือชุดข้อความที่ถูกแบ่งเป็น Chunk แล้ว เช่น texts[0], texts[1], texts[2] การตั้งค่า Include = No Other Fields หมายถึงให้ส่งออกเฉพาะข้อมูลที่แยกจากฟิลด์ texts เท่านั้น ไม่ต้องนำข้อมูลอื่นติดไปด้วย ทำให้ข้อมูลสะอาดและไม่ซ้ำซ้อน ส่วน Destination Field Name = texts คือชื่อฟิลด์ปลายทางที่ใช้เก็บข้อความแต่ละ Chunk หลังจากแยกออกมาแล้ว




ภาพที่ 4.50 หน้าการตั้งค่าสลิปเข้าระบบเร็ก

4.2.3.15 Basic LLM Chain Node ใช้สำหรับให้ AI ประมวลผลข้อความแต่ละ Chunk ที่ถูกแยกออกมาจาก Split Out Node ก่อนนำข้อมูลไปใช้งานต่อ ในภาพมีการกำหนด Prompt โดยแบ่งข้อมูลเป็น 2 ส่วนหลัก คือ <document> ใช้ใส่ข้อความเอกสารฉบับเต็มหรือข้อความที่ผ่านการปรับจาก AI Agent <chunk> ใช้ใส่ข้อความย่อยแต่ละส่วนที่ถูกแบ่งมาจาก Split Out Node จะนำข้อมูลทั้งสองส่วนไปให้โมเดล AI วิเคราะห์ เพื่อทำให้แต่ละ Chunk มีบริบทที่ชัดเจนขึ้น ไม่หลุดจากเนื้อหาเดิมของเอกสาร เช่น ช่วยสรุปหรือจัดข้อความให้เหมาะสมก่อนส่งต่อไปยังขั้นตอนถัดไป




ภาพที่ 4.51 หน้าการตั้งค่าสลิปเข้าระบบเร็ก

4.2.3.16 Ollama Chat Model ที่เชื่อมต่อกับ Basic LLM Chain เพื่อใช้เป็นโมเดล AI สำหรับประมวลผลข้อความย่อย หรือ Chunk ที่ถูกแบ่งมาจากเอกสาร ในการเลือกใช้โมเดล llama3.2:latest ผ่าน Ollama account โดยโมเดลนี้ทำหน้าที่รับคำสั่งจาก Basic LLM Chain แล้วนำข้อความไปวิเคราะห์ตาม Prompt ที่กำหนดไว้ เช่น การสรุปบริบทสั้น ๆ ของ Chunk การตรวจสอบว่าข้อความอยู่ในส่วนใดของเอกสาร และการเติมข้อมูลที่ขาดหายบางส่วนให้สมบูรณ์โดยอ้างอิงจากเอกสารฉบับเต็ม การเชื่อมต่อ Node นี้ช่วยให้ข้อความแต่ละ Chunk มีบริบทชัดเจนขึ้น ก่อนนำไปสร้าง Embedding และจัดเก็บลง Supabase Vector Store ส่งผลให้ระบบ RAG Chatbot สามารถค้นหาข้อมูลจากฐานความรู้ได้แม่นยำมากขึ้น และตอบคำถามของผู้ใช้งานได้ตรงกับเนื้อหาในเอกสารมากขึ้น




ภาพที่ 4.52 หน้าการตั้งค่าเชื่อมโมเดลโอลามาระบบเร็ก



ภาพที่ 4.53 หน้าการตั้งค่ากฎคำสั่งโมเดลโอลามาระบบเร็ก


4.2.3.17 Summarize ใช้สำหรับรวมข้อความที่ผ่านการประมวลผลจาก Basic LLM Chain Node ให้กลับมาเป็นข้อมูลชุดเดียว ก่อนส่งต่อไปยังขั้นตอนถัดไป เช่น การสร้าง Embedding หรือการบันทึกลง Supabase Vector Store ในภาพตั้งค่า Aggregation = Concatenate หมายถึง นำข้อความหลายรายการมาต่อรวมกัน โดยใช้ฟิลด์ text เป็นข้อมูลหลักในการรวมข้อความ ส่วน Separator กำหนดเป็น ###SPLIT### หมายถึงใช้ข้อความนี้เป็นตัวคั่นระหว่างแต่ละ Chunk เพื่อให้ระบบรู้ว่าข้อความแต่ละส่วนแยกจากกันอยู่ ไม่ปะปนเป็นประโยคเดียว ช่วยให้ข้อมูลที่ถูกแยกและประมวลผลทีละ Chunk สามารถถูกรวบรวมกลับมาอย่างเป็นระเบียบ พร้อมรักษาขอบเขตของแต่ละส่วนไว้ ทำให้ขั้นตอนต่อไปสามารถนำข้อมูลไปแบ่ง จัดเก็บ หรือค้นหาได้ง่ายขึ้นในระบบ RAG



ภาพที่ 4.54 หน้าการตั้งค่าซัมมารีระบบแรก


4.2.3.18 Supabase Vector Store ใช้สำหรับนำข้อมูลเอกสารที่ผ่านการจัดเตรียมแล้วไปบันทึกลงฐานข้อมูลเวกเตอร์ของ Supabase เพื่อใช้เป็นฐานความรู้ของระบบ RAG Chatbot ในการตั้งค่า Operation Mode = Insert Documents หมายถึง Node นี้ทำหน้าที่เพิ่มเอกสารใหม่เข้าไปในฐานข้อมูล ไม่ใช่การค้นหาเอกสาร ข้อมูลที่ส่งเข้ามาจากขั้นตอนก่อนหน้าคือ Summarize Node ซึ่งรวมข้อความแต่ละ Chunk ให้เป็นข้อมูลที่พร้อมจัดเก็บแล้ว จากนั้น Supabase Vector Store จะนำข้อความเหล่านี้ไปทำงานร่วมกับ Embedding Model เพื่อแปลงข้อความเป็นเวกเตอร์แล้วบันทึกลงตาราง documents ส่วน Embedding Batch Size = 16 หมายถึงระบบจะประมวลผลข้อความครั้งละ 16 ชุด เพื่อช่วยให้การสร้าง Embedding และบันทึกข้อมูลทำงานเป็นชุด ๆ ได้มีประสิทธิภาพ และ Query Name = match\_documents คือชื่อฟังก์ชันที่ใช้สำหรับค้นหาข้อมูลที่

เกี่ยวข้องในภายหลัง เมื่อผู้ใช้ถามคำถามกับ Chatbot ทำหน้าที่ บันทึกข้อความจากเอกสารลง Supabase Vector Store เพื่อสร้างฐานความรู้ให้ AI สามารถค้นหาและตอบคำถามจากข้อมูลจริงได้




ภาพที่ 4.55 หน้าการตั้งค่าเชื่อมต่อซูปาเบสระบบแรก

4.2.3.19 Embeddings Ollama ที่เชื่อมต่อกับ Supabase Vector Store Node เพื่อทำหน้าที่สร้าง Embedding หรือแปลงข้อความให้เป็นเวกเตอร์เชิงตัวเลขก่อนจัดเก็บลงฐานข้อมูลเวกเตอร์ ในการเลือกใช้โมเดล nomic-embed-text:latest ผ่าน Ollama ซึ่งเป็นโมเดลสำหรับแปลงข้อความให้กลายเป็นเวกเตอร์ที่ AI สามารถใช้เปรียบเทียบความหมายของข้อมูลได้ เมื่อข้อความจาก Summarize Node ถูกส่งเข้ามา ระบบจะใช้โมเดลนี้สร้าง Embedding แล้วส่งต่อไปยัง Supabase Vector Store เพื่อจัดเก็บลงตาราง documents Embedding มีบทบาทสำคัญในระบบ RAG เพราะช่วยให้ Chatbot สามารถค้นหาข้อมูลตาม “ความหมายของข้อความ” ได้ ไม่จำเป็นต้องค้นหาคำที่ตรงกันทั้งหมด ทำให้ระบบตอบคำถามได้แม่นยำและใกล้เคียงกับบริบทของผู้ใช้งาน




ภาพที่ 4.56 หน้าการตั้งค่าเชื่อมต่อโมเดลโอลามาเอ็มเบสดีงระบบแรก

4.2.3.20 Default Data Loader ที่เชื่อมต่อกับ Supabase Vector Store ใช้สำหรับโหลดและเตรียมข้อมูลข้อความก่อนนำไปสร้าง Embedding และจัดเก็บลงฐานข้อมูลเวกเตอร์ในภาพมีการกำหนด Type of Data = JSON หมายถึงข้อมูลที่รับเข้ามาอยู่ในรูปแบบ JSON และเลือก Mode = Load Specific Data เพื่อระบุข้อมูลที่ต้องการใช้งานโดยตรงข้อมูลที่นำเข้ามาถูกดึงจากตัวแปร `{{ $json.concatenated_text }}` ซึ่งเป็นข้อความที่ผ่านการรวมและประมวลผลจาก Summarize Node ก่อนหน้า ส่วน Text Splitting = Custom หมายถึงระบบใช้รูปแบบการแบ่งข้อความแบบกำหนดเอง เพื่อเตรียมข้อความให้เหมาะสำหรับการสร้าง Embedding และจัดเก็บใน Supabase Vector Store มีหน้าที่สำคัญในการจัดรูปแบบข้อมูลให้พร้อมสำหรับเข้าสู่กระบวนการ Vector Embedding ทำให้ข้อมูลที่ถูกจัดเก็บในฐานข้อมูลมีโครงสร้างเหมาะสมและสามารถค้นหาได้อย่างมีประสิทธิภาพ



ภาพที่ 4.57 หน้าการตั้งค่าดีฟอลต์ดาต้าโหลดเดอร์ระบบเร็ก


4.2.3.21 Character Text Splitter ที่เชื่อมต่อกับ Default Data Loader Node ใช้สำหรับแบ่งข้อความออกเป็นส่วนย่อย (Chunk) ก่อนนำไปสร้าง Embedding โดยในภาพกำหนดตัวค้นหาคำเป็น `###SPLIT###` เพื่อใช้แยกแต่ละส่วนของข้อความอย่างชัดเจน กำหนด Chunk Size = 1000 ให้แต่ละ Chunk มีความยาวประมาณ 1,000 ตัวอักษร และ Chunk Overlap = 0 คือไม่มีข้อความซ้อนทับกันระหว่างแต่ละส่วน ช่วยให้ข้อมูลถูกจัดแบ่งอย่างเป็นระเบียบและเหมาะสำหรับการประมวลผลของระบบ AI



ภาพที่ 4.58 หน้าการตั้งค่าแคแร็คเตอร์เท็กซ์สปลิตเตอร์ระบบเร็ก

#### 4.2.4 สร้างฐานข้อมูลเวกเตอร์สำหรับระบบ RAG ใน Supabase

4.2.4.1 ขั้นตอนนี้เป็นการสร้างฐานข้อมูลเวกเตอร์ใน Supabase สำหรับรองรับระบบ RAG Chatbot ผ่านหน้า SQL Editor โดยเริ่มจากการเปิดใช้งาน pgvector extension ด้วยคำสั่ง `create extension vector, with schema extensions;` เพื่อให้ฐานข้อมูลสามารถจัดเก็บและประมวลผลค่าเวกเตอร์ (Embedding) ได้ จากนั้นการสร้างตาราง documents สำหรับเก็บข้อมูลเอกสาร โดยประกอบด้วย id สำหรับรหัสข้อมูล, content สำหรับเก็บข้อความจากเอกสาร, metadata สำหรับเก็บข้อมูลประกอบเอกสารในรูปแบบ JSON และ embedding สำหรับเก็บค่าเวกเตอร์ของข้อความ ซึ่งกำหนดขนาดเวกเตอร์เป็น 768 มิติให้สอดคล้องกับโมเดล Embedding ที่ใช้งาน ต่อมา มีการสร้างฟังก์ชัน `match_documents()` เพื่อใช้ค้นหาเอกสารที่มีความหมายใกล้เคียงกับคำถามของผู้ใช้งาน โดยรับค่าเวกเตอร์ของคำถามผ่านตัวแปร `query_embedding` แล้วนำไปเปรียบเทียบกับเวกเตอร์ของเอกสารในตาราง documents ภายในฟังก์ชันมีการคำนวณค่าความคล้ายคลึงด้วยคำสั่ง `1 - (documents.embedding <=> query_embedding)` ซึ่งใช้เปรียบเทียบระยะห่างระหว่างเวกเตอร์ของคำถามและเอกสาร จากนั้นเรียงลำดับผลลัพธ์ตามความใกล้เคียง และคืนข้อมูลที่เกี่ยวข้องมากที่สุดตามจำนวนที่กำหนดใน `match_count`



ภาพที่ 4.59 หน้าการตั้งค่าการสร้างฐานข้อมูลซูปาเบส

```

1  -- Enable the pgvector extension to work with embedding vectors
2  create extension vector
3  with
4  | schema extensions;
5
6  -- Create a table to store your documents
7  create table documents (
8  | id bigserial primary key,
9  | content text, -- corresponds to Document.pageContent
10 | metadata jsonb, -- corresponds to Document.metadata
11 | embedding extensions.vector(768) -- 1536 works for OpenAI embeddings, change if needed
12 );
13

```

ภาพที่ 4.60 หน้าการตั้งค่าการสร้างฐานข้อมูลซูปาเบส

```

14 -- Create a function to search for documents
15 create function match_documents (
16 | query_embedding extensions.vector(768),
17 | match_count int default null,
18 | filter jsonb DEFAULT '{}'
19 ) returns table (
20 | id bigint,
21 | content text,
22 | metadata jsonb,
23 | similarity float
24 )

```

ภาพที่ 4.61 หน้าการตั้งค่าการสร้างฐานข้อมูลซูปาเบส

```

25 language plpgsql
26 as $$
27 #variable_conflict use_column
28 begin
29 | return query
30 | select
31 | | id,
32 | | content,
33 | | metadata,
34 | | 1 - (documents.embedding <=> query_embedding) as similarity
35 | from documents
36 | where metadata @> filter
37 | order by documents.embedding <=> query_embedding
38 | limit match_count;
39 end;
40 $$;

```

ภาพที่ 4.62 หน้าการตั้งค่าการสร้างฐานข้อมูลซูปาเบส



The screenshot shows a web-based metadata editor. At the top, there's a header "Editing value of: metadata" with "Edit" and "View" buttons. Below is a code editor with a dark theme, displaying a JSON object. The JSON has fields for "loc" (with "lines" containing "to" and "from"), "title", "source", "file\_id", "blobType", and a long "description" in Thai. Line numbers 1 through 13 are visible on the left margin.

```

1  {
2    "loc": {
3      "lines": {
4        "to": 9,
5        "from": 1
6      }
7    },
8    "title": "กยศ. คืออะไร: ความหมาย, วัตถุประสงค์ และการสนับสนุนทางการศึกษา",
9    "source": "blob",
10   "file_id": "1hWCEYjPtNGwTUlNm1e5_JdiYkxa_BhyA",
11   "blobType": "text/plain",
12   "description": "ทำความเข้าใจว่า กองทุนเงินให้กู้ยืมเพื่อการศึกษา (กยศ.) คืออะไร
13   บทบาทในการให้กู้ยืมเงินแก่นักเรียนนักศึกษาที่ขาดแคลนทุนทรัพย์เพื่อเป็นค่าเล่าเรียน
   ค่าใช้จ่ายเกี่ยวกับการศึกษา และค่าธรรมเนียมที่จำเป็น"

```

ภาพที่ 4.65 หน้าการตั้งค่าการกำหนดข้อมูลเมตาดาต้าซูปาเบส

The screenshot shows a dark-themed interface with the text "embedding vector" at the top. Below it, a single line of text displays a 10-dimensional vector: [0.0335708,0.05122791,-0.14564875,-0.06750433,0.04783069,-0.045752738,-0.0335708,0.05122791,-0.14564875,-0.06750433].

ภาพที่ 4.66 หน้าการค้นคืนข้อมูลเวกเตอร์ตัวเลขซูปาเบส

## 4.2 ผลการทดสอบ

การพัฒนาแชทบอทถามตอบด้วยโมเดลภาษาขนาดใหญ่ กรณีศึกษาของพัฒนานักศึกษามหาวิทยาลัยราชภัฏนครปฐม มีวัตถุประสงค์เพื่อพัฒนาระบบที่สามารถตอบคำถามจากข้อมูลภายในหน่วยงานได้อย่างถูกต้องและน่าเชื่อถือ โดยระบบที่พัฒนาขึ้นใช้เทคนิค Retrieval-Augmented Generation (RAG) ในการค้นคืนข้อมูลจากฐานความรู้ และใช้โมเดลภาษาขนาดใหญ่ในการสร้างคำตอบจากบริบทที่ค้นคืนมา เพื่อให้คำตอบมีความสอดคล้องกับข้อมูลต้นทางมากที่สุด

หลังจากการพัฒนาระบบเสร็จสิ้น คณะผู้จัดทำได้ดำเนินการทดสอบประสิทธิภาพของระบบ โดยใช้ชุดคำถามจำนวน 100 ข้อ ซึ่งครอบคลุมเนื้อหาที่เกี่ยวข้องกับกองพัฒนานักศึกษา ได้แก่ ข้อมูลกองทุนเงินให้กู้ยืมเพื่อการศึกษา (กยศ.) ทุนการศึกษา งานทหาร และนักศึกษาวิชาทหาร ชุดคำถามดังกล่าวถูกนำมาใช้เป็นข้อมูลทดสอบเพื่อประเมินว่าระบบสามารถค้นคืนข้อมูลที่เกี่ยวข้องและสร้างคำตอบที่ตรงกับคำถามได้มากน้อยเพียงใด


ในการทดสอบระบบ คณะผู้จัดทำได้กำหนดรูปแบบการทดลองทั้งหมด 8 รูปแบบ โดยปรับค่าพารามิเตอร์ที่เกี่ยวข้องกับกระบวนการค้นคืนข้อมูล ได้แก่ ขนาดของข้อความที่แบ่งเป็นส่วนย่อย (Chunk Size) จำนวนข้อความซ้อนทับระหว่างส่วนย่อย (Chunk Overlap) และจำนวนข้อมูลบริบทที่ระบบค้นคืนกลับมาใช้ในการตอบคำถาม (Top-k) การกำหนดรูปแบบการทดลองที่แตกต่างกันมีวัตถุประสงค์เพื่อเปรียบเทียบว่าการตั้งค่าพารามิเตอร์รูปแบบใดส่งผลให้ระบบสามารถตอบคำถามได้มีประสิทธิภาพมากที่สุด

ผลลัพธ์จากการตอบคำถามของระบบในแต่ละรูปแบบการทดลองถูกนำไปประเมินด้วยเครื่องมือประเมินหลายประเภท ได้แก่ RAGAS, DeepEval, TruLens และ LLM-as-a-Judge เพื่อวิเคราะห์คุณภาพของระบบในหลายมิติ เช่น ความเกี่ยวข้องของคำตอบกับคำถาม ความสอดคล้องของคำตอบกับข้อมูลอ้างอิง ความสามารถในการค้นคืนข้อมูลที่เกี่ยวข้อง และการลดโอกาสในการสร้างข้อมูลที่ไม่ปรากฏอยู่ในเอกสารต้นทาง การใช้เครื่องมือประเมินหลายรูปแบบช่วยให้สามารถตรวจสอบคุณภาพของระบบได้ครอบคลุมมากกว่าการพิจารณาคำตอบจากมุมมองเดียว

นอกจากนี้ คณะผู้จัดทำได้นำผลคะแนนจากเครื่องมือประเมินทั้งหมดมาวิเคราะห์เชิงสถิติเพื่อเปรียบเทียบประสิทธิภาพของการทดลองทั้ง 8 รูปแบบ และตรวจสอบความสอดคล้องของผลการประเมินจากเครื่องมือแต่ละประเภท โดยใช้ค่าสถิติ เช่น ค่าเฉลี่ย ส่วนเบี่ยงเบนมาตรฐาน ค่าสหสัมพันธ์ และค่าความสอดคล้องของตัวประเมิน ผลการทดสอบในหัวข้อนี้จึงเป็นหลักฐานสำคัญที่ใช้พิจารณาว่าระบบแชทบอทที่พัฒนาขึ้นสามารถตอบคำถามได้อย่างถูกต้อง น่าเชื่อถือ และเหมาะสมต่อการนำไปใช้งานจริงเพียงใด

#### 4.2.1 ผลการประเมินด้วย RAGAS

การประเมินด้วย RAGAS เป็นการประเมินประสิทธิภาพของระบบ RetrievalAugmented Generation (RAG) โดยพิจารณาคุณภาพของคำตอบและข้อมูลบริบทที่ระบบค้นคืนมาใช้ในการตอบคำถาม ในการทดสอบครั้งนี้ใช้ตัวชี้วัดหลัก 4 ด้าน ได้แก่ Answer Relevancy, Faithfulness, Context Precision และ Context Recall โดยคะแนนมีค่าอยู่ระหว่าง 0 ถึง 1 หากคะแนนมีค่าเข้าใกล้ 1 แสดงว่าผลการประเมินอยู่ในระดับที่ดี




ภาพที่ 4.67 ผลการเปรียบเทียบคะแนนการประเมินด้วย RAGAS

จากภาพที่ 4.67 พบว่า การทดลอง Exp 06 มีผลการประเมินด้วย RAGAS สูงที่สุดในทุกตัวชี้วัด ได้แก่ Answer Relevancy, Faithfulness, Context Precision และ Context Recall แสดงให้เห็นว่าการตั้งค่า Chunk Size 512, Chunk Overlap 64 และ Top-k 5 มีแนวโน้มให้ผลลัพธ์ที่เหมาะสมที่สุดเมื่อประเมินด้วย RAGAS โดยเฉพาะค่า Faithfulness ซึ่งสูงกว่าการทดลองอื่นสะท้อนให้เห็นว่าคำตอบของระบบมีความสอดคล้องกับข้อมูลบริบทที่ค้นคืนมาได้ดีกว่า อย่างไรก็ตาม ค่าคะแนนโดยรวมยังอยู่ในระดับไม่สูงมาก จึงแสดงให้เห็นว่าระบบยังควรได้รับการปรับปรุงเพิ่มเติมในด้านการค้นคืนข้อมูลและความเกี่ยวข้องของคำตอบกับคำถาม

#### 4.2.2 ผลการประเมินด้วย DeepEval

การประเมินด้วย DeepEval เป็นการประเมินคุณภาพของคำตอบที่ระบบสร้างขึ้น โดยพิจารณาความเกี่ยวข้องของคำตอบกับคำถาม ความสอดคล้องของคำตอบกับข้อมูลบริบท และความสามารถในการค้นคืนข้อมูลที่เกี่ยวข้องมาใช้ประกอบการตอบคำถาม ในการทดลองนี้ใช้ตัวชี้วัด 4 ด้าน ได้แก่ Answer Relevancy, Faithfulness, Contextual Precision และ Contextual Recall โดยคะแนนมีค่าอยู่ระหว่าง 0 ถึง 1 หากคะแนนมีค่าเข้าใกล้ 1 แสดงว่าผลการประเมินอยู่ในระดับที่ดี




ภาพที่ 4.68 ผลการเปรียบเทียบคะแนนการประเมินด้วย DeepEval

จากภาพที่ 4.68 พบว่า ผลการประเมินด้วย DeepEval ของแต่ละการทดลองมีค่าคะแนนแตกต่างกัน โดย Exp 06 มีความโดดเด่นด้านการค้นคืนข้อมูล เนื่องจากมีค่า Contextual Precision และ Contextual Recall สูงที่สุด แสดงให้เห็นว่าการตั้งค่า Chunk Size 512, Chunk Overlap 64 และ Top-k 5 มีแนวโน้มช่วยให้ระบบค้นคืนข้อมูลที่เกี่ยวข้องมาใช้ประกอบการตอบ คำถามได้ดีกว่ารูปแบบอื่น อย่างไรก็ตาม ค่าด้านการค้นคืนข้อมูลยังอยู่ในระดับไม่สูงมาก จึงสะท้อนให้เห็นว่าระบบยังควรได้รับการปรับปรุงเพิ่มเติมในด้านความแม่นยำและความครบถ้วนของข้อมูลบริบท

### 4.2.3 ผลการประเมินด้วย TruLens

การประเมินด้วย TruLens เป็นการประเมินคุณภาพของระบบถามตอบแบบ Retrieval-Augmented Generation (RAG) โดยใช้แนวคิด RAG Triad ซึ่งพิจารณาความสัมพันธ์ระหว่างคำถาม ข้อมูลบริบทที่ระบบค้นคืนมา และคำตอบที่ระบบสร้างขึ้น ในการทดลองนี้ใช้ตัวชี้วัดหลัก 3 ด้าน ได้แก่ Context Relevance, Groundedness และ Answer Relevance โดยคะแนนมีค่าอยู่ระหว่าง 0 ถึง 1 หากคะแนนมีค่าเข้าใกล้ 1 แสดงว่าผลการประเมินอยู่ในระดับที่ดี




ภาพที่ 4.69 ผลการเปรียบเทียบคะแนนการประเมินด้วย TruLens

จากภาพที่ 4.69 พบว่า ผลการประเมินด้วย TruLens ของแต่ละการทดลองมีค่าคะแนนแตกต่างกัน โดย Exp 06 มีผลการประเมินที่โดดเด่นในภาพรวม เนื่องจากมีค่าคะแนน Context Relevance, Groundedness และ Answer Relevance อยู่ในระดับค่อนข้างสูงเมื่อเปรียบเทียบกับ การทดลองอื่น แสดงให้เห็นว่าการตั้งค่า Chunk Size 512, Chunk Overlap 64 และ Top-k 5 มีแนวโน้มช่วยให้ระบบค้นคืนข้อมูลที่เกี่ยวข้องและสร้างคำตอบที่สอดคล้องกับบริบทได้ดีขึ้น อย่างไรก็ตาม คะแนนโดยรวมยังอยู่ในระดับไม่สูงมาก จึงสะท้อนให้เห็นว่าระบบยังควรได้รับการปรับปรุงเพิ่มเติมในด้านความเกี่ยวข้องของข้อมูลบริบท ความสอดคล้องของคำตอบกับข้อมูลที่ค้นคืนมา และความตรงประเด็นของคำตอบกับคำถาม

#### 4.2.4 ผลการประเมินด้วย LLM-as-a-Judge

การประเมินด้วย LLM-as-a-Judge เป็นการใช้โมเดลภาษาขนาดใหญ่ทำหน้าที่เป็นผู้ประเมินคำตอบของระบบ โดยพิจารณาคูณภาพของคำตอบจาก 3 ด้าน ได้แก่ Accuracy, Completeness และ Clarity ซึ่งเป็นการประเมินว่าคำตอบของระบบมีความถูกต้อง ครบถ้วน และ ชัดเจนมากน้อยเพียงใดเมื่อเปรียบเทียบกับคำตอบอ้างอิง โดยค่าคะแนนอยู่ระหว่าง 0 ถึง 1 หากคะแนนมีค่าเข้าใกล้ 1 แสดงว่าผลการประเมินอยู่ในระดับที่ดี




ภาพที่ 4.70 ผลการเปรียบเทียบคะแนนการประเมินด้วย LLM-as-a-Judge

จากภาพที่ 4.70 พบว่า การทดลอง Exp 06 มีผลการประเมินด้วย LLM-as-a-Judge สูงที่สุด โดยมีค่า Accuracy เท่ากับ 0.2610 ค่า Completeness เท่ากับ 0.2660 ค่า Clarity เท่ากับ 0.5690 และมีคะแนนเฉลี่ยเท่ากับ 0.3653 แสดงให้เห็นว่าการตั้งค่า Chunk Size 512, ChunkOverlap 64 และ Top-k 5 มีแนวโน้มช่วยให้ระบบสร้างคำตอบที่มีความถูกต้อง ครบถ้วน และชัดเจนกว่าการทดลองรูปแบบอื่นอย่างไรก็ตาม ค่า Accuracy และ Completeness ยังอยู่ในระดับไม่สูงมากเมื่อเทียบกับคะแนนเต็ม 1.0 สะท้อนให้เห็นว่าคำตอบของระบบยังมีข้อจำกัดด้าน ความถูกต้องและความครบถ้วนของเนื้อหา แม้ค่า Clarity จะสูงกว่าตัวชี้วัดอื่น แต่ระบบยังควรได้รับการปรับปรุงเพิ่มเติมเพื่อให้คำตอบมีความถูกต้องและครอบคลุมข้อมูลอ้างอิงมากยิ่งขึ้น

#### 4.2.5 สรุปผลการเปรียบเทียบและการวิเคราะห์เชิงสถิติ

จากกระบวนการประเมินผลระบบตามแผนภาพ เริ่มจากระบบสร้างคำตอบออกมาในรูปแบบ Generated Answer จากนั้นนำคำตอบดังกล่าวไปประเมินด้วยเครื่องมือประเมินผล 3 เครื่องมือ ได้แก่ RAGAS, DeepEval และ TruLens เพื่อวัดคุณภาพของคำตอบในหลายมิติ เช่น ความเกี่ยวข้องของบริบท ความสอดคล้องของคำตอบกับข้อมูลที่ค้นคืนมา และความเกี่ยวข้องของคำตอบกับคำถาม หลังจากนั้นนำผลการประเมินและคำตอบของระบบไปประเมินเพิ่มเติมด้วย Gemini LLM-as-a-Judge โดยพิจารณาจากเกณฑ์ Accuracy, Completeness และ Clarity เพื่อประเมินคุณภาพคำตอบในภาพรวม จากนั้นจึงนำคะแนนจากผู้ประเมินทั้งหมดมาวิเคราะห์เชิงสถิติ ได้แก่ Mean, Standard Deviation, Correlation และ Consistency เพื่อสรุปผลการทดลองและจัดทำรายงานผลการประเมินขั้นสุดท้าย



ภาพที่ 4.71 ผลการเปรียบเทียบคะแนนเฉลี่ยของแต่ละการทดลอง

ภาพที่ 4.71 คะแนนเฉลี่ยของแต่ละการทดลองมีความแตกต่างกัน โดย DeepEval ให้ค่าคะแนนสูงกว่าวิธีการประเมินอื่นในทุกการทดลอง ขณะที่ RAGAS และ TruLens มีค่าคะแนนค่อนข้างต่ำกว่า ส่วน LLM-as-a-Judge และ Final Combined มีแนวโน้มเปลี่ยนแปลงไปในทิศทางเดียวกันกับผลการประเมินโดยรวม 0.00 0.10 0.20 0.30 0.40 0.50 0.60 0.70 0.80 0.90 1.00 Exp 01 Exp 02 Exp 03 Exp 04 Exp 05 Exp 06 Exp 07 Exp 08 คะแนนการประเมิน การทดลอง ผลการเปรียบเทียบคะแนนเฉลี่ยของแต่ละการทดลอง RAGAS DeepEval TruLens LLM-as-a-Judge Final Combined 92 เมื่อพิจารณาคะแนน Final Combined พบว่า Exp 06 มีค่าสูงที่สุดเท่ากับ 0.3682 รองลงมาคือ Exp 02 เท่ากับ 0.3407 และ Exp 05 เท่ากับ 0.3166 แสดงให้เห็นว่า

การตั้งค่า Chunk Size 512, Chunk Overlap 64 และ Top-k 5 มีแนวโน้มให้ประสิทธิภาพโดยรวมดีที่สุดเมื่อพิจารณาาร่วมกัน จาก RAGAS, DeepEval, TruLens และ LLM-as-a-Judge ในทางตรงกันข้าม Exp 08 และ Exp 07 มีค่า Final Combined ต่ำที่สุด เท่ากับ 0.2294 และ 0.2356 ตามลำดับ สะท้อนให้เห็นว่าการตั้งค่า Chunk Overlap 128 อาจไม่เหมาะสม กับชุดข้อมูลและระบบที่ใช้ในการทดลองนี้ โดยสรุป Exp 06 จึงเป็นรูปแบบการตั้งค่าที่เหมาะสมที่สุด ในกลุ่มการทดลองทั้งหมด แม้ว่าคะแนนรวมยังอยู่ในระดับไม่สูงมากเมื่อเทียบกับคะแนนเต็ม 1.0 และระบบยังควรได้รับการปรับปรุงเพิ่มเติมทั้งด้านการค้นคืนข้อมูลและคุณภาพของคำตอบ

**ตารางที่ 4.1** ผลการวิเคราะห์ความสัมพันธ์และความสอดคล้องของเครื่องมือประเมิน

| รายการวิเคราะห์                                         | ค่าที่ได้ | ความหมาย                                |
|---------------------------------------------------------|-----------|-----------------------------------------|
| Pearson Correlation ระหว่าง RAGAS และ TruLens           | 0.9204    | มีความสัมพันธ์กันสูง                    |
| Pearson Correlation ระหว่าง RAGAS และ LLM-as-a-Judge    | 0.8625    | มีความสัมพันธ์กันสูง                    |
| Pearson Correlation ระหว่าง TruLens และ LLM-as-a-Judge  | 0.8605    | มีความสัมพันธ์กันสูง                    |
| Pearson Correlation ระหว่าง DeepEval และ LLM-as-a-Judge | 0.6196    | มีความสัมพันธ์ระดับปานกลาง              |
| Cronbach's Alpha                                        | 0.9249    | ประเมินทั้ง 4 แหล่งมีความสอดคล้องกันสูง |

จากตารางที่ 4.1 พบว่า ผลการวิเคราะห์ความสัมพันธ์ด้วยค่าสัมประสิทธิ์สหสัมพันธ์เพียร์สันระหว่างเครื่องมือประเมินส่วนใหญ่มีความสัมพันธ์ในระดับสูง โดย RAGAS และ TruLens มีความสัมพันธ์สูงที่สุด เท่ากับ 0.9204 รองลงมาคือ RAGAS และ LLM-as-a-Judge เท่ากับ 0.8625 และ TruLens กับ LLM-as-a-Judge เท่ากับ 0.8605 แสดงให้เห็นว่าเครื่องมือทั้งสามมีแนวโน้มให้ผลการประเมินไปในทิศทางเดียวกัน ส่วน DeepEval และ LLM-as-a-Judge มีความสัมพันธ์เท่ากับ 0.6196 ซึ่งอยู่ในระดับปานกลาง สะท้อนว่า DeepEval อาจมีหลักเกณฑ์หรือแนวทางการให้คะแนนแตกต่างจากเครื่องมืออื่นบางส่วน นอกจากนี้ ค่า Cronbach's Alpha เท่ากับ 0.9249 แสดงให้เห็นว่าผลการประเมินจากเครื่องมือทั้ง 4 วิธีมีความสอดคล้องกันในระดับสูง และสามารถใช้ร่วมกันเพื่อประเมินประสิทธิภาพของระบบได้อย่างน่าเชื่อถือ

ตารางที่ 4.2 ค่าเฉลี่ยและส่วนเบี่ยงเบนมาตรฐานของผลการประเมิน

| เครื่องมือประเมิน | Mean   | SD     |
|-------------------|--------|--------|
| RAGAS             | 0.1729 | 0.2891 |
| DeepEval          | 0.5210 | 0.1777 |
| TruLens           | 0.1961 | 0.2964 |
| LLM-as-a-Judge    | 0.2791 | 0.3254 |
| Final Combined    | 0.2879 | 0.2716 |

จากตารางที่ 4.2 พบว่า DeepEval มีค่าเฉลี่ยสูงสุด เท่ากับ 0.5210 รองลงมาคือ Final Combined เท่ากับ 0.2879, LLM-as-a-Judge เท่ากับ 0.2791, TruLens เท่ากับ 0.1961 และ RAGAS เท่ากับ 0.1729 ตามลำดับ แสดงให้เห็นว่า DeepEval มีแนวโน้มให้คะแนนสูงกว่าเครื่องมือประเมินอื่น เมื่อพิจารณาค่าส่วนเบี่ยงเบนมาตรฐาน พบว่า DeepEval มีค่า SD ต่ำที่สุด เท่ากับ 0.1777 สะท้อนว่าผลการประเมินมีการกระจายตัวน้อยและมีความสม่ำเสมอมากกว่าเครื่องมืออื่น ขณะที่ LLM-as-a-Judge มีค่า SD สูงที่สุด เท่ากับ 0.3254 แสดงให้เห็นว่าคะแนนมีการกระจายตัวค่อนข้างมาก ส่วนค่า Final Combined มีค่าเฉลี่ยเท่ากับ 0.2879 และค่า SD เท่ากับ 0.2716 ซึ่งสะท้อนผลการประเมินโดยรวมจากเครื่องมือทั้งหมด

#### 4.3 สรุปผลการทดสอบ

จากการทดสอบการพัฒนาแชทบอทถามตอบด้วยโมเดลภาษาขนาดใหญ่ ภาควิชาการศึกษาคณะศึกษาศาสตร์ มหาวิทยาลัยราชภัฏนครปฐม โดยใช้ชุดคำถามจำนวน 100 ข้อ และกำหนดการทดลองทั้งหมด 8 รูปแบบ พบว่าการตั้งค่าของระบบมีผลต่อคุณภาพของคำตอบที่ระบบสร้างขึ้น โดยเฉพาะค่าพารามิเตอร์ Chunk Size, Chunk Overlap และ Top-k ซึ่งส่งผลต่อการค้นคืนข้อมูลบริบทและการนำข้อมูลมาใช้ในการสร้างคำตอบ

ผลการประเมินด้วย RAGAS, DeepEval, TruLens และ LLM-as-a-Judge พบว่า การทดลอง Exp 06 ซึ่งใช้ Chunk Size 512, Chunk Overlap 64 และ Top-k 5 มีผลการประเมินโดยรวมดีที่สุดเมื่อเปรียบเทียบกับ การทดลองอื่น โดยมีค่า Final Combined สูงที่สุด เท่ากับ 0.3682 แสดงให้เห็นว่ารูปแบบการตั้งค่านี้มีแนวโน้มเหมาะสมที่สุดสำหรับระบบที่พัฒนาขึ้น เนื่องจากสามารถค้นคืนข้อมูลและสร้างคำตอบได้ดีกว่ารูปแบบอื่นในภาพรวม

นอกจากนี้ ผลการวิเคราะห์เชิงสถิติพบว่าผู้ประเมินทั้ง 4 แหล่ง ได้แก่ RAGAS, DeepEval, TruLens และ LLM-as-a-Judge มีความสอดคล้องกันในระดับสูง โดยมีค่า Cronbach's Alpha เท่ากับ 0.9249 แสดงให้เห็นว่าผลการประเมินจากแต่ละเครื่องมือมีแนวโน้มไปในทิศทางเดียวกัน และสามารถนำมาใช้ประกอบการพิจารณาประสิทธิภาพของระบบได้

อย่างไรก็ตาม คะแนนเฉลี่ยรวมของระบบยังอยู่ในระดับไม่สูงมากเมื่อเทียบกับคะแนนเต็ม 1.0 สะท้อนให้เห็นว่าระบบยังมีข้อจำกัดในด้านการค้นคืนข้อมูลบริบท ความถูกต้องของคำตอบ และความครบถ้วนของข้อมูลที่นำมาตอบคำถาม ดังนั้น ระบบยังควรได้รับการปรับปรุงเพิ่มเติม เช่น การ

ปรับปรุงคุณภาพข้อมูลต้นทาง การแบ่งข้อความให้เหมาะสมมากขึ้น การปรับค่าการค้นคืนข้อมูล และการปรับ Prompt เพื่อให้ระบบสามารถตอบคำถามได้ถูกต้อง ครบถ้วน และน่าเชื่อถือมากยิ่งขึ้น

## บทที่ 5

### สรุปผลและข้อเสนอแนะ

ในบทนี้จะกล่าวถึงสรุปผลและข้อเสนอแนะของการพัฒนาระบบแชทบอทถามตอบด้วยโมเดลภาษาขนาดใหญ่กรณีศึกษาของพัฒนานักศึกษามหาวิทยาลัยราชภัฏนครปฐม ซึ่งมีรายละเอียดดังต่อไปนี้

#### 5.1 สรุปผล

จากการพัฒนาระบบแชทบอทถามตอบด้วยโมเดลภาษาขนาดใหญ่ กรณีศึกษาของพัฒนานักศึกษา มหาวิทยาลัยราชภัฏนครปฐม ผู้วิจัยได้พัฒนาระบบโดยประยุกต์ใช้เทคนิค Retrieval-Augmented Generation (RAG) ร่วมกับฐานข้อมูลเวกเตอร์ Supabase และโมเดลภาษาขนาดใหญ่ Google Gemini เพื่อให้ระบบสามารถค้นคืนข้อมูลที่เกี่ยวข้องจากฐานความรู้และนำมาใช้ในการสร้างคำตอบสำหรับผู้ใช้งาน โดยมี n8n ทำหน้าที่จัดการ Workflow ของระบบ และใช้ LINE Messaging API เป็นช่องทางในการรับคำถามและส่งคำตอบกลับไปยังผู้ใช้งาน

ระบบสามารถรับคำถามจากผู้ใช้งานผ่าน LINE จากนั้นส่งข้อมูลเข้าสู่ Workflow ของ n8n เพื่อประมวลผลและค้นคืนข้อมูลจากฐานข้อมูลเวกเตอร์ ก่อนส่งข้อมูลที่เกี่ยวข้องให้โมเดล Google Gemini ใช้ในการสร้างคำตอบ และส่งผลลัพธ์กลับไปยังผู้ใช้งานผ่าน LINE โดยภายใน n8n ยังมีการใช้ Code Node สำหรับจัดรูปแบบคำตอบ และ HTTP Request Node สำหรับส่งข้อมูลกลับไปยัง LINE Messaging API

ในการทดสอบระบบ ผู้วิจัยใช้ชุดคำถามจำนวน 100 ข้อ และกำหนดรูปแบบการทดลองทั้งหมด 8 รูปแบบ โดยปรับค่า Chunk Size, Chunk Overlap และ Top-k เพื่อเปรียบเทียบประสิทธิภาพของระบบ RAG

จากผลการทดลองพบว่า Exp 06 ซึ่งใช้ค่า Chunk Size = 512, Chunk Overlap = 64 และ Top-k = 5 ให้ผลการประเมินโดยรวมดีที่สุด โดยมีค่า Final Combined เท่ากับ 0.3682

เมื่อประเมินด้วย RAGAS, DeepEval, TruLens และ LLM-as-a-Judge พบว่า Exp 06 มีผลการประเมินโดยรวมดีที่สุดเมื่อเปรียบเทียบกับารทดลองรูปแบบอื่น อย่างไรก็ตาม คะแนนโดยรวมยังไม่สูงมาก โดยเฉพาะด้านความถูกต้องและความครบถ้วนของคำตอบ จึงแสดงให้เห็นว่าระบบสามารถนำมาใช้เป็นต้นแบบในการตอบคำถามเกี่ยวกับข้อมูลของพัฒนานักศึกษาได้ แต่ยังสามารถพัฒนาประสิทธิภาพเพิ่มเติมได้

## 5.2 ปัญหาและข้อจำกัด

การพัฒนาระบบแชทบอทถามตอบด้วยโมเดลภาษาขนาดใหญ่กรณีศึกษาของพัฒนานักศึกษามหาวิทยาลัยราชภัฏนครปฐมครั้งนี้พบปัญหาและข้อจำกัดบางประการ ดังนี้

5.2.1 ระบบยังมีข้อจำกัดด้านความถูกต้องและความครบถ้วนของคำตอบ

5.2.2 ประสิทธิภาพของระบบขึ้นอยู่กับคุณภาพและความครบถ้วนของข้อมูลในฐานความรู้ หากข้อมูลที่จัดเก็บในฐานข้อมูลไม่ครบถ้วนหรือไม่เป็นปัจจุบัน อาจส่งผลต่อข้อมูลที่ระบบค้นคืนและคำตอบที่สร้างขึ้น

5.2.3 กระบวนการค้นคืนข้อมูลยังมีข้อจำกัด แม้ Exp 06 จะให้ผลดีที่สุดจากการทดลองทั้งหมด แต่คะแนนการประเมินโดยรวมยังไม่สูงมาก จึงควรปรับปรุงกระบวนการ Retrieval และการจัดเตรียมข้อมูลเพิ่มเติม

5.2.4 ระบบมีการพึ่งพาการเชื่อมต่อระหว่าง LINE Messaging API, n8n, Supabase และโมเดล Google Gemini ดังนั้นหากส่วนใดส่วนหนึ่งของระบบไม่สามารถให้บริการได้ อาจส่งผลต่อกระบวนการตอบคำถามของ Chatbot

5.2.5 การทดลองประสิทธิภาพของระบบใช้ชุดคำถามจำนวน 100 ข้อ จึงยังอาจไม่ครอบคลุมรูปแบบคำถามทั้งหมดที่อาจเกิดขึ้นจากการใช้งานจริง

## 5.3 แนวทางการนำไปใช้

การพัฒนาระบบแชทบอทถามตอบด้วยโมเดลภาษาขนาดใหญ่กรณีศึกษาของพัฒนานักศึกษามหาวิทยาลัยราชภัฏนครปฐมนี้สามารถนำไปใช้และต่อยอดได้ในหลายด้าน ดังนี้

5.3.1 สามารถนำระบบแชทบอทไปใช้เป็นช่องทางสำหรับให้นักศึกษาสอบถามข้อมูลของกองพัฒนานักศึกษาผ่าน LINE โดยไม่จำเป็นต้องค้นหาข้อมูลจากหลายช่องทาง

5.3.2 สามารถนำระบบไปใช้สำหรับตอบคำถามเกี่ยวกับข้อมูลด้าน กยศ.ทุนการศึกษา งานทหาร และนักศึกษาวิชาทหาร ซึ่งเป็นกลุ่มข้อมูลที่กำหนดไว้ในขอบเขตของระบบ

5.3.3 สามารถนำ n8n มาใช้ในการจัดการ Workflow ของระบบ เช่น รับข้อมูลจาก LINE ประมวลผลข้อมูล เรียกใช้ฐานข้อมูลเวกเตอร์ ส่งข้อมูลให้โมเดล AI และจัดรูปแบบคำตอบก่อนส่งกลับไปยัง LINE โดย n8n รองรับการเชื่อมต่อบริการต่าง ๆ ผ่าน API และ Workflow แบบอัตโนมัติ

5.3.4 สามารถนำการตั้งค่า Exp 06 ได้แก่ Chunk Size 512, Chunk Overlap 64 และ Top-k 5 ไปใช้เป็นค่าตั้งต้นในการพัฒนาระบบ เนื่องจากเป็นรูปแบบที่ให้ผลการประเมินโดยรวมดีที่สุดจากการทดลองทั้ง 8 รูปแบบ

## 5.4 ข้อเสนอแนะ

การพัฒนาระบบแชทบอทถามตอบด้วยโมเดลภาษาขนาดใหญ่กรณีศึกษาของพัฒนานักศึกษามหาวิทยาลัยราชภัฏนครปฐมสำหรับการพัฒนาระบบในอนาคต มีข้อเสนอแนะดังนี้

5.4.1 ควรปรับปรุงและเพิ่มข้อมูลในฐานความรู้ของระบบให้มีความครบถ้วน ถูกต้อง และเป็นปัจจุบัน เพื่อเพิ่มประสิทธิภาพในการค้นคืนข้อมูลและการตอบคำถาม

5.4.2 ควรทดลองปรับค่า Chunk Size, Chunk Overlap และ Top-k เพิ่มเติม รวมถึงศึกษาวิธีการค้นคืนข้อมูลรูปแบบอื่น เพื่อเพิ่มความแม่นยำของระบบ

5.4.3 ควรปรับปรุง Prompt และคำสั่งของ AI Agent ใน n8n เพื่อควบคุมให้โมเดลสร้างคำตอบจากข้อมูลที่ค้นคืนได้ และลดการสร้างข้อมูลที่ไม่มีอยู่ในฐานความรู้ โดยในระบบที่พัฒนามีการกำหนดคำสั่งให้ค้นหาข้อมูลจาก Supabase และแจ้งผู้ใช้เมื่อไม่พบข้อมูลที่ตรงกับคำถาม

5.4.4 ควรเพิ่มจำนวนและความหลากหลายของชุดคำถามสำหรับการทดสอบ เพื่อให้สามารถประเมินประสิทธิภาพของระบบได้ครอบคลุมรูปแบบการใช้งานจริงมากขึ้น

## บรรณานุกรม

- จตุรงค์ จิตติยพล, และ พงษ์ศักดิ์ ดรพินิจ. (2565). การพัฒนาระบบสารสนเทศเพื่อการเรียนรู้ คำศัพท์เครือข่ายคอมพิวเตอร์ผ่านแอปพลิเคชัน Line Chatbot. วารสารสหวิทยาการวิจัยและวิชาการ, 2(4), 607–618.
- ชนาธิป ชื่นมนัส, วรากร เลื่องลือภูมิ, กิตติกร วิริยะศาสตร์, ผกามาศ วงศ์สาย, อุบล ธงสถาพร วัฒนา, วิชัย แผ้วเกษม, และ พันธุ์เทพ แก้วมงคล. (2567). การวิจัยและพัฒนาระบบ สนทนาอัตโนมัติในข้อมูลป้องกันประเทศ. วารสารวิชาการเทคโนโลยีป้องกันประเทศ, 6(14).
- นฤพธิดา สุตสงวน. (2567). การพัฒนาระบบสนทนาโต้ตอบอัจฉริยะเพื่อให้คำปรึกษาการศึกษา และ แนะนำการศึกษาต่อ มหาวิทยาลัยราชภัฏบุรีรัมย์.
- มนต์ทิชา รัตนพันธ์, และ ฉัตรวดี สายใยทอง. (2566). การพัฒนา Line Chatbot สำหรับงานบริการ ด้านงานวิจัย กรณีศึกษาสถาบันวิจัยและพัฒนา มหาวิทยาลัยเทคโนโลยีราชมงคลธัญบุรี. วารสารวิจัยประยุกต์ด้านวิทยาศาสตร์และเทคโนโลยี, 22(1), 78–89.
- พรชัย จันทรถาวร, ปุณ เทียงบุรณธรรม, ฉวีวรรณ เค้นไพบูลย์, Supawatanakorn Wongthanavas, และ Somkid Keawthip. (2567). เมืองสู่เมืองแห่งการเรียนรู้ของไทย: การสังเคราะห์ งานวิจัยโดยแบบจำลองภาษาขนาดใหญ่. วารสารวิชาการ
- ภูมिरพี เมเยอร์. (2567). ระบบการเรียนรู้ปฏิบัติการร่วมกันจากระยะไกลร่วมกับโมเดลภาษาขนาดใหญ่ บนเว็บแอปพลิเคชันสำหรับการทดลองสอบเทียบเทอร์โมคัปเปิล [วิทยานิพนธ์, จุฬาลงกรณ์มหาวิทยาลัย]. Chulalongkorn University Theses and Dissertations.
- สุมนา บุชบก, ญัฐพร เพ็ชรพงษ์, และ จิรณัฐ สิงโตแก้ว. (2563). การพัฒนาแอปพลิเคชัน Chatbot สำหรับงานบริการนักศึกษา กรณีศึกษากองพัฒนานักศึกษา มหาวิทยาลัยเทคโนโลยีราชมงคลสุวรรณภูมิ. วารสารวิจัย มหาวิทยาลัยเทคโนโลยีราชมงคลธัญบุรี, 19(2), 85–94.
- อัคริมา สุ่มมาตย์, นิตยา ศรีวรรเดชไพศาล, ระพีพัฒน์ ปิยะนาจ, พีรณัฐ จันทรมนิม, วิศรุต ศิละลาย, และ กานดา สายแก้ว. (2567). การพัฒนา Chatbot AI ด้วยเครื่องมือ Dialogflow เพื่อ เพิ่มประสิทธิภาพการทำงานด้านการตอบคำถามผู้ใช้บริการห้องสมุด. PULINET Journal.
- ประทีป หมื่นทิส, และ สุขุมล กิตติสิน. (2568). การพัฒนาแชทบอทบริการลูกค้าที่เข้าใจบริบทและ เลือกใช้เครื่องมือโดยอัตโนมัติด้วยแบบจำลองภาษาขนาดใหญ่และ LangChain. วารสาร งานวิจัยและพัฒนาเชิงประยุกต์โดยสมาคม ECTI, 5(2), 11–24.
- สุ่มมาตย์, อ., ศรีวรรเดชไพศาล, น., มีกฤษ, ด., วรรณพราหมณ์, จ., บุตรโยจันโท, ส., สัพโส, ส., & สายแก้ว, ก. (2026). พลิกโฉมบริการตอบคำถามห้องสมุด มข.: จากแชทบอทธรรมดาสู่ AI อัจฉริยะบน LINE. PULINET Journal, 13(1), A107–A118.
- Mekara, B., Khunpatwattana, W., & Batzinger, R. P. (2023). Large language models like ChatGPT bring new challenges to higher education
- DeepEval. (2026). Answer relevancy metric. DeepEval Documentation.
- DeepEval. (2026). Faithfulness metric. DeepEval Documentation.

- Es, S., James, J., Espinosa-Anke, L., & Schockaert, S. (2023). RAGAS: Automated evaluation of retrieval augmented generation. *arXiv*
- Google AI for Developers. (2026). Generating content with the Gemini API. Google AI Documentation.
- Lewis, P., Perez, E., Piktus, A., Petroni, F., Karpukhin, V., Goyal, N., Küttler, H., Lewis, M., Yih, W., Rocktäschel, T., Riedel, S., & Kiela, D. (2020). Retrieval-augmented generation for knowledge-intensive NLP tasks. *Advances in Neural Information Processing Systems*, 33.
- Ollama. (2026). Embeddings. Ollama Documentation. Retrieved June 14, 2026, from <https://docs.ollama.com/capabilities/embeddings>
- pgvector. (2026). pgvector: Open-source vector similarity search for Postgres. GitHub.
- TruLens. (2026). RAG triad. TruLens Documentation.
- Es, S., James, J., Espinosa-Anke, L., & Schockaert, S. (2023). RAGAS: Automated evaluation of retrieval augmented generation. *Proceedings of the 17th Conference of the European Chapter of the Association for Computational Linguistics: System Demonstrations*, 150–155.
- Liu, Y., Iyer, D., Xu, Y., Wang, S., Xu, R., & Zhu, C. (2023). G-Eval: NLG evaluation using GPT-4 with better human alignment. In *Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing* (pp. 2511–2522). Association for Computational Linguistics.
- TruLens. (n.d.). Feedback functions for LLM and RAG evaluation. TruLens Documentation.
- Zheng, L., Chiang, W.-L., Sheng, Y., Zhuang, S., Wu, Z., Zhuang, Y., Lin, Z., Li, Z., Li, D., Xing, E. P., Zhang, H., Gonzalez, J. E., & Stoica, I. (2023). Judging LLM-as-a-judge with MT-Bench and Chatbot Arena. *Advances in Neural Information Processing Systems*, 36.
- Jaroenrue, Y., Kaewboonma, N., Ruangrajitpakorn, T., & Panawong, J. (2026). Development of generative chatbot towards Thai rice knowledge using retrieval-augmented generation. *Engineering Access*, 12(2), 309–317.
- Rattananimit, W., & Sakchaikul, J. (2026). Efficacy assessment of a RAG-based chatbot for educational computer programming.

## ภาคผนวก ก

### Workflow การทำงานของระบบ LINE Chatbot และระบบ RAG

## ภาคผนวก ก

### Workflow การทำงานของระบบ LINE Chatbot และระบบ RAG ด้วย n8n

#### 1. Workflow การทำงานของ LINE Chatbot



จากภาพที่ ก-1 แสดง Workflow การทำงานของระบบ LINE Chatbot ที่พัฒนาด้วย n8n

การทำงานของระบบประกอบด้วยขั้นตอนหลักดังนี้

##### 1.1 Webhook

เป็นจุดเริ่มต้นของ Workflow ทำหน้าที่รับข้อมูลข้อความที่ผู้ใช้งานส่งเข้ามาจาก LINE และส่งข้อมูลเข้าสู่กระบวนการทำงานของ n8n

##### 1.2 Edit Fields

ทำหน้าที่จัดเตรียมและกำหนดข้อมูลที่ได้รับจาก Webhook ให้อยู่ในรูปแบบที่เหมาะสมสำหรับนำไปประมวลผลในขั้นตอนถัดไป

##### 1.3. AI Agent

เป็นส่วนหลักในการประมวลผลคำถามของผู้ใช้งาน โดยทำหน้าที่ประสานการทำงานระหว่างแบบจำลองภาษา ระบบความจำ และเครื่องมือสำหรับค้นคืนข้อมูล เพื่อสร้างคำตอบที่เหมาะสมกับคำถาม

##### 1.4 Google Gemini Chat Model

ทำหน้าที่เป็นแบบจำลองภาษาสำหรับประมวลผลคำถามและสร้างคำตอบ โดย AI Agent จะส่งข้อมูลที่เกี่ยวข้องให้แบบจำลองใช้ในการสร้างคำตอบ

### 1.5 Simple Memory

ใช้สำหรับจัดเก็บบริบทหรือประวัติการสนทนา เพื่อช่วยให้ระบบสามารถประมวลผลคำถามโดยคำนึงถึงบริบทของการสนทนาได้

### 1.6 Supabase Vector Store

ทำหน้าที่เป็นฐานข้อมูลเวกเตอร์สำหรับจัดเก็บข้อมูลความรู้ที่ผ่านกระบวนการสร้าง Embedding แล้ว เมื่อมีคำถามเข้ามา ระบบสามารถค้นคืนข้อมูลที่มีความเกี่ยวข้องกับคำถามเพื่อนำมาใช้ประกอบการสร้างคำตอบ

### 1.7 Ollama Embeddings

ทำหน้าที่แปลงข้อมูลและคำถามให้อยู่ในรูปแบบเวกเตอร์ โดยใช้สำหรับกระบวนการค้นคืนข้อมูลจาก Supabase Vector Store


### 1.8 Code

ทำหน้าที่ประมวลผลหรือจัดรูปแบบข้อมูลที่ได้จาก AI Agent ก่อนส่งต่อไปยังขั้นตอนการส่งคำตอบกลับไปยัง LINE

### 1.9 HTTP Request

ทำหน้าที่ส่งคำตอบที่ผ่านการประมวลผลแล้วกลับไปยัง LINE ผ่านการเรียกใช้งาน API

## 2. Workflow การจัดเตรียมข้อมูลและระบบ RAG



จากภาพที่ ก-2 แสดง Workflow การจัดเตรียมข้อมูลและจัดเก็บข้อมูลสำหรับระบบ Retrieval-Augmented Generation (RAG) ที่พัฒนาด้วย n8n

การทำงานของระบบประกอบด้วยขั้นตอนหลักดังนี้

#### 2.1 Google Drive Trigger

ทำหน้าที่ตรวจสอบและรับไฟล์เอกสารจาก Google Drive เพื่อเริ่มกระบวนการจัดเตรียมข้อมูลเข้าสู่ระบบ RAG

#### 2.2 Loop Over Items

ทำหน้าที่วนประมวลผลไฟล์ที่ได้รับเข้ามาทีละรายการ เพื่อให้ระบบสามารถจัดการเอกสารแต่ละไฟล์ได้อย่างเป็นลำดับ

#### 2.3 Edit Fields

ทำหน้าที่จัดเตรียมและกำหนดข้อมูลที่จำเป็นสำหรับการประมวลผลเอกสารในขั้นตอนถัดไป

#### 2.4 Download File

ทำหน้าที่ดาวน์โหลดไฟล์จากแหล่งจัดเก็บ เพื่อนำไฟล์เข้าสู่กระบวนการสกัดข้อมูล

#### 2.5 Switch

ใช้สำหรับตรวจสอบหรือแยกประเภทของไฟล์ เพื่อกำหนดกระบวนการประมวลผลให้เหมาะสมกับประเภทของเอกสาร

#### 2.6 Extract From File

ทำหน้าที่สกัดข้อความหรือข้อมูลจากไฟล์เอกสาร เพื่อเปลี่ยนข้อมูลให้อยู่ในรูปแบบที่สามารถนำไปประมวลผลต่อได้

#### 2.7 Edit Fields / Code / Split Out

ข้อมูลที่สกัดได้จะถูกจัดรูปแบบ ประมวลผล และแยกข้อมูลออกเป็นส่วนที่เหมาะสมสำหรับการสร้างฐานความรู้

#### 2.8 Recursive Character Text Splitter

ทำหน้าที่แบ่งข้อความจากเอกสารออกเป็นส่วนย่อยหรือ Chunk เพื่อให้สามารถนำไปสร้าง Embedding และค้นคืนข้อมูลได้อย่างมีประสิทธิภาพ

#### 2.9 Default Data Loader

ทำหน้าที่จัดเตรียมข้อมูลเอกสารให้อยู่ในรูปแบบที่สามารถนำเข้าสู่กระบวนการสร้าง Embedding และจัดเก็บใน Vector Store

#### 2.10 Ollama Embeddings

ทำหน้าที่แปลงข้อความแต่ละส่วนให้อยู่ในรูปแบบเวกเตอร์ โดยใช้ Embedding Model ของ Ollama เพื่อให้สามารถค้นหาข้อมูลตามความคล้ายคลึงทางความหมายได้

#### 2.11 Supabase Vector Store

ทำหน้าที่จัดเก็บข้อมูลที่ผ่านกระบวนการสร้าง Embedding แล้ว พร้อมข้อมูลที่เกี่ยวข้อง เพื่อใช้เป็นฐานความรู้สำหรับระบบ RAG

ภาคผนวก ข  
การสร้างเครื่องมือประเมินด้วยเทคโนโลยี AI

## ภาคผนวก ข

### การสร้างเครื่องมือประเมินด้วยเทคโนโลยี AI

#### 1.Ragas

##### 1.1 Prompt ในการสร้างเครื่องมือประเมิน

คุณคือ Senior Python Developer และ AI Evaluation Engineer ช่วยเขียนโปรแกรม Python สำหรับประเมินระบบ RAG ด้วย Ragas โดยใช้ Gemini API เป็น LLM Judge และ Ollama เป็น Embedding Model โปรแกรมต้องอ่านข้อมูลจากไฟล์ raw rag results json ซึ่งมี records ประกอบด้วย experiment id, config, metrics input ซึ่งภายในมี question, ground truth, generated answer และ retrieved contexts รวมถึง metadata ใช้ Ragas Metrics จำนวน 4 ตัว ได้แก่ answer relevancy, faithfulness, context precision และ context recall โดยใช้ Gemini Model จากไฟล์ ENV ผ่าน Gemini API Key หรือ Google API Key และอ่านชื่อโมเดลจากตัวแปร RAGAS Gemini Model หากไม่มีให้ใช้ Gemini 2.5 Flash Lite เป็นค่าเริ่มต้น ใช้ Ollama Embedding จากตัวแปร RAGAS Embedding Model หากไม่มีให้ใช้ nomic embed text latest เป็นค่าเริ่มต้น กำหนด temperature เป็น 0 และ raise exceptions เป็น false มีระบบ Retry สูงสุด 10 ครั้งสำหรับข้อผิดพลาดประเภท 429, 503, Unavailable, Resource Exhausted, Rate Limit และ Invalid JSON โดยใช้ Linear Backoff และคำนวณ average score จากคะแนนของ Ragas Metrics ทั้ง 4 ตัว ให้ดึง q id จาก metrics input q id ก่อน และหากไม่มีให้ใช้ Regular Expression รูปแบบ id ตามด้วยตัวเลขจาก experiment id หากยังไม่พบให้กำหนดค่าที่เหมาะสม และสร้าง base experiment id โดยตัดส่วน id และตัวเลขออกจาก experiment id รองรับการทำงานต่อจากผลลัพธ์เดิมด้วย Resume เพื่อข้าม Record ที่ประเมินสำเร็จแล้ว รองรับการประเมินเฉพาะรายการที่เคยเกิด Invalid JSON Error โดยใช้ตัวเลือก Only Invalid JSON Errors และหากประเมินสำเร็จให้ลบ Error เดิมของ Record นั้นออก ต้องบันทึก Checkpoint หลังประเมินทุก Record และป้องกันข้อมูลซ้ำด้วยการ Deduplicate ตาม record experiment id รองรับ Command Line Arguments ได้แก่ input, output dir, limit, only experiment, sleep, resume และ only invalid json errors โปรแกรมต้องสร้าง Output จำนวน 4 ไฟล์ ได้แก่ ragas results detail json, ragas results detail csv, ragas results summary json และ ragas results summary csv โดย Summary ต้องจัดกลุ่มตาม base experiment id คำนวณค่าเฉลี่ยของ answer relevancy, faithfulness, context precision, context recall และ overall average score จากนั้นเรียงลำดับจากคะแนนรวมสูงไปต่ำ ให้ใช้ Libraries ได้แก่ ragas, langchain google genai, ollama, datasets, pandas และ python dotenv โดยแบ่งโค้ดออกเป็น 7 ส่วน ได้แก่ CONFIG, HELPERS, RAGAS EMBEDDINGS, RAGAS EVALUATION, CHECKPOINT และ RESUME, SUMMARY และ MAIN เขียนเป็น Python เต็มไฟล์ที่สามารถใช้งานจริงได้ มี Type Hints, Comments, Docstrings และ main ห้ามเขียน Pseudocode และต้องรองรับภาษาไทยทั้งตอนอ่านและเขียนไฟล์ โดยไฟล์ CSV ต้องรองรับภาษาไทยอย่างถูกต้องและใช้ UTF 8 with BOM ในการบันทึกข้อมูล

## 2. Deepeval

### 2.1 Prompt ในการสร้างเครื่องมือประเมิน

ช่วยเขียนโปรแกรม Python สำหรับประเมินผลระบบ RAG ด้วย DeepEval โดยใช้ Gemini API เป็น LLM Judge โปรแกรมต้องอ่านข้อมูลจากไฟล์ JSON ที่มีโครงสร้างหลักเป็น records โดยแต่ละ record มีข้อมูลอย่างน้อย ได้แก่ experiment id, config, metrics input question, metrics input ground truth, metrics input generated answer, metrics input retrieved contexts และ metadata ใช้ DeepEval สำหรับประเมินคุณภาพคำตอบของระบบ RAG ด้วยตัวชี้วัดจำนวนสี่ตัว ได้แก่ Answer Relevancy, Faithfulness, Contextual Precision และ Contextual Recall โดยไม่ต้องใช้ Contextual Relevancy ให้สร้างคลาส Gemini Judge ที่สืบทอดจาก DeepEval Base LLM โดยรับ API Key และชื่อโมเดล สร้าง Client ด้วย Google GenAI และมีฟังก์ชันสำหรับโหลดโมเดล ฟังก์ชันสำหรับสร้างคำตอบ ฟังก์ชันสร้างคำตอบแบบอะซิงโครนัส และฟังก์ชันสำหรับเรียกชื่อโมเดล โดยฟังก์ชันสร้างคำตอบต้องเรียก Gemini API ผ่าน Client Models Generate Content และหาก Gemini ไม่ส่งข้อความกลับมาให้แสดงข้อผิดพลาด อ่าน API Key จากไฟล์ ENV โดยใช้ Gemini API Key หรือ Google API Key อ่านชื่อโมเดลจากตัวแปรสภาพแวดล้อม DeepEval Gemini Model หากไม่มีให้ใช้ Gemini 2.5 Flash Lite เป็นค่าเริ่มต้น และอ่านค่า Threshold จากตัวแปรสภาพแวดล้อม DeepEval Threshold หากไม่มีให้ใช้ค่า 0.5 สร้างระบบ Retry สำหรับข้อผิดพลาดที่เกิดจากโมเดลภาษาหรือ API โดยให้ทำการ Retry เมื่อพบข้อผิดพลาดประเภท 503, Unavailable, Service Unavailable, The Model Is Overloaded, 429, Resource Exhausted, Rate Limit และ Invalid JSON โดยกำหนดจำนวน Retry สูงสุดสิบครั้งและรอสามสิบวินาทีต่อครั้ง ในการสร้างตัวชี้วัดให้ใช้ค่า Threshold ตามที่กำหนด ใช้ Gemini Judge เป็นโมเดล กำหนดให้ไม่ต้องสร้างเหตุผลประกอบคะแนน และใช้การประเมินแบบไม่ทำงานพร้อมกัน สร้างฟังก์ชัน Evaluate Record โดยรับ Record, Judge และ Threshold จากนั้นดึงข้อมูลคำถาม คำตอบมาตรฐาน คำตอบที่ระบบสร้าง และข้อมูลบริบทที่ค้นพบจาก Record แล้วสร้างกรณีทดสอบสำหรับ DeepEval จากนั้นประเมินด้วยตัวชี้วัดทั้งสี่ตัว เก็บคะแนนของแต่ละตัวชี้วัด คำนวณคะแนนเฉลี่ย และคืนผลลัพธ์เป็นข้อมูลที่ประกอบด้วยรหัสการประเมิน รหัสการทดลองหลัก รหัสการทดลองของ Record รหัสคำถาม การตั้งคำถามทดลอง คำถาม คำตอบมาตรฐาน คำตอบที่ระบบสร้าง ข้อมูลบริบทที่ค้นพบ คะแนนของแต่ละตัวชี้วัด เหตุผล คะแนนเฉลี่ย และข้อมูลเพิ่มเติม สร้างฟังก์ชัน Build Summary เพื่อจัดกลุ่มผลลัพธ์ตามรหัสการทดลองหลัก และคำนวณค่าเฉลี่ยของ Answer Relevancy, Faithfulness, Contextual Precision, Contextual Recall และคะแนนเฉลี่ยรวม จากนั้นเรียงลำดับผลการทดลองจากคะแนนรวมสูงที่สุดไปต่ำที่สุด โปรแกรมต้องบันทึกผลลัพธ์ออกเป็นไฟล์รายละเอียดแบบ JSON ไฟล์รายละเอียดแบบ CSV ไฟล์สรุปแบบ JSON และไฟล์สรุปแบบ CSV โดยไฟล์ CSV ต้องรองรับภาษาไทยและใช้การเข้ารหัส UTF 8 with BOM โปรแกรมต้องรองรับการทำงานต่อจากผลลัพธ์เดิมด้วย Resume โดยโหลดผลลัพธ์เดิมจากไฟล์รายละเอียด ข้าม Record ที่มีรหัสการทดลองของ Record ซึ่งประเมินสำเร็จแล้ว และป้องกันข้อมูลซ้ำด้วยรหัสการทดลองของ Record โปรแกรมต้องรองรับการประเมินเฉพาะรายการที่เคยเกิด

ข้อผิดพลาด Invalid JSON โดยโหลทรายการข้อผิดพลาดเดิม เลือกเฉพาะ Record ที่เคยเกิดข้อผิดพลาด Evaluation LLM Outputted an Invalid JSON แล้วนำกลับมาประเมินใหม่ และหากประเมินสำเร็จให้ลบข้อผิดพลาดเดิมของ Record นั้นออก โปรแกรมต้องรองรับคำสั่งสำหรับกำหนดไฟล์นำเข้า โพลเดอร์ผลลัพธ์ จำนวน Record ที่ต้องการประเมิน การเลือกเฉพาะการทดลอง เวลาพักระหว่าง Record การทำงานต่อจากผลลัพธ์เดิม และการประเมินเฉพาะ Invalid JSON โปรแกรมต้องบันทึกผลลัพธ์ทันทีหลังจากประเมินแต่ละ Record เพื่อป้องกันข้อมูลสูญหายหากโปรแกรมหยุดทำงานระหว่างการประเมิน และควรแสดงสถานะการทำงานระหว่างประเมิน เช่น จำนวน Record ที่ต้องประเมิน ชื่อโมเดล Judge ค่า Threshold สถานะ Resume จำนวน Record ที่ประเมินสำเร็จ จำนวน Invalid JSON Error Record ที่กำลังประเมิน ตัวชี้วัดที่กำลังประเมิน คะแนนเฉลี่ย และสถานะสำเร็จหรือข้อผิดพลาด ให้เขียนโปรแกรมโดยแบ่งฟังก์ชันอย่างชัดเจน อ่านง่าย และมี Type Hints รองรับภาษาไทยทั้งการอ่านและการเขียนไฟล์ ไม่ต้องใช้ Contextual Relevancy ไม่ต้องสร้างเหตุผลประกอบคะแนนเพื่อให้การประเมินทำงานได้รวดเร็วขึ้น และต้องเขียนเป็นโปรแกรม Python เติมรูปแบบที่สามารถนำไปใช้งานได้จริง

### 3.Trulens

#### 3.1 Prompt ในการสร้างเครื่องมือประเมิน

คุณคือ Senior Python Developer และ AI Evaluation Engineer ช่วยเขียนโค้ด Python สำหรับทำ TruLens Evaluation Pipeline ของระบบ RAG โดยมีเป้าหมายเพื่อประเมินคุณภาพของระบบ RAG ด้วย TruLens RAG Triad โดยใช้ Gemini เป็น Judge Model ผ่าน LiteLLM จากนั้นสรุปผลการประเมินออกมาเป็นไฟล์ JSON และ CSV โปรแกรมต้องอ่านข้อมูลจากไฟล์ raw rag results json ซึ่งมี key หลักคือ dataset name และ records โดยแต่ละ record ประกอบด้วย experiment id ซึ่งมีรูปแบบตัวอย่างเช่น exp 01 id1 cs256 co64 k3, config ซึ่งประกอบด้วย chunk size, chunk overlap และ top k, metrics input ซึ่งประกอบด้วย q id, question, ground truth, generated answer และ retrieved contexts ที่เป็นรายการข้อความรวมถึง metadata จากนั้นให้วนประเมินแต่ละ record ด้วย TruLens RAG Triad จำนวน 3 Metrics ได้แก่ Context Relevance, Groundedness และ Answer Relevance โดย Context Relevance ให้ใช้ TruLens provider context relevance และประเมินทีละ context จาก retrieved contexts แล้วคำนวณค่าเฉลี่ยของทุก context เป็น Context Relevance Score สำหรับ Groundedness ห้ามใช้ TruLens provider groundedness เนื่องจากมีปัญหาเกี่ยวกับ tuple และ float ให้สร้าง Custom Groundedness Function โดยเรียก Gemini โดยตรงผ่าน LiteLLM และใช้ Prompt ภาษาไทยเพื่อประเมินว่าคำตอบมีหลักฐานรองรับจาก context มากน้อยเพียงใด โดยกำหนดเกณฑ์คะแนน 1.0 หมายถึงมีหลักฐานรองรับทั้งหมด 0.5 หมายถึงมีหลักฐานรองรับบางส่วน และ 0.0 หมายถึงไม่มีหลักฐานรองรับ และให้ Gemini ตอบกลับในรูปแบบ JSON ที่ประกอบด้วย score ซึ่งเป็นตัวเลขแบบ float และ reason ซึ่งเป็นข้อความ สำหรับ Answer Relevance ให้ใช้ TruLens provider relevance เพื่อประเมินว่า generated answer ตรงตรงกับ question มากน้อยเพียงใด จากนั้นคำนวณ average score จาก Context Relevance,

Groundedness และ Answer Relevance โดยใช้สูตรค่าเฉลี่ยของคะแนนทั้งสามตัว ให้ตั้ง q id จาก metrics input q id ก่อน และหากไม่มีให้ตั้งจาก experiment id ด้วย Regular Expression รูปแบบ id ตามด้วยตัวเลข และสร้าง base experiment id โดยตัดส่วน id และตัวเลขออกจาก experiment id เช่น exp 01 id1 cs256 co64 k3 ให้กลายเป็น exp 01 cs256 co64 k3 ให้ใช้ Gemini ผ่าน LiteLLM และ TruLens โดยใช้ Library litellm และ trulens providers litellm อ่านชื่อโมเดลจากไฟล์ ENV ผ่านตัวแปร TRULENS GEMINI MODEL หากไม่มีให้ใช้ gemini 2.5 flash lite เป็นค่าเริ่มต้น อ่าน API Key จากไฟล์ ENV ผ่าน GEMINI API KEY หรือ GOOGLE API KEY และกำหนด temperature เป็น 0 ต้องมีระบบ Retry โดย Retry ได้สูงสุด 10 ครั้ง และ Retry เฉพาะ Error ที่เกี่ยวข้องกับ 429, 503, UNAVAILABLE, Service Unavailable, high demand, RESOURCE EXHAUSTED และ RateLimitError โดยใช้ Linear Backoff ซึ่งคำนวณเวลารอจาก RETRY WAIT SECONDS คูณด้วยจำนวนครั้งที่ Retry โปรแกรมต้องบันทึก Checkpoint หลังจากประเมินแต่ละ Record โดยบันทึกลงไฟล์ trulens results detail json และหากไฟล์นี้มีอยู่แล้วให้โหลดข้อมูลเดิมและข้าม Record ที่ประเมินสำเร็จแล้วเพื่อรองรับ Resume Mode ส่วน Record ที่เกิด Error ให้บันทึกไว้ใน key errors และต้องสามารถนำ Error เดิมกลับมาประเมินใหม่ได้ รองรับ Command Line Arguments ได้แก่ input สำหรับกำหนด path ของ Input JSON โดยค่าเริ่มต้นเป็น raw rag results json, output dir สำหรับกำหนดโฟลเดอร์ Output โดยค่าเริ่มต้นเป็น outputs trulens, limit สำหรับจำกัดจำนวน Record ที่ต้องการประเมิน, only experiment สำหรับเลือกเฉพาะ base experiment id ที่ระบุ, only record สำหรับเลือกเฉพาะ record experiment id เดียวแล้วนำผลลัพธ์กลับไป merge กับผลลัพธ์เดิม, only error สำหรับประเมินเฉพาะ Record ที่เคยเกิด Error แล้วนำผลลัพธ์กลับไป merge, resume สำหรับข้าม Record ที่ประเมินสำเร็จแล้วและ merge ผลลัพธ์กลับไป merge, sleep สำหรับกำหนดเวลาพักระหว่าง Record โดยค่าเริ่มต้นเป็น 1 วินาที หลังจากประเมินเสร็จให้สร้าง Summary โดย Group ตาม base experiment id และคำนวณค่าเฉลี่ยของ Context Relevance, Groundedness, Answer Relevance และ Overall Average Score ของแต่ละกลุ่ม จากนั้นเรียงลำดับจาก Overall Average Score มากไปน้อย โปรแกรมต้องสร้าง Output ทั้งหมด 4 ไฟล์ ได้แก่ trulens results detail json, trulens results detail csv, trulens results summary json และ trulens results summary csv และต้องบันทึกผลหลังประเมินทุก Record เพื่อป้องกันข้อมูลสูญหาย โดย CSV Detail ต้องมี Column ได้แก่ Evaluation ID, Base Experiment ID, Record Experiment ID, Q ID, Chunk Size, Chunk Overlap, Top K, Question, Context Relevance, Groundedness, Answer Relevance, Average Score และ Error ส่วน CSV Summary ต้องมี Column ได้แก่ experiment id, record count, chunk size, chunk overlap, top k, average context relevance, average groundedness, average answer relevance และ overall average score โค้ดต้องมี main และสามารถรันด้วยคำสั่ง python run trulens from raw json.py ได้ โดยใช้ Library ได้แก่ litellm, trulens providers litellm, pydantic, python dotenv และ pandas ให้เขียนโค้ดแบบอ่านง่าย แบ่ง Section อย่างชัดเจนเป็น CONFIG, HELPERS, CUSTOM GROUNDEDNESS, TRULENS RAG TRIAD, SUMMARY และ MAIN พร้อม Comment และ Docstring ด้านบน และต้องเขียนเป็น

Python เต็มไฟล์ที่สามารถนำไปใช้งานได้ ห้ามเขียน Pseudocode พร้อมอธิบายวิธีติดตั้ง Library วิธีสร้างไฟล์ ENV และวิธีรันโปรแกรมให้ครบถ้วน

## 4. LLM-as-a-Judge

### 4.1 Prompt ในการสร้างเครื่องมือประเมิน

คุณคือ Senior Python Developer และ AI Evaluation Engineer ช่วยเขียนโค้ด Python สำหรับทำ Master Evaluation Pipeline ของระบบ RAG โดยมีเป้าหมายเพื่อรวมผลการประเมินจาก 3 Framework ได้แก่ Ragas, DeepEval และ TruLens แล้วใช้ Gemini เป็น LLM as a Judge เพื่อประเมินคำตอบเพิ่มเติม จากนั้นสรุปผลการประเมินออกมาเป็นไฟล์ JSON และ CSV โปรแกรมต้องอ่านข้อมูลจากไฟล์ ragas results detail json, deepeval results detail json และ trulens results detail json โดยแต่ละไฟล์มี key หลักคือ dataset name และ evaluations ซึ่งภายใน evaluations แต่ละ record มีข้อมูลประมาณ evaluation id, experiment id หรือ base experiment id, q id, config, question, ground truth, generated answer, retrieved contexts, scores, average score และ metadata โปรแกรมต้องโหลดข้อมูลจากไฟล์ JSON ทั้งสามไฟล์และจับคู่ข้อมูลของ Ragas, DeepEval และ TruLens โดยใช้ experiment id ร่วมกับ q id เป็นตัวระบุหลัก หาก q id ไม่มีโดยตรงให้พยายามดึง q id จาก evaluation id ด้วยรูปแบบ Regular Expression เช่น q001, id1 หรือ q1 หากไม่พบข้อมูล DeepEval หรือ TruLens ที่ตรงกับ Ragas ให้แสดงข้อผิดพลาดโดยระบุ experiment id และ q id ที่ไม่สามารถจับคู่ได้ จากนั้นสร้าง Base Record ที่รวมข้อมูล evaluation id, experiment id, q id, config, question, ground truth, generated answer, retrieved contexts, ผลการประเมินจาก Ragas, DeepEval และ TruLens และ performance metadata ของข้อมูลแต่ละรายการ โปรแกรมต้องใช้ Gemini API ผ่าน Library Google GenAI โดยใช้โมเดล Gemini 2.5 Flash Lite อ่าน API Key จากไฟล์ ENV ผ่านตัวแปร GEMINI\_API\_KEY กำหนด temperature เป็น 0 และให้ Gemini ส่งผลลัพธ์เป็น JSON เท่านั้น โดยใช้ Pydantic Schema เพื่อควบคุมรูปแบบผลลัพธ์ของ Gemini ให้สร้าง Pydantic Class ชื่อ Judge Output ซึ่งมี accuracy score เป็นตัวเลขระหว่าง 0.0 ถึง 1.0, completeness score เป็นตัวเลขระหว่าง 0.0 ถึง 1.0, clarity score เป็นตัวเลขระหว่าง 0.0 ถึง 1.0, reasoning accuracy เป็นข้อความ, reasoning completeness เป็นข้อความ และ reasoning clarity เป็นข้อความ Prompt สำหรับ Gemini Judge ต้องกำหนดให้ Gemini ทำหน้าที่เป็นกรรมการกลางสำหรับประเมินคุณภาพคำตอบของระบบ RAG โดยให้เปรียบเทียบ Generated Answer กับ Ground Truth เท่านั้น ห้ามใช้ Retrieved Contexts ห้ามใช้คะแนนจาก Framework อื่น และห้ามใช้ความรู้จากภายนอก ให้คะแนน Accuracy, Completeness และ Clarity ในช่วง 0.0 ถึง 1.0 และให้เหตุผลเป็นภาษาไทยที่สั้น ชัดเจน และเข้าใจง่าย จากนั้นคำนวณ Gemini Average โดยนำ Accuracy Score, Completeness Score และ Clarity Score มาหาค่าเฉลี่ย คำนวณ Combined Three Frameworks Average โดยนำค่าเฉลี่ยของ Ragas, DeepEval และ TruLens มาหาค่าเฉลี่ย และคำนวณ Final Combined Average โดยนำ Combined Three Frameworks Average และ Gemini Average มาหาค่าเฉลี่ย โปรแกรมต้องมีระบบ Retry สำหรับข้อผิดพลาดจาก Gemini โดย

Retry สูงสุด 7 ครั้ง และ Retry เฉพาะข้อผิดพลาดประเภท 429, 500, 502, 503, 504, Timeout, Unavailable, Overloaded, Server Disconnected และ Connection Error โดยใช้ Exponential Backoff ร่วมกับ Random Jitter โปรแกรมต้องบันทึก Checkpoint หลังประเมินแต่ละคำถามลงในไฟล์ master evaluation results detail json และหากไฟล์นี้มีอยู่แล้วให้โหลดข้อมูลเดิมและข้าม evaluation id ที่เคยประเมินสำเร็จแล้ว หากเกิดข้อผิดพลาดให้บันทึกข้อมูลข้อผิดพลาดไว้ใน key errors เพื่อให้สามารถตรวจสอบและประเมินใหม่ได้ หลังจากประเมินข้อมูลทั้งหมดเสร็จให้สร้าง Summary โดยจัดกลุ่มตาม experiment id และคำนวณ Mean, Population Standard Deviation, Minimum และ Maximum ของคะแนนแต่ละประเภท ได้แก่ Ragas Average Score, DeepEval Average Score, TruLens Average Score, Combined Three Frameworks Average, Gemini Accuracy, Gemini Completeness, Gemini Clarity, Gemini Average และ Final Combined Average จากนั้นสร้าง Output จำนวน 3 ไฟล์ ได้แก่ master evaluation results detail json, master evaluation summary json และ master evaluation summary csv โดยไฟล์ Summary CSV ต้องมี Column ได้แก่ experiment id, chunk size, chunk overlap, top k, record count, Ragas Mean, DeepEval Mean, TruLens Mean, Combined Three Frameworks Mean, Gemini Accuracy Mean, Gemini Completeness Mean, Gemini Clarity Mean, Gemini Average Mean และ Final Combined Mean โปรแกรมต้องมี main function และสามารถรันด้วยคำสั่ง python run master evaluation with Gemini.py ได้ ใช้ Library ได้แก่ Google GenAI, Pydantic และ Python Dotenv เขียนโค้ดแบบอ่านง่าย แบ่ง Section อย่างชัดเจน เป็น Settings, Gemini Result Schema, Prompt, Helpers, Gemini Call, Prepare Data From All Frameworks, Summary และ Main พร้อม Comment และ Docstring ด้านบน โดยต้องเขียนเป็น Python เต็มไฟล์ที่สามารถนำไปใช้งานจริงได้ ห้ามเขียน Pseudocode และต้องอธิบายวิธีติดตั้ง Library วิธีสร้างไฟล์ ENV วิธีเตรียมไฟล์ Input และวิธีรันโปรแกรมให้ครบถ้วน

## 5.ข้อมูลดิบสร้าง Ground-truth แล้วมี Generated-answer

### 5.1 Prompt ในการสร้างเครื่องมือประเมิน

คุณคือ Senior Python Developer และ AI Engineer ช่วยเขียนโปรแกรม Python สำหรับสร้างข้อมูลดิบเพื่อใช้ประเมินระบบ RAG โดยมีเป้าหมายเพื่อรันคำถามหลายข้อกับหลาย Experiment ของระบบ RAG แล้วบันทึกผลลัพธ์เป็นไฟล์ JSON เพื่อนำไปใช้ต่อกับ Ragas, DeepEval และ TruLens โปรแกรมต้องใช้ Python 3, Ollama สำหรับสร้าง Embedding โดยใช้โมเดล nomic embed text latest, Supabase และ pgvector สำหรับทำ Vector Search โดยเรียก Supabase ผ่าน RPC Function ชื่อ match documents, Gemini API สำหรับสร้างคำตอบโดยใช้ Gemini 2.5 Flash Lite เป็นค่าเริ่มต้น, Python Dotenv สำหรับโหลดค่าจากไฟล์ ENV และ Requests สำหรับเรียก API โดยไฟล์ Input ประกอบด้วย raw rag evaluation input 100 json ซึ่งภายในเป็น List หรือ Dict ที่มี Key records, data หรือข้อมูล และแต่ละ Record มี id, question และ ground truth และมีไฟล์ experiments json ซึ่งมี Key experiments เป็น List โดยแต่ละ Experiment ประกอบด้วย experiment id, chunk size, chunk overlap, candidate

k, top k, rpc function, embedding model, supabase url env, supabase key env และ enabled ส่วนไฟล์ ENV ต้องรองรับ GEMINI API KEY, GEMINI MODEL, OLLAMA BASE URL, EMBEDDING MODEL, REQUEST TIMEOUT SECONDS รวมถึง Supabase URL และ Key ตามชื่อ Environment Variable ที่ระบุใน experiments json โปรแกรมต้องโหลดคำถามจาก Input JSON โหลด Experiments จาก experiments json และเลือกเฉพาะ Experiment ที่ enabled เป็น true จากนั้นวนทุก Experiment และทุก Question โดยสร้าง Embedding จาก Question ผ่าน Ollama Endpoint api embed แล้วส่ง Embedding ไปยัง Supabase RPC ผ่าน Endpoint rest v1 rpc ตามชื่อ RPC Function ที่กำหนดใน Experiment จากนั้นให้ Supabase คืน Context ตามค่า Candidate K และทำการ Rerank Context ใหม่ก่อนเลือก Final Top K โดยใช้ Hybrid Score ซึ่งคำนวณจาก Vector Similarity รวมกับ Keyword Bonus และ Metadata Bonus แล้วหัก Noise Penalty โดย Keyword Bonus ให้คำนวณจาก Keyword ในคำถามที่พบใน Context และ Metadata Bonus ให้พิจารณาหมวดคำถาม เช่น dsl, studentloan หรือ กยศ, military หรือ ผ่อนผันทหาร และ rotc หรือ นศท ส่วน Noise Penalty ให้ลดคะแนน Context ที่มีข้อความ Noise เช่น บริบทโดยย่อ, เครื่องหมายแบ่งส่วน Context, แท็ก Chunk และแท็ก Document รวมถึงรูปแบบข้อความที่ไม่จำเป็น ต้องลบ Context ที่ซ้ำกันก่อนเลือก Context สุดท้ายตามค่า Top K จากนั้นสร้าง Prompt ภาษาไทยสำหรับ Gemini โดยกำหนดบทบาทให้เป็นผู้ช่วยของกองพัฒนานักศึกษา มหาวิทยาลัยราชภัฏนครปฐม และกำหนดให้ใช้เฉพาะข้อมูลจาก Context เท่านั้น ห้ามใช้ความรู้ภายนอก ห้ามเดา และหาก Context ไม่เกี่ยวข้องให้ตอบว่า ขอภัยค่ะ ไม่พบข้อมูลนี้ในระบบ กรุณาติดต่อกองพัฒนานักศึกษา 034 109 300 ต่อ 3388 หากมี Source ให้ใส่ท้ายคำตอบว่า ที่มา: [source] จากนั้นส่ง Prompt เข้า Gemini เพื่อสร้าง Generated Answer และเก็บ Metadata ได้แก่ Timestamp, Retrieval Latency, Generation Latency และ Total Tokens Used โดย Output JSON ในแต่ละ Record ต้องมี Experiment ID ที่แทรก Q ID ลงในรูปแบบ เช่น exp 01 id1 cs256 co64 k3, Config ซึ่งประกอบด้วย Chunk Size, Chunk Overlap และ Top K และ Metrics Input ซึ่งประกอบด้วย Q ID, Question, Ground Truth, Retrieved Contexts และ Generated Answer รวมถึง Metadata โดย Output หลักต้องมี Dataset Name, Description, Database Count, Experiment Count, Question Count, Expected Record Count, Record Count, Error Count, Experiments, Records และ Errors หากเกิด Error ระหว่างการทำงานให้เก็บข้อมูล Error ลงใน Errors และทำงานต่อโดยไม่หยุดโปรแกรม ต้องบันทึก Output JSON หลังประมวลผลทุก Question เพื่อป้องกันข้อมูลสูญหายหากโปรแกรมหยุดทำงาน และต้องรองรับ Command Line Arguments ได้แก่ input, experiments, output, limit questions และ only experiment โดยโปรแกรมต้องเขียนเป็นไฟล์เดียว ใช้ Type Hints แยกฟังก์ชันอย่างชัดเจน มี Error Handling รองรับภาษาไทย ใช้ JSON Dump โดยกำหนด ensure ascii เป็น false และ indent เป็น 2 ห้ามใช้ LangChain ห้ามใช้ OpenAI และต้องสามารถรันจาก Command Line ได้โดยตรง ให้เขียนโค้ด Python แบบเต็มไฟล์ที่สามารถนำไปใช้งานจริงได้ พร้อม Comment และ Docstring อธิบายส่วนสำคัญของโปรแกรม และห้ามเขียน Pseudocode


ภาคผนวก ค  
ผลการประเมินระบบ

## ภาคผนวก ค

### ผลการประเมินระบบ

#### 1.ผลการประเมิน Ragas

ตารางผลการประเมินด้วย RAGAS ของการทดลองทั้ง 8 Experiments




|    | A               | B                       | C                   | D                        | E                     | F | G |
|----|-----------------|-------------------------|---------------------|--------------------------|-----------------------|---|---|
| 1  | <b>การทดลอง</b> | <b>Answer Relevancy</b> | <b>Faithfulness</b> | <b>Context Precision</b> | <b>Context Recall</b> |   |   |
| 2  | Exp 01          | 0.1616                  | 0.1591              | 0.1442                   | 0.1283                |   |   |
| 3  | Exp 02          | 0.1953                  | 0.3843              | 0.1598                   | 0.2150                |   |   |
| 4  | Exp 03          | 0.1310                  | 0.1567              | 0.1233                   | 0.1300                |   |   |
| 5  | Exp 04          | 0.1467                  | 0.3168              | 0.1256                   | 0.1400                |   |   |
| 6  | Exp 05          | 0.1700                  | 0.3518              | 0.1858                   | 0.1800                |   |   |
| 7  | Exp 06          | 0.2127                  | 0.4264              | 0.1870                   | 0.2900                |   |   |
| 8  | Exp 07          | 0.0741                  | 0.1322              | 0.0675                   | 0.0900                |   |   |
| 9  | Exp 08          | 0.0679                  | 0.1242              | 0.0608                   | 0.0900                |   |   |
| 10 |                 |                         |                     |                          |                       |   |   |
| 11 |                 |                         |                     |                          |                       |   |   |

ภาพที่ ค-1 ตารางผลการประเมินด้วย RAGAS

#### 2.ผลการประเมิน Deepeval

ตารางผลการประเมินด้วย Deepeval ของการทดลองทั้ง 8 Experiments




|    | A               | B                       | C                   | D                           | E                        |
|----|-----------------|-------------------------|---------------------|-----------------------------|--------------------------|
| 1  | <b>การทดลอง</b> | <b>Answer Relevancy</b> | <b>Faithfulness</b> | <b>Contextual Precision</b> | <b>Contextual Recall</b> |
| 2  | Exp 01          | 0.7117                  | 0.9617              | 0.2417                      | 0.2200                   |
| 3  | Exp 02          | 0.7282                  | 0.9183              | 0.2442                      | 0.2800                   |
| 4  | Exp 03          | 0.7537                  | 0.8955              | 0.1658                      | 0.1700                   |
| 5  | Exp 04          | 0.7182                  | 0.9472              | 0.1491                      | 0.2100                   |
| 6  | Exp 05          | 0.7350                  | 0.9067              | 0.2325                      | 0.2650                   |
| 7  | Exp 06          | 0.7303                  | 0.9350              | 0.2454                      | 0.3450                   |
| 8  | Exp 07          | 0.8008                  | 0.9250              | 0.1108                      | 0.1550                   |
| 9  | Exp 08          | 0.7688                  | 0.9092              | 0.1339                      | 0.1583                   |
| 10 |                 |                         |                     |                             |                          |
| 11 |                 |                         |                     |                             |                          |
| 12 |                 |                         |                     |                             |                          |

ภาพที่ ค-2 ตารางผลการประเมินด้วย Deepeval

### 3.ผลการประเมิน Trulens

ตารางผลการประเมินด้วย Trulens ของการทดลองทั้ง 8 Experiments




|   | A        | B                 | C            | D                |
|---|----------|-------------------|--------------|------------------|
| 1 | การทดลอง | Context Relevance | Groundedness | Answer Relevance |
| 2 | Exp 01   | 0.1620            | 0.1850       | 0.2000           |
| 3 | Exp 02   | 0.1927            | 0.2750       | 0.2700           |
| 4 | Exp 03   | 0.1589            | 0.1700       | 0.1400           |
| 5 | Exp 04   | 0.1487            | 0.1850       | 0.1700           |
| 6 | Exp 05   | 0.3267            | 0.2050       | 0.2033           |
| 7 | Exp 06   | 0.2733            | 0.2700       | 0.2667           |
| 8 | Exp 07   | 0.2522            | 0.0850       | 0.1233           |
| 9 | Exp 08   | 0.1947            | 0.0900       | 0.1200           |

ภาพที่ ค-3 ตารางผลการประเมินด้วย Trulens

### 4.ผลการประเมิน LLM-as-a-Judge

ตารางผลการประเมินด้วย LLM-as-a-Judge ของการทดลองทั้ง 8 Experiments




|   | A        | B        | C            | D       | E | F |
|---|----------|----------|--------------|---------|---|---|
| 1 | การทดลอง | Accuracy | Completeness | Clarity |   |   |
| 2 | Exp 01   | 0.1620   | 0.1610       | 0.4940  |   |   |
| 3 | Exp 02   | 0.2310   | 0.2320       | 0.5540  |   |   |
| 4 | Exp 03   | 0.1370   | 0.1360       | 0.4750  |   |   |
| 5 | Exp 04   | 0.1487   | 0.1520       | 0.4870  |   |   |
| 6 | Exp 05   | 0.1920   | 0.1940       | 0.5120  |   |   |
| 7 | Exp 06   | 0.2610   | 0.2660       | 0.5690  |   |   |
| 8 | Exp 07   | 0.1080   | 0.1060       | 0.4570  |   |   |
| 9 | Exp 08   | 0.1080   | 0.1070       | 0.4480  |   |   |

ภาพที่ ค-4 ตารางผลการประเมินด้วย LLM-as-a-Judge

## 5.ผลการเปรียบเทียบคะแนนเฉลี่ยของแต่ละการทดลอง

ผลการเปรียบเทียบคะแนนเฉลี่ยของแต่ละการทดลอง ของการทดลองทั้ง 8 Experiments



|    | A               | B            | C               | D              | E                     | F                     | G |
|----|-----------------|--------------|-----------------|----------------|-----------------------|-----------------------|---|
| 1  | <b>การทดลอง</b> | <b>RAGAS</b> | <b>DeepEval</b> | <b>TruLens</b> | <b>LLM-as-a-Judge</b> | <b>Final Combined</b> |   |
| 2  | Exp 01          | 0.1492       | 0.5338          | 0.1954         | 0.2723                | 0.2825                |   |
| 3  | Exp 02          | 0.2386       | 0.5427          | 0.2459         | 0.3390                | 0.3407                |   |
| 4  | Exp 03          | 0.1353       | 0.4963          | 0.1563         | 0.2494                | 0.2560                |   |
| 5  | Exp 04          | 0.1823       | 0.5061          | 0.1679         | 0.2624                | 0.2739                |   |
| 6  | Exp 05          | 0.2219       | 0.5348          | 0.2450         | 0.2994                | 0.3166                |   |
| 7  | Exp 06          | 0.2790       | 0.5639          | 0.2700         | 0.3653                | 0.3682                |   |
| 8  | Exp 07          | 0.0909       | 0.4979          | 0.1535         | 0.2237                | 0.2356                |   |
| 9  | Exp 08          | 0.0857       | 0.4926          | 0.1349         | 0.2210                | 0.2294                |   |
| 10 |                 |              |                 |                |                       |                       |   |
| 11 |                 |              |                 |                |                       |                       |   |
| 12 |                 |              |                 |                |                       |                       |   |

ภาพที่ ค-5 ผลการเปรียบเทียบคะแนนเฉลี่ยของแต่ละการทดลอง

## ประวัติผู้จัดทำ

|                 |                                                                                                                                                     |
|-----------------|-----------------------------------------------------------------------------------------------------------------------------------------------------|
| ชื่อ            | นาย พชรพงศ์ อิติวานิชย์                                                                                                                             |
| วันเดือนปีเกิด  | วันที่ 1 มกราคม พ.ศ. 2547                                                                                                                           |
| ที่อยู่         | บ้านเลขที่ 99/118 หมู่ที่ 3 ตำบล ธรรมศาลา อำเภอ เมืองนครปฐม<br>จังหวัด นครปฐม รหัสไปรษณีย์ 73000                                                    |
| E-mail          | gameminkung3@gmail.com                                                                                                                              |
| หมายเลขโทรศัพท์ | 092-765-8906                                                                                                                                        |
| การศึกษา        | ระดับมัธยมต้น โรงเรียนพระปฐมวิทยาลัย<br>ระดับมัธยมปลาย วิทยาลัยอาชีวศึกษานครปฐม<br>ระดับปริญญาตรี สาขาวิชา เทคโนโลยีสารสนเทศมหาวิทยาลัยราชภัฏนครปฐม |

## ประวัติผู้จัดทำ

|                 |                                                                                                                                                 |
|-----------------|-------------------------------------------------------------------------------------------------------------------------------------------------|
| ชื่อ            | นาย ชาญวิชญ์ เทพเทียน                                                                                                                           |
| วันเดือนปีเกิด  | วันที่ 26 ตุลาคม พ.ศ.2546                                                                                                                       |
| ที่อยู่         | บ้านเลขที่ 23 หมู่ 6 ต.ทุ่งเฒ่า อ.เมือง จ.นครปฐม รหัสไปรษณีย์ 73000                                                                             |
| E-mail          | markeiei2610@gmail.com                                                                                                                          |
| หมายเลขโทรศัพท์ | 065-980-2159                                                                                                                                    |
| การศึกษา        | ระดับมัธยมต้น โรงเรียนศรีวิชัยวิทยา<br>ระดับมัธยมปลาย โรงเรียนศรีวิชัยวิทยา<br>ระดับปริญญาตรี สาขาวิชา เทคโนโลยีสารสนเทศมหาวิทยาลัยราชภัฏนครปฐม |

## ประวัติผู้จัดทำ

|                 |                                                                                                                                             |
|-----------------|---------------------------------------------------------------------------------------------------------------------------------------------|
| ชื่อ            | นาย ลภัส โพธิ์ทองคำ                                                                                                                         |
| วันเดือนปีเกิด  | วันที่ 16 ตุลาคม พ.ศ.2546                                                                                                                   |
| ที่อยู่         | บ้านเลขที่ 459/3 ต.พระประโทนเจดีย์ อ.เมือง จ.นครปฐม<br>รหัสไปรษณีย์73000                                                                    |
| E-mail          | liwliw123za@gmail.com                                                                                                                       |
| หมายเลขโทรศัพท์ | 083-597-6926                                                                                                                                |
| การศึกษา        | ระดับมัธยมต้น โรงเรียนพระปฐมวิทยาลัย<br>ระดับมัธยมปลาย อาชีวศึกษานครปฐม<br>ระดับปริญญาตรี สาขาวิชา เทคโนโลยีสารสนเทศมหาวิทยาลัยราชภัฏนครปฐม |

## ประวัติผู้จัดทำ

|                 |                                                                                                                                                   |
|-----------------|---------------------------------------------------------------------------------------------------------------------------------------------------|
| ชื่อ            | นาย วัฒนา รัตนสุวรรณชัย                                                                                                                           |
| วันเดือนปีเกิด  | วันที่ 7 มีนาคม พ.ศ. 2547                                                                                                                         |
| ที่อยู่         | บ้านเลขที่ 75/7 ต.ทุ่งคอก อ.สองพี่น้อง จ.สุพรรณบุรี รหัสไปรษณีย์ 72190                                                                            |
| E-mail          | wattanatatar@gmail.com                                                                                                                            |
| หมายเลขโทรศัพท์ | 094-793-4970                                                                                                                                      |
| การศึกษา        | ระดับมัธยมต้น โรงเรียนสระยายโสมวิทยา<br>ระดับมัธยมปลาย โรงเรียนสระยายโสมวิทยา<br>ระดับปริญญาตรี สาขาวิชา เทคโนโลยีสารสนเทศมหาวิทยาลัยราชภัฏนครปฐม |